А. В. Пролубников

МАШИННОЕ ОБУЧЕНИЕ

НЕЙРОННЫЕ СЕТИ

Новосибирский государственный университет

2025

Оглавление

1 Введение **7**

1.1 Распознавание образов и машинное обучение 7

1.1.1 Обучение с учителем 9

1.1.2 Обучение без учителя 10

1.2 Вектор признаков 13

1.3 Ошибка обобщения. Недообучение и переобучение. 16

1.4 Регистрация информации и ошибки в данных 17

2 Элементы теории вероятностей **21**

2.1 Случайная величина 22

2.2 Вероятностные распределения 22

2.3 Центральная предельная теорема 26

2.4 Генерирование нормально распределённой случайной величины 27

2.4.1 Табличный способ 28

2.4.2 Способ, использующий ЦПТ 28

2.5 Формула Байеса 29

2.5.1 Формула Байеса 29

2.5.2 Байесовский классификатор для распознавания спама 31

2.6 Задания 34

3 Метод ближайшего соседа **35**

3.1 Постановка задачи 35

3.2 Мера близости. Функция ошибки 36

3.3 Метод ближайшего соседа 38

3.4 Выбор параметров метода ближайшего соседа 40

3.5 Распознавание растровых изображений с помощью метода ближайшего соседа . . . 41
3.6 Метод ближайшего соседа как подход к оценке плотности случайной величины . . . 43
3.6.1 Ядерное оценивание плотности распределения . . . 45
3.6.2 Метод ближайшего соседа . . . 47
3.7 Регрессия с помощью метода ближайшего соседа и ядерная регрессия . . . 48
3.8 Прототипы и выбросы. . . . 51
3.9 Нормализация . . . 53
3.10 Проклятие размерности . . . 54
3.11 Метод главных компонент . . . 58
3.12 Компромисс между смещением и дисперсией . . . 60
3.12.1 Ошибки смещения и дисперсии . . . 60
3.12.2 Декомпозиция ошибки прогнозирования с помощью модели на ошибку смещения и дисперсии . . . 65
3.12.3 Достижение компромисса между смещением и дисперсией . . . 66
3.13 Задания . . . 68

4 Метод наименьших квадратов для решения задач регрессионного анализа 71
4.1 Задача регрессионного анализа и метод наименьших квадратов . . . 71
4.2 Линейная регрессия . . . 72
4.3 Полиномиальная регрессия . . . 76
4.4 Переобучение и способы его устранения . . . 76
4.5 Регуляризация . . . 77
4.6 Кросс-валидация . . . 81
4.7 Метод наименьших квадратов и метод наибольшего правдоподобия . . . 83
4.8 Задания . . . 86

5 Нейронные сети 89
5.1 Перцептрон . . . 90
5.2 Многослойный перцептрон . . . 97
5.3 Выбор функции активации . . . 101

5.4 Обучение нейронной сети 104
5.5 Вычисление градиента функции ошибки 107
5.5.1 Приближённое вычисление 107
5.5.2 Метод обратного распространения ошибки 108
5.6 Взрыв и исчезновение градиента 111
5.7 Аппроксимационные возможности нейронных сетей 113
5.8 Задания 114

6 Деревья решений **117**
6.1 Категориальные и некатегориальные признаки 117
6.2 Выбор параметров классификаторов в узлах дерева решений 122
6.3 Меры неоднородности выборки 123
6.4 Критерии остановки ветвления 126
6.5 Усечение дерева решений 127
6.6 Случай неопределённых атрибутов 129
6.7 Случайные леса. Ансамбли классификаторов. Бэггинг. Бустинг 129
6.8 Задания 129

7 Байесовская теория решений **133**
7.1 Байесовское решающее правило 133
7.2 Минимизация ошибки и условный риск 136
7.3 Классификация в случае двух классов 140
7.4 Задача классификации с возможным отказом от принятия решения 141
7.5 Разделяющие функции 143
7.6 Дискретный случай 147
7.7 Задания 150

Литература **153**

1 Введение

1.1 Распознавание образов и машинное обучение

Распознавание образов это научное направление, включающее в себя разделы информатики и смежных математических дисциплин и связанное с разработкой методов для нахождения в данных закономерностей, а также для установления принадлежности некоторого объекта (предмета, процесса, явления, ситуации, сигнала) к одному из заранее выделенных классов объектов. Процесс распознавания основан на сопоставлении признаков, характеризующих исследуемый объект с признаками других известных объектов, в результате чего делается вывод о наиболее правдоподобном их соответствии. В англоязычной научной литературе это научное направление именуется как *pattern recognition* от слова *pattern* — образец, шаблон.

Исходя из такого распознавания, производимого с помощью вычислительных алгоритмов, принимаются решения относительно обрабатываемых данных, например, их классификация по различным заданным для них категориям (классам). Математические методы распознавания образов используются для решения таких прикладных задач, как распознавание почерка и речи, лиц, классификации текстов по рубрикам, распознавания штрих-кодов, автомобильных номеров, изображений, выявления аномальных режимов работы сердца по вариабельности сердечного ритма, распознавания сейсмических режимов и прогнозирования сейсмической опасности и многих других.

В рамках этого учебного пособия, прежде всего, мы будем иметь дело с двумя типами задач распознавания образов —

1) задачи восстановления функциональной зависимости (или задачи *регрессионного анализа*);
2) задачи классификации — задачи установления принадлежности неко-

торого объекта одному из заданных классов объектов.

Второй случай может быть рассмотрен как разновидность первого, в котором восстанавливаемая функциональная зависимость имеет конечную дискретную область значений. Однако, такая специфика приводит к постановкам задач, отличным от постановок задач регрессионного анализа.

Таким образом, рассматриваемые нами задачи — это задачи со следующей постановкой.

Задача 1. Предполагается существование некоторой неизвестной функции $f : X \to Y$. Задана *обучающая выборка* — это множество соответствующих друг другу значений $x \in X$ и $y \in Y$, то есть набор пар

$$\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \ldots, (x^{(N)}, y^{(N)})\},$$

где $y^{(i)} = f(x^{(i)}) + \varepsilon^{(i)}$ для некоторых малых значений $\varepsilon^{(i)}$, соответствующих *ошибкам измерений* значений $f(x^{(i)})$ в $x^{(i)}$. Необходимо найти такое отображение $\tilde{f} : X \to Y$, которое было бы как можно более близким к неизвестному отображению f в соответствии с некоторым критерием близости.

В случае решения задачи классификации X — множество классифицируемых объектов, Y — множество индексов (меток) заданных классов C_k. Близость полученного отображения $\tilde{f}$ к неизвестному отображению f оценивается с помощью обучающей выборки или с помощью другой, *валидационной* выборки, то есть других пар соответствующих значений x и y, используемых для такого оценивания. Кроме того, помимо обучающей и тестовой выборки для оценки близости $\tilde{f}$ к f может быть использована *тестовая* выборка, содержащая данные не используемые при обучении. В отличие от тестовой выборки, данные такой выборки не используются на этапах процесса обучения.

Таким образом, близость полученного отображения $\tilde{f}$ к неизвестному отображению f оценивается, вообще говоря, с помощью данных трёх выборок:

а) обучающей,
б) валидационной.
в) тестовой,

Для решения задач распознавания образов и классификации широко используются методы *машинного обучения*, которые характеризуются тем, что распознаванию (классификации), предшествует *стадия обучения*, в ходе которой на основе информации, предоставляемой обучающей выборкой, строится функция $\tilde{f}$. Стадия обучения представляет собой выбор параметров некоторой математической модели, на основе которой производится распознавание.

Методы машинного обучения подразделяются на два типа:

1) методы обучения с учителем,
2) методы обучения без учителя.

По мере развития вычислительной техники и методов работы с большими данными становятся всё более распространёнными методы *глубокого обучения*. Под такими методами понимаются методы машинного обучения использующие нейронные сети с достаточно сложной архитектурой для того, чтобы зафиксировать сложные зкономерности во входных данных, для обучения которых требуются боьшие объёмы данных. Особую роль при реализации таких методов машинного обучения играют подходы к организации вычислений при обучении, прежде всего использование параллельных вычислений.

1.1.1 Обучение с учителем

При *обучении с учителем* считается заданной обучающая выборка («размеченная выборка»), исходя из которой на стадии обучения строится отображение $\tilde{f}$. Так, в случае решения задачи классификации предполагается, что имеется некоторый набор объектов, отнесённых к одному из заданных классов.

Примером задачи с заданной обучающей выборкой является следующая задача 2. Такую постановку будет иметь задача распознавания растровых изображений, которую мы рассмотрим далее.

Задача 2. Пусть задано множество $P = \{P^{(1)}, \ldots, P^{(N)}\}$ некоторых *эталонных объектов*, как-либо математически описанных. Имеется объект P, который представляет собой некоторый объект $P^{(t)} \in P$, подвергнутый преобразованию, затрудняющему распознавание — определение того, из какого эталонного объекта в результате этого преобразования получен P. Необходимо распознать P.

Задание множества эталонных объектов P, относительно которых необходимо классифицировать объект P, в этой задаче эквивалентно заданию обучающей выборки, каждый элемент которой определяет класс C_k. Используя обучающую выборку P и применяя какой-либо метод машинного обучения, мы классифицируем объект P.

Обучение с учителем реализуется при решении задачи распознавания рукописного текста. На стадии обучения на вход алгоритма классификации подаются образцы написания буквы с указанием того, какой буквы образец написания подан. При этом для каждой буквы может быть использовано несколько изображений, отличающихся друг от друга, но позволяющих зафиксировать особенности её начертания. В результате, когда на стадии классификации на вход алгоритма подаётся изображение буквы, она распознаётся, исходя из зафиксированных на стадии обучения особенностей её начертания. Предполагается, что распознаваемая буква имеет начертание, вообще говоря, отличное от тех, что были использованы на стадии обучения.

Рассматриваемые в этом учебном пособии методы ближайшего соседа, линейной и полиномиальной регрессии, нейронных сетей прямого распространения относятся к методам, использующим обучение с учителем.

Для решения задач распознавания образов используются также вероятностные методы классификации. Вероятностные методы не ставят однозначно соответствующий распознаваемому объекту класс, а сопоставляют каждому классу вероятность того, что объект принадлежит ему.

Примером такого подхода является рассматриваемая в учебном пособии баейесовская теория решений. Этот подход также реализует обучение с учителем, поскольку для получения всей вероятностной информации, необходимой для его применения и которая считается заданной, требуется обучающая выборка. На основе этой выборки могут быть оценены вероятности, плотности вероятностных распределений, условные вероятностные распределения и пр. вероятностные характеристики выборки.

1.1.2 Обучение без учителя

При *обучении без учителя* классификация производится без использования какой-либо информации о принадлежности объектов классам. При

этом на стадии обучения необходимо обнаружить какие-либо закономерности в данных, поданных на вход алгоритма, которые позволили бы принимать верное решение при классификации новых входных данных.

Рассмотрим пример подхода, реализующего обучение без учителя, для решения следующей задачи классификации текстов.

Задача 3. Имеется некоторый набор текстов научных статей на тематики, принадлежащие различным научным областям. При этом соответствие этих текстов областям не задано. Необходимо разбить множество имеющихся текстов на подмножества текстов, принадлежащих одним и тем же научным областям, не используя никакой дополнительной информации об этих текстах. В частности, неизвестен сам набор областей, к которым принадлежат тексты.

Опишем один из возможных подходов к решению этой задачи.

Этап 1. Производим предварительную обработку текстов статей, удаляя из них слова, не несущие информации, которая может быть использована для классификации — предлоги, союзы и пр. Назовём оставшиеся слова *терминами*. Исключаем из терминов окончания, суффиксы и приставки, отбрасывание которых не приводит к потере информации, необходимой для отнесения терминов к научным областям.

Этап 2. Составляем *матрицу совместной встречаемости* терминов в имеющихся текстах. В ij-ой позиции матрицы совместной встречаемости указываем *совместную встречаемость* i-го и j-го термина: считаем, что термины совместно встречаются в текстах n раз, если они n раз встречаются на расстоянии не более чем D терминов друг от друга, где D — задаваемый параметр. На диагонали этой матрицы — нули.

Этап 3. Строим взвешенный неориентированный граф — *граф совместной встречаемости*, вершины которого соответствуют терминам. Матрицей смежности этого графа является матрица совместной встречаемости.

Этап 4. Построенный граф разбиваем на компоненты связности:

1). Задаём предполагаемое количество тематик m, как либо оцениваемое, исходя из имеющихся текстов или выбирая это значение, ис-

ходя из оценивания результатов повторного применения рассматриваемого подхода при разных значениях m. Например, этот параметр может быть оценён как количество наиболее удалённых в графе совместной встречаемости вершин, соответствующих терминам T_i $(i=\overline{1,m})$ с наибольшей частотой встречаемости.

2). Разбиваем граф на компоненты связности, используя, например, следующий алгоритм: рассматривая пары терминов $\{T_i, T_j\}$, последовательно удаляем в каждой из соединяющих их цепей рёбра наименьшего веса среди весов рёбер из этих цепей. Количество *тематик текстов*, задающих разбиение терминов по научным областям, считаем равным количеству компонент связности. Считаем термины, оказавшиеся в одной и той же компоненте связности, принадлежащими одной тематике.

Этап 5. Классифицируем имеющиеся тексты научных статей, исходя из частот встречаемости в них терминов из полученных тематик.

На этапах 2–4 приведённого подхода производится кластеризация терминов — разделение всех терминов на непересекающиеся подмножества терминов, предположительно принадлежащих разным научным областям. В целом, под *кластеризацией данных* понимают процедуру, позволяющую при наличии некоторого множества объектов задать правила, с помощью которых можно относить объекты к различным классам, понимаемым как группы объектов близких друг к другу относительно некоторого критерия близости. Эти группы выявляются в заданном множестве объектов в ходе кластеризации.

Кроме того, нами будут рассмотрены задачи и методы *генеративного моделирования*, под которым понимается автоматическое распознавание закономерностей и зависимостей во входных данных. Генеративное моделирование представляет собой разновидность машинного обучения без учителя. В его ходе решаются специфические задачи, которые не сводятся к рассмотренным выше задачам регрессии и классификации.

Примером таких задач могут служить задачи *нормализации входа*, для решения которых требуется преобразовать входные данные в соответствии с заданными требованиями. Это может быть например преобразование масштабирования изображения, сохраняющее его качество, стилизация изображения или видео- и аудио-данных. Такие преобразования могут быть охарактеризованы как приведение входных данных к

некой заданной *нормализованной форме*. Кроме того, такие генеративные модели, как, например, автоэнкодер, могут служить для генерирование новых данных, которых не было в исходной выборке, но которые непротиворечиво могли бы в ней быть.

Обучение с учителем и обучение без учителя могут комбинироваться друг с другом, если имеются как объекты, о принадлежности которых к заданным классам известно, так и объекты, относительно которых такой информации нет.

1.2 Вектор признаков

При решении задачи распознавания образов необходимо определить вектор признаков, который характеризует объект. Везде далее будем считать, что характеризующий объект набор признаков задаётся как вектор $x \in \mathbb{R}^m$ — *вектор признаков* . При этом m, то есть количество отобранных признаков объекта, должно быть достаточным для решения задачи. Важно, чтобы различные признаки несли в себе различную информацию и были статистически независимы. При этом признаки объектов не всегда могут быть интерпретированы в интуитивно понятных терминах.

Важной задачей при отборе признаков объекта является уменьшение размерности получаемого вектора признаков, поскольку набор признаков должен быть эффективно вычислимым, то есть вычислимым за некоторое «разумное» время при заданных ограничениях на использование машинной памяти.

Рассмотрим следующий пример задачи 1, сформулированной выше. Пусть дано изображение размером 28×28 пикселей, представленных в виде вектора признаков

$$x = (x_1, \ldots, x_{784}) \in \mathbb{R}^{784}.$$

В качестве решения такой задачи необходимо представить *классификатор* — алгоритм, который, получая на вход вектор признаков x, идентифицировал бы по нему цифру и выдавал бы её в качестве результата. Примеры возможных входных изображений приведены на рис. 1.1.

Затрудняющее распознавание преобразование, являющееся причиной ошибок в данных, называют *зашумлением* (или «шумом»). Зашумление

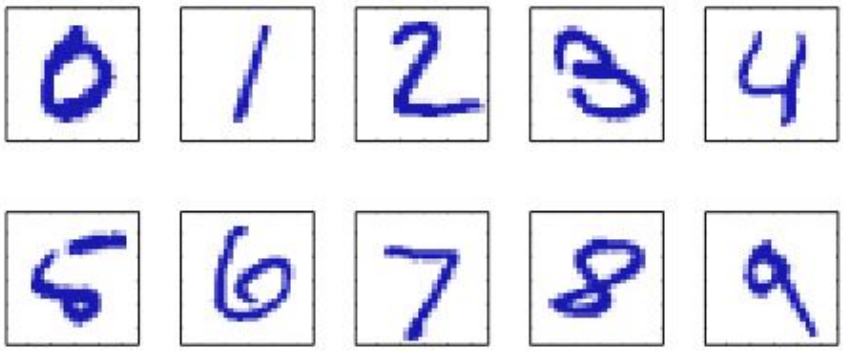


Рис. 1.1: Рукописные символы.

может быть вызвано случайными факторами, связанными с регистрацией числовых значений признаков. Это могут быть факторы, искажающие истинные значения признаков, например, колебания интенсивности освещения при получении изображений распознаваемых объектов, колебания температурных характеритик окружающей среды, влияющих на процесс измерения, случайная порча информации о распознаваемых объектах.

В рассматриваемом примере, изображения цифр, представляемых матрицей пикселов или, что эквивалентно, векторами пикселов, получаемых конкатенацией строк матриц пикселов, как правило, при регистрации оказываются зашумленными. Например, при решении задачи автоматического распознавания автомобильных номеров в качестве зашумления может выступать порча или загрязнение цифр или букв, считываемых с номера с помощью какого-либо регистрирующего их устройства.

Другими примерами зашумления изображений букв и цифр являются такие их искажений, как поворот, неравномерное искажение частей изображений, изменения фона, на котором изображёна буква или цифра и тому подобные преобразования. Задача распознавания в этом случае становится вычислительно неразрешимой при достаточно большом количестве используемых изображений для одной и той же буквы и достаточно большого количества искажающих изображение буквы преобразований. Труднорешаемость этой задачи часто обеспечивает надёжность отказа в доступе вредоносному программному обеспечению к ресурсам в сети Интернет.

Вариантом подхода к решению такой задачи распознавания могло бы

быть использование некоторых эвристик (правил), которые позволяли бы различать рукописные цифры, основываясь на форме составляющих их штрихов, линий. Однако, как правило, на практике это приводит к разрастанию количества правил и исключений для них, что не позволяет эффективно решать задачу.

Гораздо лучшие результаты даёт в этом случае машинное обучение. При таком подходе предполагается, что задана выборка рукописных символов достаточно большой мощности. Эта выборка используется для подбора параметров адаптивной, то есть «подстраивающейся» под выборку модели, используемой для описания распознаваемых объектов. Результатом работы алгоритма машинного обучения, который реализует такую адаптацию, является функция $y(x)$, определённая на входном векторе признаков x. В наиболее общем виде такой алгоритм может быть описан следующим образом.

В случае распознавания рукописных цифр обучающая выборка представляет собой набор пар вида $\{(x^{(i)}, y^{(i)})\}_{i=1}^{N}$, которая включает в себя векторы пикселов изображений цифр $x^{(i)}$ и сами соответствующие им цифры — *(метки классов)* $y^{(i)}$, где $y^{(i)} \in \{0, 1, 2, 3, \ldots, 8, 9\}$.

Проклятие размерности. При большой размерности вектора признаков начинает играть роль так называемое проклятие размерности, которое влечёт необходимость хранения слишком большого количества данных и резко возрастающую сложность вычислений. Кроме того, для любой пары объектов из обучающей выборки расстояние между ними с ростом размерности будет стремится к одному и тому же значению. В результате вектор признаков может не содержать информации, пригодной для решения задачи распознавания. В этой связи для многомерных данных часто необходимо уметь уменьшать размерность задачи, то есть выделять из множества всех признаков признаки, критически важные для решения задачи. В качестве таких подходов далее нами будет рассмотрен метод главных компонент и подход, реализуемый автоэнкодером, который может считаться его обобщением.

Проблемы возникающие в связи с проклятием размерности рассматриваются в данном учебном пособии и иллюстрируются на примерах в разделе «Метод ближайшего соседа», однако присущи они всем методам решения задач распознавания образов при больших размерностях

векторов признаков.

Данные, подаваемые на вход алгоритма распознавания, могут быть подвергнуты предобработке, в результате которой они преобразуются так, чтобы задача решалась проще. Например, изображения рукописных символов, на основе которых производится обучение при решении задачи распознавания рукописного текста, преобразуются перед стадией обучения. В частности, каждое изображение масштабируется, в результате чего изображения букв представляются матрицами пикселов, что эквивалентно заданию векторов признаков одного размера. Это существенно упрощает распознавание. Распознаваемое изображение также подвергатся такой предобработке.

1.3 Ошибка обобщения. Недообучение и переобучение.

Цель обучения — получить такую модель, то есть функцию $\tilde{f}$, что с её помощью можно предсказывать значения функции f из рассмотренной выше постановки задачи 1 для значений x, не содержащиехся в используемых при обучении выборках. Главная задача при выборе и обучении модели — получить модель с большой *обобщающей силой*, или, что эквивалентно, меньшей *ошибкой обобщения (англ. out-of-sample-error)*, т.е. позволяющей предсказывать значения восстанавливаемой функциональной зависимости (при регрессии или классификации) для векторов признаков, не содержащихся в обучающей выборке.

Модель может иметь параметры, определяемые в ходе обучения, и *гиперпараметры* — параметры модели, задавамые перед её обучением и в ходе обучения не меняющиеся.

Недообучение (underfitting) имеет место, если после обучения модель $\tilde{f}$ не позволяет правильно определять значение $\tilde{f}(x)$ для данных, используемых при обучении. То есть для большей части пар $(x^{(i)}, y^{(i)})$ из обучающей и тестовой выборок $\tilde{f}(x^{(i)})$ сильно отличается от соответствующих значений $y^{(i)}$ для задачи регрессии, или $\tilde{f}(x^{(i)}) \neq y^{(i)}$ для задачи классификации. Недообучение может быть вызвано следующими причинами:

а) обучающая выборка выборка слишком мала;

б) выборка содержит данные с большими ошибками, так называемые «выбросы» (мы обсудим эту ситуацию позже);
в) выбранная модель слишком проста для того, чтобы зафиксировать закономерности в данных.

Говорят, что имеет место *переобучения (overfitting)*, если модель позволяет правильно определять значение $\tilde{f}(x)$ для данных, используемых при обучении, но непригодна для других данных. Это могут быть данные валидационной или тестовой выбоки. Так, например, для рассматриваемой далее задачи классификации рукописных цифр разнообразие возможных входных векторов x, представляюих изображения распознаваемых рукописных цифр столь велико, что обучающая и тестовая выборка могут составлять только малую долю всех возможных входных векторов, кодирующих изображения цифр. Они могут, например, быть изображениями, полученными для относительно небольшой группы людей. Но именно эти написания цифр и практически только их с помощью полученного классификатора, то есть с помощью функции $\tilde{f}$, можно распознавать правильно. В случае задачи регрессии переобучение означает небольшую ошибку на данных, используемых для обучения, и большую — для остальных.

1.4 Регистрация информации и ошибки в данных

Практическая реализация метода распознавания образов предполагает реализацию *машинного восприятия* — преобразования света, звука, температуры и др. в электрические или какие-либо иные сигналы. Задача распознавания решается тем легче, чем проще может быть закодирован распознаваемый сигнал, то есть чем меньшей оказывается размерность вектора признаков, представляющего сигнал. Примерами реализации машинного восприятия могут служить процессы считывания информации с магнитных носителей, перфокарт, реализации машинного зрения и др.

С решением задач распознавания образов связаны в том числе задачи декодирования записей физических процессов и классификация физических явлений, которые могут быть не связаны напрямую с восприятием через органы чувств человека. При этом предполагается, что распозна-

ваемые объекты существуют независимо от воспринимающего и распознающего (классфицирующего) субъекта, и что, решая поставленную задачу, субъект никак не может повлиять на распознаваемый объект и его характеристики.

Решение задач распознавания образов с помощью машинного восприятия может большую вычислительную сложность, как по времени, так и по памяти. Даже при наличии алгоритма распознавания его практическая реализация может оказаться невозможной. Кроме того, сами процессы распознавания человеком, которые можно пытаться моделировать при решении задачи, как правило, трудно формализуемы. Затруднения, связанные с анализом восприятия человеком и его моделированием, вызваны тем, что большинство процессов восприятия распознвемых объектов человеком происходят неосознанно.

Таким образом, автоматизация процессов анализа и интерпретации образов, алгоритмы для реализации которой дают математические методы распознавания образов, трудна в связи с тем, что

а) как правило, стадия обучения требует обработки большого объёма информации, полученной при машинном восприятии, что требует значительных вычислительных затрат;
б) сами процессы регистрации человеком образов, как правило, сложны и плохо формализуемы, а возможно, и неизвестны.

Даже если мы имеем дело с ситуацией, в которой нам удалось при регистрации характеристик объекта избавиться от всех видов зашумления, измерительные приборы, с помощью которых производится регистрация числовых значений признаков объектов, могут давать эти значения с ошибками $\varepsilon^{(i)}$ из постановки задачи 1, случайными или систематическими. Причём в случае случайных ошибок их вероятностное распределение может быть неизвестно. Для оценки значения признака используются зафиксированные в ходе повторяющихся измерений его среднее значение, медианное значение, среднеквадратическое отклонение и др. Обычно предполагается, что значение признака представляет собой некоторую случайную величину, распределение которой известно. Так, например, при практическом использовании измерительных инструментов, примерно в 60% случаев распределение абсолютной величины ошибки является нормальным [1, 2].

Однако, на практике часто бывает сложно сделать выводы о том, как

распределена наблюдаемая случайная величина, которой является ошибка измерений. Прежде всего, причиной этого может являться нехватка экспериментальных данных, то есть небольшая мощность обучающей выборки. В этом случае, выборка оказывается недостаточной для того, чтобы делать по ней предположения о вероятностном распределении случайной ошибки.

Несмотря на это, во многих случаях можно предполагать наличие заданного вероятностного распределения ошибки.

2 Элементы теории вероятностей

Ключевым понятием для математических методов распознавания образов является понятие неопределённости. Неопределённость может быть вызвана как непредсказуемыми по своей величине ошибками измерений значений признаков, характеризующих распознаваемый объект, так и тем, что данные, исходя из которых производится распознавание, конечны и их объём зачастую может не давать полной и однозначной информации, достаточной для решения задач распознавания и классификации.

Теория вероятностей позволяет работать с неопределёнными числовыми значениями и является одним из основных инструментов при решении задач распознавания образов. Так, предполагается то или иное распределение ошибок измерений (как правило, нормальное), с которыми получены данные выборок. А в рассматриваемой далее теории решений использование методов теории вероятностей и, в частности, формулы (теоремы) Байеса играет основополагающую роль и позволяет использовать данную нам вероятностную информацию для оценивания вероятностей ошибок, сделанных при классификации, и потерь, к которым ведут эти ошибки.

Этот раздел указывает на те базовые элементы теории вероятностей и математической статистики, знание которых необходимо для понимания материала, излагаемого в учебном пособии. В разделе даются способы генерирования значений случайной величины с распределением, близким к нормальному. Приводится пример использования формулы Байеса, являющейся основой для *байесовских методов* классификации, для решения задачи распознавания спама.

2.1 Случайная величина

Под *случайной величиной* понимается переменная, значения которой представляют собой исходы некоторого эксперимента. Под таким экспериментом может пониматься измерение значения некоторого признака.

Случайная величина может быть дискретной или непрерывной. В случае *дискретной* случайной величины множество принимаемых ей значений дискретно, то есть состоит из изолированных друг от друга значений. Количество возможных значений, принимаемых дискретной случайной величиной может быть как конечным, так и бесконечным, но не более чем счётным. Распределение дискретной случайной величины задаётся вероятностями принятия ей возможных значений.

Непрерывная случайная величина принимает значения из некоторого интервала, конечного или бесконечного. Количество возможных значения для непрерывной случайно величины бесконечно. Распределение непрерывной случайной величины задаётся функцией распределения или функцией плотности распределения.

Определения используемых нами понятий теории вероятностей даются, например, в [3, 4]. Будем использовать следующие обозначения:

- $\mathsf{P}(A)$ обозначает вероятность какого-либо события A;
- $\mathsf{p}(x)$ — значение функции плотности вероятностного распределения случайной величины в точке x;
- $\mathsf{F}(x)$ — значение функции распределения случайной величины в точке x;
- $\mathsf{M}(\xi)$ и $\mathsf{D}(\xi)$ — среднее значение случайной величины и её дисперсия, $\sigma(\xi)$ — средеквадратичное отклонение.

2.2 Вероятностные распределения

Рассмотрим вероятностные распределения, которые будут использоваться нами далее. Наиболее часто нами будут использоваться равномерное и нормальное распределения. Кроме того, для моделирования нормального шума для задач классификации используется распределение Бернулли и биномиальное распределение.

Равномерное распределение. Наименьшее количество информации о возможном значении случайной величины ξ в ходе эксперимента имеется в случае её *равномерного распределения* (дискретного или непрерывного). В этом случае равновероятны p все значения из заданного (возможно, дискретного) интервала возможных значений ξ.

Функция равномерного распределения случайной величины задаётся как

$$\mathsf{F}(x) = \begin{cases} 0, & x < a; \\ \dfrac{x-a}{b-a}, & a \le x \le b; \\ 1, & x \ge b. \end{cases}$$

Функция плотности непрерывного равномерного распределения на отрезке $[a, b]$ имеет вид

$$\mathsf{p}(x) = \frac{1}{b-a}.$$

$\mathsf{p}(x)=0$ для $x \notin [a, b]$. Для непрерывного равномерного распределения

$$\mathsf{M}(\xi) = \frac{a+b}{2},\ \mathsf{D}(\xi) = \frac{(b-a)^2}{12}.$$

Распределение Бернулли и биномиальное распределение. Пусть случайная величина ξ дискретна и принимает значения 0 и 1 со следующими вероятностями $\mathsf{P}(x=1)=\mu$ и $\mathsf{P}(x=0)=1-\mu$, $\mu \in [0, 1]$. *Распределение Бернулли* задаётся как

$$\mathrm{Bern}(x) = \mu^x (1-\mu)^{1-x},$$

и имеет следующие математическое ожидание и дисперсию:

$$\mathsf{M}(\xi) = \mu,\ \mathsf{D}(\xi) = \mu(1-\mu).$$

μ — параметр распределения Бернулли.

Пусть имеется множество $\{x^{(1)}, \ldots, x^{(N)}\}$ наблюдаемых в ходе эксперимента значений ξ, распределённой в соответствии с распределением Бернулли с параметром μ. Распределение в этом множестве количества значений $x^{(i)}$ равных 1 называется *биномиальным распределением* и задаётся вероятностями

$$\mathrm{Bin}(m) = \frac{N!}{m!(N-m)!}\,\mu^m (1-\mu)^{N-m}.$$

Поскольку $m = x^{(1)} + \ldots + x^{(N)}$, математическое ожидание и дисперсия биномиального распределения следующие:

$$\mathsf{M}(m) = N\mu,\ \mathsf{D}(m) = N\mu(1-\mu).$$

Рассматриваемое далее нормальное распределение является предельным случаем биномиального распределения при $N \to \infty$.

Нормальное распределение. В случае нормального распределения случайной величины ξ, полученные в ходе экспериментов её значения будут сконцентрированы в относительно небольшой области около среднего значения

$$\mu = \mathsf{M}(\xi),\ \mathsf{D}(\xi) = \sigma^2,$$

где μ и σ — параметры, задающие распределение. По известному «правилу трёх сигм», с вероятностью близкой к 0.997 значение нормально распределённой случайной величины лежит в интервале $(\mu - 3\sigma, \mu + 3\sigma)$, где $\sigma = \sigma(\xi)$ — среднеквадратическое отклонение (рис. 2.1.).

Функция распределения нормально распределённой случайно величины — это функция Лапласа, значение которой может быть вычислено приближённо с помощью численного интегрирования или используя её протабулированные значения:

$$\mathsf{F}(x) = \frac{1}{\sqrt{2\pi}\sigma} \int\limits_{-\infty}^{x} \exp\left(-\frac{(t-\mu)^2}{2\sigma^2}\right) dt. \tag{1}$$

Плотность вероятности *нормально распределённой* случайной величины ξ задаётся как

$$\mathsf{p}(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right). \tag{2}$$

Значение функции плотности $\mathsf{p}(x)$ в x тем больше, чем более вероятно, что случайная величина принимает значение x или близкие ему значения.

Если случайная величина ξ имеет нормальное распределение, задаваемое (1) и (2), то это обозначается как $\xi \sim \mathcal{N}(\mu, \sigma^2)$. *Стандартное нормальное распределение* — это нормальное распределение с параметрами $\mu = 0$ и $\sigma = 1$.

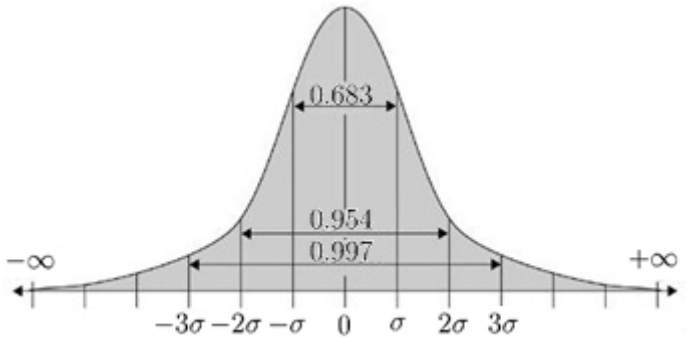


Рис. 2.1: Плотность вероятности для нормально распределённой случайной величины.

Многомерное нормальное распределение. *Ковариационной матрицей* для m-мерного случайного вектора ξ называется матрица $\Sigma=(\sigma_{ij})$, где

$$\sigma_{ij}=\mathsf{M}\big((\xi_i-\mu_i)(\xi_j-\mu_j)\big).$$

σ_{ii} — дисперсия ξ_i. Если ξ_i и ξ_j независимы, то $\sigma_{ij}=0$.

Нормальная плотность распределения значений для $\xi=(\xi_1,\ldots,\xi_m)$ задаётся формулой

$$\mathsf{p}(x)=\frac{1}{(2\pi)^{m/2}\det(\Sigma)^{1/2}}\exp\left(-\frac{1}{2}(x-\mu)^{\top}\Sigma^{-1}(x-\mu)\right), \qquad (3)$$

где $\mu=(\mu_1,\ldots,\mu_m)$ — вектор средних значений: $\mu_i=\mathsf{M}\xi_i$, $\Sigma=(\sigma_{ij})$ — ковариационная матрица.

Если случайная величина $\xi=(\xi_1,\ldots,\xi_m)$ имеет плотность распределения, заданную (3), это обозначается как $\xi\sim\mathcal{N}(\mu,\Sigma)$.

Таким образом, многомерное нормальное распределение полностью задаётся своими $m+m(m+1)/2$ параметрами: m-мерным вектором μ средних значений случайных компонент и $m(m+1)/2$ различными элементами ковариационной матрицы Σ. В случае взаимной независимости случайных компонент Σ — диагональная матрица: $\Sigma=\mathrm{diag}(\sigma_{11},\ldots,\sigma_{mm})$.

2.3 Центральная предельная теорема

Под *систематическими* понимаются ошибки, являющиеся неслучайными и имеющие определенную направленность. Примером систематической ошибки измерений является смещение стрелки ненагруженных весов относительно нулевой отметки на некоторую постоянную величину. Зная это смещение, можно, всякий раз производя с помощью таких весов измерения массы, вычитать его из их показаний. Как правило, систематические ошибки могут быть устранены или учтены с достаточной точностью.

Ошибки в данных, оставшиеся после устранения систематических ошибок, могут возникать из большого количества источников малых ошибок. При определённых условиях, распределение суммы большого количества малых независимых случайных величин с ростом этого количества стремится к нормальному распределению, что утверждается центральными предельными теоремами. Из чего следует, что в ситуации, когда ошибки измерений являются результатом действия большого числа малых независимых факторов, мы можем с достаточной уверенностью полагать, что итоговая ошибка распределена нормально. Для таких случаев центральные предельные теоремы обосновывают использование нормального распределения.

Под *центральными предельными теоремами* понимаются теоремы, утверждающие, что сумма достаточно большого количества независимых или слабо зависимых случайных величин, примерно равных друг другу, имеет распределение, близкое к нормальному. Так как в прикладных задачах многие случайные величины формируются под влиянием нескольких независимых или слабо зависимых случайных факторов, то их распределение часто можно считать нормальным. При этом ни один из факторов не должен быть доминирующим.

Под классической формулировкой центральной предельной теоремы (*ЦПТ*) понимается следующая.

Теорема. *Пусть* $\xi_1, \ldots, \xi_n, \ldots$ *— бесконечная последовательность независимых одинаково распределённых случайных величин, имеющих конечное математическое ожидание* μ *и дисперсию* σ^2*. Пусть*

$$S_n = \sum_{i=1}^{n} \xi_i.$$

Тогда случайная величина

$$\frac{S_n - \mu n}{\sigma\sqrt{n}}$$

при $n \to \infty$ *сходится по распределению к случайной величине с распределением* $\mathcal{N}(0, 1)$*.*

Варианты центральной предельной теоремы отличаются друг от друга в ограничениях на распределение суммируемых случайных величин ξ_i.

2.4 Генерирование нормально распределённой случайной величины

Генерирование случайных величин с заданными распределениями требуется для моделирования прикладных процессов, количественные характеристики которых описываются как случайные величины с такими распределениями.

Рассмотрим два способа генерирования случайной величины, распределённой нормально, что понадобится нам при выполнении заданий, связанных с задачами регрессионного анализа.

В случае нормально распределённой ошибки предполагается, что полученное в ходе измерения значение признака x представляет собой зафиксированное значение случайной величины ξ вида

$$x = x_0 + \varepsilon,$$

где $x_0 \in \mathbb{R}$ — истинное значение величины измеряемого признака, а ε — *ошибка измерений*. Значение ε — это значение случайной величины,

распределённой нормально. Как правило, после устраннения систематических ошибок измерений полагается, что $\mathsf{M}(\varepsilon) = 0$.

2.4.1 Табличный способ

Верно следующее утверждение:

Утверждение 1. *Пусть случайная величина ξ распределена равномерно на отрезке $[0, 1]$, а $F(x)$ — некоторая функция распределения. Тогда случайная величина $F^{-1}(\xi)$ распределена в соответствии с F.*

Таким образом, генерируя значения x равномерно распределённой случайной величины ξ и имея протабулированную функцию F некоторого распределения, или имея машинную реализацию функции F^{-1} обратной к ней, можно генерировать значения y случайной величины η с любым, в том числе, нормальным законом распределения.

2.4.2 Способ, использующий ЦПТ

Пусть необходимо сгенерировать случайную величину ξ с распределением $\mathcal{N}(\mu, \sigma^2)$, и пусть χ_i — значения случайной величины, получаемой с помощью какого-либо генератора случайных чисел, моделирующего равномерное распределение на интервале $[0, 1]$.

Будем считать, что количество n случайных слагаемых, достаточных для получения значения случайной величины с распределением близким к $\mathcal{N}(0, 1)$, равно 12. Значение случайной величины ξ, распределение которой близко к распределению $\mathcal{N}(\mu, \sigma^2)$, может быть сгенерировано следующим алгоритмом.

Алгоритм генерирования значения случайной величины с распределением, близким к $\mathcal{N}(\mu, \sigma^2)$

1). Вычисляем значение случайной величины

$$S_n = \sum_{i=1}^{n} \chi_i.$$

2). Имея при $n=12$ $\mathsf{M}(S_n) = n/2 = 6$, $\sigma^2(S_n) = n/12 = 1$, вычисляем значение случайной величины

$$\eta = \frac{S_n - \dfrac{n}{2}}{\sqrt{\dfrac{n}{12}}}.$$

При $n=12$ имеем $\eta = S_n - 6$. Случайная величина η имеет распределение близкое к $\mathcal{N}(0,1)$.

3). Значения случайной величины ξ с распределением $\mathcal{N}(\mu, \sigma^2)$ получаются из значений случайной величины η: $\xi = \mu + \sigma\eta$.

Для обоснования рассмотренных подходов к генерированию значений случайной величины с нормальным распределением, выполните упражнения 1, 2 и 3 из раздела **Задания** к этому разделу.

2.5 Формула Байеса и её применение в методах решения задач распознавания образов

2.5.1 Формула Байеса

Формула Байеса позволяет определить вероятность некоторого события при условии, что произошло другое связанное с ним событие. Имея вероятности реализаций предпосылок некоторого события и используя формулу Байеса, мы можем получить новое значение вероятности реализаций этих предпосылок при условии, что событие произошло.

Предположим, что на множестве $\mathcal{W} = \{W_1, \ldots, W_n\}$ событий, являющихся возможными предпосылками события X, заданы вероятности событий $\mathsf{P}(W_1)$, ... , $\mathsf{P}(W_n)$. Эти вероятности событий из $\mathcal{W}$ называются *априорными*, то есть рассчитанными до наступления события X. Будем считать, что в определённый момент времени происходит только одно из событий W_i, то есть реализуется только одна из предпосылок события X.

Пусть, кроме того, заданы условные вероятности наступления события X при реализации каждой из предпосылок, то есть заданы вероятности события X в том случае, если происходит одно из этих событий — вероятности $\mathsf{P}(X|W_1), \ldots, \mathsf{P}(X|W_n)$. Обозначим как $\mathsf{P}(W_i|X)$ *апостериорную*, то есть рассчитанную после того, как событие X произошло, вероятность наступления события-предпосылки W_i.

По формуле Байеса

$$\mathsf{P}(W_i|X) = \frac{\mathsf{P}(X|W_i)\mathsf{P}(W_i)}{\mathsf{P}(X)}, \tag{4}$$

где $\mathsf{P}(X)$ рассчитывается по *формуле полной вероятности*:

$$\mathsf{P}(X) = \mathsf{P}(X|W_1)\mathsf{P}(W_1) + \ldots + \mathsf{P}(X|W_n)\mathsf{P}(W_n).$$

В рассматриваемых далее задачах классификации формула Байеса позволяет максимизировать вероятность принятия верного выбора решения относительно реализовавшегося события-предпосылки W_i, исходя из наблюдаемых значений вектора признаков x. Считается, что вероятность события после регистрации вектора x составляет

$$\mathsf{P}(W_i|x) = \frac{\mathsf{p}(x|W_i)\mathsf{P}(W_i)}{\mathsf{p}(x)}. \tag{5}$$

Для дискретного распределения на множестве событий-предпосылок W_i и непрерывных условных плотностей распределения $\mathsf{p}(x|W_i)$ имеем:

$$\mathsf{p}(x) = \mathsf{p}(x|W_1)\mathsf{P}(W_1) + \mathsf{p}(x|W_2)\mathsf{P}(W_2).$$

Заметим, что благодаря наличию знаменателей $\mathsf{P}(X)$ в (4) и $\mathsf{p}(x)$ в (5) сумма апостериорных вероятностей событий-предпосылок равна 1. (Выполните задание 8 из раздела **Задания** к данному разделу).

Функция плотности условного распределения $\mathsf{p}(x|W_i)$ называется *функцией правдоподобия*. Такое название призвано подчеркнуть, что событие W_i тем более вероятно при наблюдаемых значениях x, чем больше значение $\mathsf{p}(x|W_i)$. Аналогично могут быть рассмотрены случаи, когда x принимает значения из дискретного множества, и когда задана непрерывная функция плотности $\mathsf{p}(w)$.

2.5.2 Байесовский классификатор для распознавания спама

В качестве примера использования формулы Байеса для решения задач распознавания образов, рассмотрим *наивный байесовский классификатор для распознавания спама*. Под *спамом* понимаются рекламные сообщения, рассылаемые в большом количестве большому количеству абонентов услуг электронной почты.

Задача. Почтовому клиенту пользователя, либо самому серверу необходимо отфильтровывать спам при загрузке пользователем сообщений электронной почты с сервера, определяя является ли каждое отдельное сообщение спамом или нет.

При построении байесовского классификатора спама используется обучающая выборка из сообщений электронной почты, относительно которых известно, являются ли они спамом или нет. Для того, чтобы оценки вероятностей вхождения заданного слова в сообщение, которое является спамом, были оценены верно, такая обучающая выборка должна быть достаточно большой.

При построении наивных байесовских классификаторов «наивно» предполагается, что признаки, исходя из которых классифицируется объект, являются независимыми. Это позволяет вычислять вероятности, используя правило умножения вероятностей, справедливое для независимых событий. Часто такое предположение не является оправданным. Так, например, полагая в качестве событий вхождение или отсутствие вхождения различных слов в сообщение, утверждать, что эти события независимы, нельзя. Тем не менее, при решении многих прикладных задач классификации с помощью наивных байесовских классификаторов, при построении которых такое предположение делается, могут быть получены хорошие результаты. Это верно и для байесовского классификатора спама, который используется практически всеми популярными спам-фильтрами.

Пусть слова из набора всех слов $\mathcal{W}$ из сообщений обучающей выборки пронумерованы, то есть $\mathcal{W} = \{W_1, \ldots, W_m\}$. Пусть $\mathsf{P}(S)$, $\mathsf{P}(\bar{S})$ — априорные вероятности того, является ли сообщением спамом или нет. Большинство программ, реализующих байесовский классификатор, используют априорные значения $\mathsf{P}(S) = \mathsf{P}(\bar{S}) = 1/2$. Для слов из $\mathcal{W}$ известны

вероятности $\mathsf{P}(W|S)$ того, что слово W окажется в сообщении, являющемся спамом. Это значение рассчитывается как частота появления в обучающей выборке сообщений, являющихся спамом и содержащих слово W, среди всех сообщений, являющихся спамом и содержащих слова из $\mathcal{W}$. Аналогичным образом рассчитывается вероятность $\mathsf{P}(W|\bar{S})$ того, что слово W окажется в сообщении, не являющемся спамом. Расчёт этих вероятностей производится вручную как частота встречаемости слова в сообщениях-спаме.

Значения этих вероятностей для слов, содержащихся в сообщении, используются для вычисления вероятности того, что сообщение является спамом. Если полученное значение вероятности превышает некоторое пороговое значение, то сообщение классифицируется как спам.

Теорема Байеса будет использоваться нами двумя способами:

а) для вычисления вероятности того, что сообщение — спам, исходя из вхождения в сообщение заданного слова;

б) для вычисления вероятности того, что сообщение — спам, исходя из вхождения в сообщение всех содержащихся в нём слов.

По формуле Байеса для вероятности $\mathsf{P}(S|W)$ того, что сообщение S, содержащее слово W, является спамом при условии вхождения него слова W, имеем:

$$\mathsf{P}(S|W) = \frac{\mathsf{P}(W|S)\mathsf{P}(S)}{\mathsf{P}(W|S)\mathsf{P}(S) + \mathsf{P}(W|\bar{S})\mathsf{P}(\bar{S})},$$

что при принятых нами зачениях априорных вероятностей эквивалентно

$$\mathsf{P}(S|W) = \frac{\mathsf{P}(W|S)}{\mathsf{P}(W|S) + \mathsf{P}(W|\bar{S})}. \tag{6}$$

Таким образом, используя (6), мы можем рассчитать вероятность того, является ли сообщение спамом, исходя из вхождения в него заданного слова.

С учётом вхождения в сообщение всех содержащихся в нём слов из $\mathcal{W}$, вероятность того, что сообщение является спамом по формуле Байеса составляет

$$\mathsf{P}(S|W_1, \ldots, W_n) = \frac{\mathsf{P}(W_1, \ldots, W_n|S)\mathsf{P}(S)}{\mathsf{P}(W_1, \ldots, W_n)}.$$

Полагая вхождение слов $W_1, \ldots, W_n$ в сообщение-спам независимым и применяя формулу полной вероятности, имеем

$$\frac{\mathsf{P}(W_1, \ldots, W_n|S)\mathsf{P}(S)}{\mathsf{P}(W_1, \ldots, W_n)} = \frac{\left(\prod_{i=1}^{n} \mathsf{P}(W_i|S)\right)\mathsf{P}(S)}{\mathsf{P}(W_1, \ldots, W_n)} =$$

$$= \frac{\left(\prod_{i=1}^{n} \frac{\mathsf{P}(S|W_i)\mathsf{P}(W_i)}{\mathsf{P}(S)}\right)\mathsf{P}(S)}{\mathsf{P}(W_1, \ldots, W_n)} = \frac{\left(\prod_{i=1}^{n} \frac{\mathsf{P}(S|W_i)\mathsf{P}(W_i)}{\mathsf{P}(S)}\right)\mathsf{P}(S)}{\left(\prod_{i=1}^{n} \mathsf{P}(W_i|S)\right)\mathsf{P}(S) + \left(\prod_{i=1}^{n} \mathsf{P}(W_i|\bar{S})\right)\mathsf{P}(\bar{S})} =$$

$$= \frac{\left(\prod_{i=1}^{n} \mathsf{P}(S|W_i)\mathsf{P}(W_i)\right)\mathsf{P}(S)^{1-n}}{\left(\prod_{i=1}^{n} \mathsf{P}(S|W_i)\mathsf{P}(W_i)\right)\mathsf{P}(S)^{1-n} + \left(\prod_{i=1}^{n} \mathsf{P}(\bar{S}|W_i)\mathsf{P}(W_i)\right)(1 - \mathsf{P}(S))/\mathsf{P}(S)^n}.$$

Так как мы полагаем $\mathsf{P}(S) = \mathsf{P}(\bar{S}) = 1/2$, то получаем

$$\mathsf{P}(S|W_1, \ldots, W_n) = \frac{\left(\prod_{i=1}^{n} \mathsf{P}(S|W_i)\mathsf{P}(W_i)\right)}{\left(\prod_{i=1}^{n} \mathsf{P}(S|W_i)\mathsf{P}(W_i)\right) + \left(\prod_{i=1}^{n} \mathsf{P}(\bar{S}|W_i)\mathsf{P}(W_i)\right)} =$$

$$= \frac{\prod_{i=1}^{n} \mathsf{P}(S|W_i)}{\prod_{i=1}^{n} \mathsf{P}(S|W_i) + \prod_{i=1}^{n} (1 - \mathsf{P}(S|W_i))},$$

где значения $\mathsf{P}(S|W_i)$ рассчитываются по (6).

Полученное значение вероятности $\mathsf{P}(S|W_1, \ldots, W_n)$ сравнивается с некоторым заданным пороговым значением. Если $\mathsf{P}(S|W_1, \ldots, W_n)$ превышает это пороговое значение, то сообщение классифицируется как спам.

2.6 Задания

1. Докажите утверждение 1.
2. Докажите, что распределённая нормально с параметрами μ и σ случайная величина η может быть получена из случайной величины $\xi \sim \mathcal{N}(0,1)$ по следующей формуле:

$$\eta = \mu + \sigma\xi.$$

3. Покажите, что для n независимых равномерно распределённых на $[0,1]$ случайных величин ξ_i и $S_n = \sum_{i=1}^{n} \xi_i$ имеем

$$\mathsf{M}S_n = \frac{1}{2}n, \quad \mathsf{D}S_n = \frac{1}{12}n.$$

4. Пусть для случайной величины ξ задана функция плотности $\mathsf{p}(x)$. Произведём замену координат: $x = g(t)$. Всегда ли будет для случайной величины ζ с функцией плотности $\mathsf{p}(t)$ выполняться $\mathsf{M}(\xi) = \mathsf{M}(\zeta)$? Будет ли верно, что $x_0 = g(t_0)$ для точек x_0 и t_0, в которых достигается максимум плотности распределения случайных величин ξ и ζ?
5. Пусть $\zeta = z(\xi)$, то есть ζ — случайная величина, полученная из случайной величины ξ, значение которой подвергнуто преобразованию z. Всегда ли будет выполняться равенство $M(\zeta) = z(M(\xi))$? Что можно сказать о соответствии медианных значений случайных величин ξ и ζ?
6. Покажите, что если все признаки взаимно независимы, то задаваемая (3) плотность $\mathsf{p}(x)$ равна произведению одномерных нормальных плотностей компонент x.
7. Покажите, что если признаки ξ_i и ξ_j независимы, то $\sigma_{ij} = 0$.
8. Докажите, что Σ — неотрицательно определённая матрица. В каком случае Σ не положительно определена?
9. Докажите формулу Байеса. Покажите, что сумма апостериорных вероятностей всех предпосылок, рассчитанных по ней, равна 1.

3 Метод ближайшего соседа

Рассматриваемые в этой главе подходы и понятия, такие как мера близости, выбросы, нормализация данных, проклятие размерности, смещение и дисперсия, которые будут введены нами в этой главе и рассмотрены на примере метода ближайшего соседа, относятся ко всем без исключения методам машинного обучения.

3.1 Постановка задачи

Предположим, что нам дан некоторый объект и заданы *соседние* к нему, то есть объекты относительно близкие по своим наблюдаемым свойствам к данному объекту и для которых нам известна их принадлежность к тому или иному классу из множества заданных классов. Необходимо классифицировать данный нам объект, исходя из имеющейся информации. Формально такая задача классификации ставится следующим образом.

Задача. Дан вектор признаков $x \in \mathbb{R}^m$ и дана обучающая выборка $\{(x^{(i)}, y^{(i)})\}_{i=1}^N$, $x^{(i)} \in \mathbb{R}^m$, — векторы признаков, $y^{(i)}$ — метки (номера) классов $\mathcal{C}_1, \ldots, \mathcal{C}_l$, которым принадлежат $x^{(i)}$, то есть $x^{(i)} \in \mathcal{C}_{y^{(i)}}$. Предполагается, что x принадлежит только одному из этих классов: существует s, $1 \leq s \leq l$, такой, что $x \in \mathcal{C}_s$. Необходимо определить s.

Для решения этой задачи классификации может быть использован *метод ближайшего соседа (kNN — k nearest neighbours)*. Предположим, что задана некоторая *мерой близости*, характериующая сходство векторов признаков. В результате применения этого метода для заданного параметра k классифицируемый вектор признаков x относится к тому же классу, что и k ближайших к нему векторов признаков из обучающей выборки.

3.2 Мера близости. Функция ошибки

Для решения задачи классификации или распознавания методом ближайшего соседа необходимо ввести *меру близости* — показатель сходства (или «близости») объектов, представляющий собой некоторым образом заданное расстояние между представляющими объекты векторами признаков. Векторы признаков считаются тем ближе друг к другу, чем меньше значения меры близости для них.

Пусть $x, y \in \mathbb{R}^m$ — векторы признаков, близость которых друг другу необходимо оценить. В качестве меры близости векторов x и y может выступить такая функция $\rho : \mathbb{R}^m \times \mathbb{R}^m \to \mathbb{R}_+$, для которой выполняются следующие условия:

1) $\rho(x, y) \geq 0$;
2) $\rho(x, y) = 0$ только если $x = y$;
3) $\rho(x, y) = \rho(y, x)$;

Мера близости — это функция ρ, сопоставляющее двум векторам из $\mathbb{R}^n$ неотрицательное значение, соответствующее их удалённости друг от друга. Чем ближе по своим наблюдаемым свойствам объекты, представляемые векторами признаков x и y, тем меньше значение $\rho(x, y)$.

Отметим, что, вообще говоря, не требуется чтобы функция ρ была расстоянием в обычном математическом смысле, поскольку не требуется выполнение неравенства треугольника.

Такая мера близости как *функции ошибки (error function)* является неотъемлемой частью любого подхода машинного обучения, позволяющей контролировать близость искомой функции $\tilde{f}$ из постановки задачи распознавания образов к неизвестной восстанавливаемой функции f. Функция ошибки, характеризующая близость функций $\tilde{f}$ и f на выборке $\{(x^{(i)}, y^{(i)})\}_{i=1}^N = \{(x^{(i)}, f(x^{(i)}))\}_{i=1}^N = \{X, Y\}$, где

$$X = \left(x^{(1)}, \ldots, x^{(N)}\right), \; Y = \left(f(x^{(1)}, \ldots, f(x^{(N)})\right)$$

может быть определена как $\rho(Y, \tilde{Y})$, где $\tilde{Y} = \left(\tilde{f}(x^{(1)}), \tilde{f}(x^{(2)}), \ldots, \tilde{f}(x^{(N)})\right)$.

В качестве меры близости векторов признаков может быть использовано, в частности, одно из расстояний между векторами в $\mathbb{R}^n$, рассмотренных ниже.

Выбор меры близости. Выбор используемой меры близости является важнейшим этапом решения задачи классификации методом ближайшего соседа и определяется спецификой задачи. Помимо расстояний, приведённых в списке ниже, в качестве мер близости могут быть применены расстояния, учитывающие такую специфику.

Для задания меры близости векторов признаков могут использоваться следующим образом определённые расстояния между векторами $x, y \in \mathbb{R}^m$.

а) Евклидово расстояние

$$\rho(x, y) = \sqrt{\sum_{i=1}^{m} (x_i - y_i)^2}.$$

При этом предполагается, что все признаки сходны по их физическому смыслу и измерены в одинаковых единицах, в противном случае признаки нормируют.

б) Квадрат евклидова расстояния

$$\rho(x, y) = \sum_{i=1}^{m} (x_i - y_i)^2.$$

Эта мера близости используется в тех случаях, когда неообходимо увеличить числовое значение меры близости для более отдалённых объектов.

в) Расстояние

$$\rho(x, y) = \sum_{i=1}^{m} |x_i - y_i|.$$

Для такой меры близости влияние отдельных больших разностей при суммировании уменьшается, так как они не возводятся в квадрат.

г) Взвешенное евклидово расстояние

$$\rho(x, y) = \sqrt{\sum_{i=1}^{m} w_i (x_i - y_i)^2}.$$

Используется в том случае, если можно задать *веса* w_i признаков в соответствии с их важностью для решения задачи классификации.

д) Расстояние Чебышёва

$$\rho(x, y) = \max_{1 \le i \le m} |x_i - y_i|.$$

Близость векторов оценивается по одному признаку, различия в котором для x и y максимальны.

Обобщая введённое понятие меры близости, можно сказать, что она определяет насколько близки математические представления объектов или каких-либо их отображений друг к другу. Помимо векторов признаков, мера близости может быть определена для функций, вероятностных распределения и др.

В качестве используемых нами в дальнейшем функций ошибки будут использоваться средние *абсолютная (MAE — mean absolute error)* и *квадратичная (MSE — mean squared error)* ошибки, получаемые из мер близости б) и в) усреднением по компонентам вектора, то есть домножением на $1/m$. Для оценивания близости вероятностных распределений нами будут использоваться определяемые в дальнейшем энтропия («логистическая функция ошибки»), кросс-энтропия и мера Кульбака-Лейблера.

3.3 Метод ближайшего соседа

Алгоритм, реализующий метод ближайшего соседа, следующий. Предположим, что задана мера близости ρ, наилучшим образом характеризующая сходство объектов, представляемых векторами признаков.

Вход: значение параметра k, вектор признаков $x \in \mathbb{R}^m$, обучающая выборка $\{(x^{(i)}, y^{(i)})\}_{i=1}^N$.

Шаг 1. Пусть $\rho_i = \rho(x, x^{(i)})$. Упорядочить множество $\{\rho_i\}_{i=1}^N$ по неубыванию:

$$\rho_{i_1} \le \rho_{i_2} \le \ldots \le \rho_{i_j} \le \ldots \le \rho_{i_k} \le \ldots \le \rho_{i_N}.$$

В соответствии с полученным порядком, упорядочиваем векторы $x^{(i)}$:

$$x^{(i_1)}, x^{(i_2)}, \ldots, x^{(i_j)}, \ldots, x^{(i_k)}, \ldots, x^{(i_N)}.$$

Шаг 2. Найти множество $\mathcal{N}_k$, состоящее из k *ближайших соседей* вектора x, то есть k первых в соответствии с произведённым упорядочиванием векторов $x^{(i)}$:

$$\mathcal{N}_k = \{x^{(i_j)} \mid j \leq k\}.$$

Шаг 3. Выбрать номер класса s такой, что в $\mathcal{N}_k$ содержится наибольшее количество элементов из этого класса.

Выход. $\mathcal{C}_s$ — класс, которому принадлежит x.

Метод парзеновского окна Для заданной меры близости ρ может быть сформулирован следующим подход к решению поставленной задачи: отнести x к тому классу $\mathcal{C}_j$, на представителе $x^{(p)}$ которого (то есть $x^{(p)} \in \mathcal{C}_j$), достигается минимум $\rho(x, x^{(p)})$ по всем элементам выборки, то есть

$$p = \arg \min_{1 \leq p \leq N} \rho(x, x^{(p)}).$$

В случае $k > 1$ выбирается такой класс $\mathcal{C}_j$, что на удаленнии от x не большем чем δ для заданного $\delta > 0$, принадлежащих классу $\mathcal{C}_j$ элементов обучающей выборки больше, чем для любого другого класса:

$$j = \arg \max_{1 \leq j \leq n} |\{x^{(i)} | (x^{(i)} \in \mathcal{C}_j) \text{ и } (\rho(x, x^{(i)}) < \delta)\}|.$$

В этом случае δ также является параметром метода.

Метод ближайшего соседа и метод парзеновского окна являются простейшими методами машинного обучения, в которых отсутствует стадия обучения, понимаемая как подбор параметров обучаемой модели. Если в методе ближайшего соседа мы фиксируем количество k соседних векторов признаков из выборки к заданному вектору, то в методе парзеновского окна мы задаём размер ячеек δ, на которые мы разбиваем всё множество $\mathbb{R}^m$, которому могут принадлежать векторы признаков для решаемой задачи. Исходя из того, векторов признаков какого класса оказывается больше в ячейке, в которую попадает заданный вектор, мы определяем его класс.

3.4 Выбор параметров метода ближайшего соседа

Особенностью метода ближайшего соседа является его чувствительность к локальной структуре данных, представляемых классифицируемым вектором признаков и векторами признаков из обучающей выборки. Поэтому при его применении важным является подбор параметров метода и использование дополнительных процедур, с помощью которых подчёркивается близость объектов по их наблюдаемым свойствам и лучше поддаётся количественному оцениванию с помощью выбранной меры близости.

Выбор значения параметров k и δ при $k>1$ при использовании метода ближайшего соседа зависит от решаемой задачи и обучающей выборки, которую мы имеем. Большие значения k и δ могут уменьшить влияние на результат случайных факторов, таких как ошибки измерений. Однако при этом могут возникать сложности, вызванные тем, что объекты разных классов могут быть ближе друг к другу, нежели объекты одного класса.

Одной из особенностей метода ближайшего соседа является то, что он может давать неверный результат, когда среди k ближайших к распознаваемому объекту преобладают объекты некоторого класса, при том, что ближайшими по своим свойствам к нему они могут и не быть. Такое преобладание может иметь место, когда элементы из одного класса в выборке оказываются существенно ближе к классифицируемому вектору, чем элементы выборки из другого класса или классов, но на расстоянии, не большем, чем δ от него, элементов другого класса оказывается больше не в силу их близости к нему, а в силу их многочисленности в выборке и завышенности значения δ.

В таких случаях могут быть использованы веса, назначаемые соседям так, что даже при относительно меньшем количестве более близкие объекты из обучающей выборки оказывают большее влияние на результат распознавания, нежели объекты более удалённые. Так, например, обычная схема назначения весов состоит в том, что каждому соседу назаначается вес равный $1/d$, где d — расстояние до него.

3.5 Распознавание растровых изображений с помощью метода ближайшего соседа

В качестве примера применения метода ближайшего соседа рассмотрим его применение к решению задачи распознавания растровых изображений.

Растровое изображение — это изображение, представляющее собой совокупность пикселов и задаваемое матрицей значений параметров пикселов в соответствующих позициях. Этими параметрами могут быть код цвета пиксела, яркость пиксела и др.

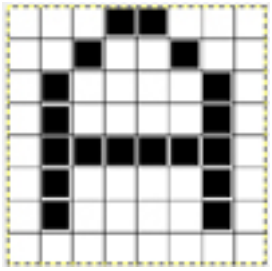


Рис. 3.1: Растровое изображение.

Такая задача может быть поставлена как задача 2 из главы 1. Множество эталонов в данном случае — это некоторый набор изображений (фиксированные изображения букв, цифр, штрих-кодов и др), подвергнутых зашумлению. Под зашумлением в данном случае будем понимать изменение элемента матрицы в заданном интервале. Будем считать, что зашумление производится случайно и равномерно по элементам матриц. То есть изменение любого элемента матрицы в заданном интервале равновероятно. Само изменение значения элемента матрицы также является равномерно распредёленной на этом интервале величиной. При этом нами не рассматриваются преобразования смещения изображения, его поворота и другие искажения всего изображения или его части.

Рассмотрим эту задачу в матричной постановке.

Задача 2. Задано множество из N квадратных эталонных $n \times n$-матриц $\mathcal{A} = \{\mathcal{A}_1, \ldots, \mathcal{A}_N\}$. Дана $n \times n$-матрица $A = (a_{ij})$, полученная зашумлением одной из эталонных матриц — некоторой матрицы $\mathcal{A}_p = (a_{ij}^{(p)})$, $\mathcal{A}_p \in \mathcal{A}$.

Известно, что

$$a_{ij} \in [a_{ij}^{(p)} - \delta, a_{ij}^{(p)} + \delta]$$

для заданного значения $\delta > 0$. Необходимо определить, зашумлением какой из эталонных матриц получена матрица A, то есть определить $\mathcal{A}_p$.

Для *бинарного* изображения элементы матрицы принадлежат множеству $\{0, 1\}$, для изображения *в градациях серого цвета* — множеству $\{0, 1, 2, \ldots, 255\}$.

Используя метод ближайшего соседа и одну из приведённых выше мер близости векторов признаков, в качестве которых в данном случае выступают конкатенации строк матриц A_i, задача может быть решена минимизацией функции $\rho(i) = \rho(x, x^{(i)})$, где

$$x = A_1 || \ldots || A_n,$$

$$x^{(i)} = \mathcal{A}_{i1} || \ldots || \mathcal{A}_{in},$$

где A_j, $\mathcal{A}_j$ — j-е строки матриц.

В заданиях 1 и 2 из раздела **Задания** к этой главе, требуется реализовать метод ближайшего соседа решения задач распознавания бинарных изображений и распознавания изображений в градациях серого цвета.

К решению такой задачи может быть применён интервальный подход к распознаванию числовых матриц [8], в качестве которых могут быть рассмотрены матрицы значений параметров пикселов изображений. Как мера близости для матриц в [8] используется оценка объёма объединённого множества решений интервальной системы уравнений, полученной по этим матрицам. Объём (лебегова мера) объединённого множества решений интервальной системы линейных уравнений характеризует совокупный разброс отклонений значений элементов матрицы распознаваемого изображения от соответствующих элементов матрицы эталонного изображени

3.6 Метод ближайшего соседа как подход к оценке плотности случайной величины

Задачи регрессии и классификации могут быть рассмотрены как задачи оценивания распределения неизвестной случайной величины. Выборка вида $\{(x^{(i)}, y^{(i)})\}_{i=1}^{N}$ может быть рассмотрена как выборка $\{x^{(i)}\}_{i=1}^{N}$, где в качестве $x^{(i)}$ рассматриваются векторы $(x^{(i)}, y^{(i)})$. Значения $x^{(i)}$ для выборки $\{(x^{(i)}\}_{i=1}^{N}$ могут быть проинтерпретированы как значения случайной величины x, определенной на некоторой области $\mathcal{D}$, которой принадлежат значения $x^{(i)}$. Имея конечное множество наблюдений (выборка) $\{(x^{(i)}, y^{(i)})\}_{i=1}^{N}$, необходимо смоделировать распределение y на $\mathcal{D}$. При этом предполагается, что значения в выборке получены независимо в соответствии с одним и тем же распределением.

Отметим, что, вообще говоря, такая задача принципиально является некорректно поставленной. Под *корректно поставленной задачей* понимается прикладная задача, математическое решение которой существует, единственно и устойчиво, то есть непрерывно зависит от данных в некоторой разумной топологии [5, 6]. *Некорректно поставленная задача* — задача, не обладающая каким-либо из свойств корректно поставленной задачи. Для задачи оценивания распределения решение принципиально не единственно, поскольку для заданной выборки существует бесконечное количество распределений, в соответствии с которыми она может быть получена. В качестве такого распределения может быть рассмотрено любое вероятностное распределение, задающее ненулевую случайную величину.

Методы оценивания плотнотсти вероятностного распределения могут быть разделены на два класса:

1. *Параметрические методы*, которые применяются тогда, когда известен вид распределения, но неизвестны его параметры, количество которых невелико. Оценивание плотности распределения в этом случае сводится к оцениванию значений параметров плотности распределения, в соответсвии с которым получена выборка. В дальнейшем мы неоднократно будем иметь дело с задачей оценивания параметров нормального распределения. Параметры распределения входят в число параметров таких методов.

2. *Непараметрические методы*, при использовании которых нет никакой информации о виде распределения, а есть только выборка, в соответствии с которым она получена. Параметры таких методов определяют особенности таких методов, их вычислительную сложность, но не саму форму распределения, его функцию плотности.

Параметрические методы оценивания распределения непригодны, если нет достаточных оснований предполагать наличие некоторого распределения, в соответствии с которым сформирована выборка. В частности, на практике распределение, как правило, является *мультимодальным*, то есть имеется несколько вероятностных распределений, совокупность которых задаёт случайную величину. А для *малых выборок*, то есть для таких, когда N много меньше размерности вектора признаков, оценивание по ним распределения принципиально не имеет смысла.

Предположим, что имеется выборка $\{x^{(i)}\}_{i=1}^{N}$, полученная в соответствии с некоторым неизвестным распределением с функцией плотности $\mathsf{p}(x)$, определённой на множестве возможных значений векторов признаков $\mathcal{D}$ в m-мерном пространстве. Пусть $\mathcal{R}$ — некоторая область малого объёма в $\mathcal{D}$. Вероятность попадания значения x в $\mathcal{R}$ определяется как

$$\mathsf{P} = \int\limits_{\mathcal{R}} \mathsf{p}(x)dx.$$

Вероятность попадания K случайных значений точек в $\mathcal{R}$ распределена в соответствии с биномиальным распределением:

$$\mathrm{Bin}(K|N,\mathsf{P}) = \frac{N!}{K!(N-K)!}\mathsf{P}^K(1-\mathsf{P})^{N-K}.$$

Для больших N большинство из них будет концентрироваться близко к средему значению $N\mathsf{P}$, поэтому

$$K \approx N\mathsf{P}. \tag{1}$$

Если область $\mathcal{R}$ достаточно мала, то значения плотности $\mathsf{p}(x)$ для $x \in \mathcal{R}$ будут примерно одинаковы и

$$\mathsf{P} \approx \mathsf{p}(x)V, \tag{2}$$

где V — объём $\mathcal{R}$. Из (1) и (2) получаем:

$$\mathsf{p}(x) \approx \frac{K}{NV}. \tag{3}$$

Отметим, что, с одной стороны, область $\mathcal{R}$ должна быть достаточно мала, чтобы $\mathsf{p}(x)$ можно было считать в ней примерно одинаковой. С другой стороны, она должна быть достаточо велика, чтобы количество K попадающих в неё точек было достаточным, чтобы значения случайной величины концентрировались около определённого для неё среднего значения.

Выражение (3) может быть использовано двумя способами:

1) можно зафиксировать K и определить V, исходя из имеющихся данных выборки, то есть использовать метод ближайшего соседа;
2) можно зафиксировать V и определить по данным выборки значение K, то есть использовать ядерное оценивание плотности (метод парзеновского окна).

В обоих случаях при $N \to \infty$ определяемая (3) функция $\mathsf{p}(x)$ будет стремиться к функции плотности, в соответствии с которой сформирована выборка, если с ростом N растёт и значение K [9].

3.6.1 Ядерное оценивание плотности распределения

Пусть $\mathcal{R}$ — гиперкуб малого объёма с центром в точке x, в которой оценивается плотность. Для оценивания значения K определим для $t \in \mathcal{D}$ *ядерную функцию (парзеновское окно)*:

$$\mathcal{K}(t) = \begin{cases} 1, & \text{если } |t_i| \le 1/2, i = \overline{1,m}; \\ 0, & \text{иначе,} \end{cases}$$

где t_i — i-я компонента $t \in \mathbb{R}^m$.

Пусть $I_h(x)$ — гиперкуб со стороной h и центром в x. Ядерная функция может быть рассчитана для x_n в произвольном x с заданным значением параметра h — *шириной окна*:

$$\mathcal{K}\left(\frac{x - x^{(i)}}{h}\right) = \begin{cases} 1, & \text{если } x^{(i)} \in I_h(x); \\ 0, & \text{иначе.} \end{cases}$$

Общее количество K точек, попадающих в этот гиперкуб, определяется как

$$K = \sum_{i=1}^{N} \mathcal{K}\left(\frac{x - x^{(i)}}{h}\right). \tag{4}$$

Подставляя (4) в (3), получаем

$$\mathsf{p}(x) = \frac{1}{N} \sum_{i=1}^{N} \frac{1}{h^m} \mathcal{K}\left(\frac{x - x^{(i)}}{h}\right), \tag{5}$$

так как $V = h^m$. (5) может быть интерпретировано как сумма по N гиперкубам с центрами в x_i.

Отметим, что при таком определении функции плотности на границах этих гиперкубов мы будем получать разрывы функции. Чтобы избежать этого может быть использована более гладкая модель ядерного оценивания. Как правило, такая модель получается с помощью гауссиана:

$$\mathsf{p}(x) = \frac{1}{N} \sum_{i=1}^{N} \frac{1}{(2\pi h^2)^{1/2}} \exp\left(-\frac{\|x - x^{(i)}\|^2}{2h^2}\right), \tag{6}$$

где h — стандартное отклонение компоненты случайного вектора для многомерного нормального распределения. Параметр h в этом случае может пониматься как параметр сглаживания, значение которого должно быть подобрано оптимальным образом, то есть так, чтобы получаемая модель наилучшим образом соответствовала данным выборки. То есть так, чтобы модель была достаточно общей и описывала как можно больше данных выборки с достаточной точностью, а с другой стороны, чтобы эта точность была достаточной для всех групп близко расположенных в $\mathcal{D}$ точек выборки. Далее мы более подробно рассмотрим этот вопрос в главе о компромиссе между смещением и дисперсией.

Вообще говоря, в качестве функции ядра в (4) может быть использована любая такая функция $K(t)$, что

$$\mathcal{K}(t) \geq 0,$$

$$\int_{\mathcal{D}} \mathcal{K}(t)dt = 1.$$

3.6.2 Метод ближайшего соседа

В методе ядерного оценивания фиксирование параметра h может препятствовать адекватному оцениванию плотности при использовании любой функции ядра: в областях с большой плотностью (эмпирической) данных мы будем получать слишком сильное сглаживание, что не позволит извлечь из данных структуру распределения, тогда как малое значение h будет приводить к слишком большим колебаниям получаемой функции, с помощью которой мы моделируем функцию плотности неизвестного нам распределения, там где плотность данных выборки мала. То есть в этом случае требуемой для адекватного оценвания значение h может сильно зависеть от области $\mathcal{R}$. Метод ближайшего соседа устраняет эту проблему. Применяя этот метод, вместо того, чтобы в (3) фиксировать V и определять k по данным выборки, будем, наоборот, фиксировать k и определять соответствующий этому значению объём V. Параметром сглаживания в этом случае является k.

Рассмотрим оценивание плотности вероятностного распределения в контексте решения задачи классификации.

Возмём сферу малого радиуса с центром точке x. Будем увеличивать её радиус до тех пор, пока в него не попадёт K точек выборки $\{(x^{(i)}\}_{i=1}^{N}$. Исходя из определения вероятности как интеграла по $\mathcal{D}$, такая модель не является моделью оценивания плотности вероятности, поскольку интеграл от получаемой функции, моделирующей функцию плотности, будет, вообще говоря, расходящимся на всём $\mathcal{D}$.

Пусть в выборке имеется N_i точек из класса C_i,

$$\sum_{i=1}^{c} N_i = n,$$

где c — количество классов. Для классификации x построим сферу, включающую в себя k ближайших точек выборки. Пусть V — объём такой сферы, содержащей k_i точек класса C_i. В этом случае (3) даёт оценку плотности для каждого класса, которая может быть определена как

$$\mathsf{p}(x|C_i) = \frac{k_i}{N_i V}. \tag{7}$$

Без учёта принадлежности классу плотность распределения элементов

выборки при таком подходе будет определена

$$\mathsf{p}(x) = \frac{k}{NV}. \tag{8}$$

Априорная вероятность попадания точки (вектора признаков) в класс C_i будет определена как

$$\mathsf{P}(C_i) = \frac{N_i}{N}. \tag{9}$$

Из (7)–(9) по формуле Байеса получаем:

$$\mathsf{P}(\mathcal{C}_i|x) = \frac{\mathsf{p}(x|C_i)\mathsf{P}(\mathcal{C}_i|x)}{\mathsf{p}(x)} = \frac{k_i}{k}. \tag{10}$$

Для минимизации вероятности неправильной классификации точке x назначается класс с наибольшим значением k_n/k.

В случае значения параметра $k=1$ метода ближайшего соседа частота ошибок для него не более чем вдвое превышает частоту ошибок для оптимального классификатора [10].

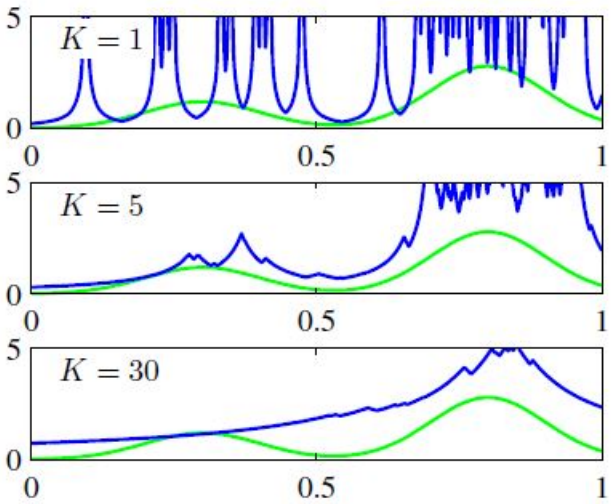
На рис. 2 показано сглаживание для метода ближайшего соседа при различных значениях k в случае данных выбоки, сформированных в соответсвии с бимодальным одномерным нормальным распределением. Очевидно, что оптимальным в этом случае является значение $k=5$.

Отметим, что поскольку для большой точности решения задач классификации и регрессии, как правило, требуются большие выборки, обе рассмотренные модели оценивания плотности имеют значительную вычислительную сложность как по памяти, так и по времени. Для уменьшения вычислительной сложности по времени могут быть использованы деревья поиска, которые строятся по данным выборки до запуска алгоритма, реализующего один из этих методов.

3.7 Регрессия с помощью метода ближайшего соседа и ядерная регрессия

До сих пор мы рассматривали метод ближайшего соседа для решения задачи классификации. В этом случае восстановливаемая функциональ-

Illustration of K-nearest-neighbour density estimation using the same data set as in Figures 2.25 and 2.24. We see that the parameter K governs the degree of smoothing, so that a small value of K leads to a very noisy density model (top panel), whereas a large value (bottom panel) smoothes out the bimodal nature of the true distribution (shown by the green curve) from which the data set was generated.



ная зависимость имеет дискретную область значений, представляющую собой метки классов, одному из которых принадлежит объект, представляемый вектором признаков. Этот метод также применим и для решения задачи регрессии, где восстанавливаемая по выборке функция непрерывна.

Применяя метод ближайшего соседа мы простейшим способом — как среднее арифметическое — оцениваем условное математическое ожидание случайной величины y, предполагая при этом наличие некоторого условного её распределения относительно x. Имея выборку $\{(x^{(i)}, y^{(i)})\}_{i=1}^{N}$, для вычисления значения y в точке x (в «точке запроса») находится среднее значение $y^{(i)}$ для ближайших соседей $x^{(i)}$ из выборки. Как и в случае классификации, при регрессии могут использоваться веса, применяемые при вычислении среднего. При этом назначаемые $y^{(i)}$ веса тем больше, чем ближе соответствующие $x^{(i)}$ к x, для которой определяется значение $y = f(x)$. Например, веса могут быть назначены обратно пропорционально расстоянию $\rho(x, x^{(i)})$.

На рис. N представлен результат регрессии методом ближайшего соседа. Выбор парметра k метода ближайшего соседа в случае регрессии определяет то, насколько гладкой (не в смысле непрерывности производной второго порядка для функции) является получемая по выборке кривая.

Для того, чтобы получать гладкую в математическом смысле функцию, может быть использована *ядерная регрессия*. В этом случае мы

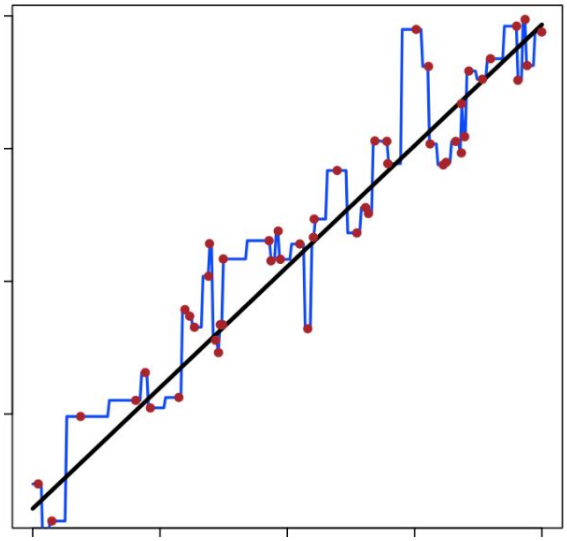


Рис. 3.2: Регрессия методом ближайшего соседа.

строим нелинейное отображение, используя некоторую ядерную функцию, устанавливая отношение между x и y, то есть находим функцию $y = \tilde{f}(x) = m(x)$, где m — функция, получаемая с помощью ядерной функции, усредняющая значения y_i с помощью ядерной функции, тем самым оценивая $\mathsf{M}(y|x)$.

В качестве функции $m(x)$ выбирается взвешенное среднее, где веса определяются с помощью ядерной функции [12, 13, 14]:

$$m(x) = \sum_{i=1}^{N} \frac{K(x - x^{(i)})}{\sum\limits_{i=1}^{N} K(x - x^{(i)})} y^{(i)}, \tag{11}$$

где $K(t)$ — ядерная функция с шириной окна h. В качестве K может быть выбран гауссиан (6).

На рис. 3.3 показаны примеры ядерной регрессии с гауссианами с разными параметрами для ширины окна $h = 0.1$ (синий график), $h = 0.3$ (зелёный), $h = 0.5$ (красный) и $h = 1$ (голубой). Элементы выборки отмечены синими кружками. Заметим, что максимальная близость получаемой функциональной зависимости к той, по которой получена выборка, не обязательно означает прохождения её графика через точки выбоорки.

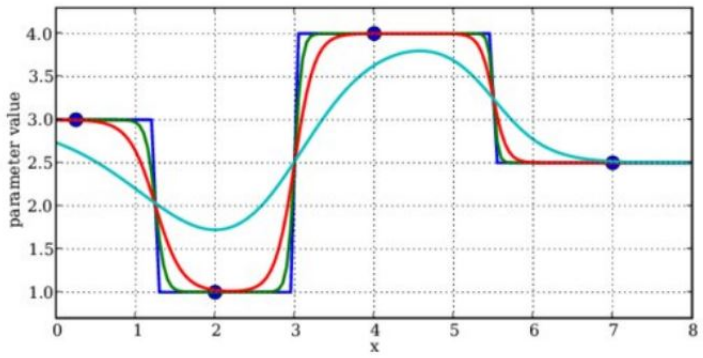


Рис. 3.3: Ядерная регрессия.

3.8 Прототипы и выбросы.

Часто для решения задач классификации методом ближайшего соседа требуется использовать не все имеющиеся в распоряжении данные, а только их часть. Для повышения качества и ускорения производимой с помощью метода ближайшего соседа классификации выделяются группы близких в соответстви с некоторой мерой близости векторов признаков. Каждая такая группа называется *кластером* и может быть заменена при классификации одним вектором признаков — прототипом. *Прототип* — это вектор признаков, который вляется репрезентативным для всех векторов признаков кластера. После замены кластеров прототипами распознавание производится не с учётом исходной обучающей выборки, а исходя из удалённости распознаваемого вектора признаков от полученных прототипов.

Выбросом назовём вектор признаков из обучающей выборки, который классифицируется неправильно с помощью метода ближайшего соседа, использующего для этого обучающую выборку, из которой исключён этот вектор. Определение выбросов — это одна из наиболее выжных задач, которые необходимо решать при работе с достаточно большими обучающими выборками. Отметим, что единого формального определения выброса нет. Вообще говоря, выбросом называется

То есть выброс — это элемент обучающей выборки, ближайшими к которому являются объекты, принадлежащие классам отличным от того, которому принадлежит сам элемент. Причинами появления выбросов могут быть:

а) случайные ошибки измерений компонент вектора признаков;
б) недостаточное количество элементов обучающей выборки, принадлежащей некоторому классу;
в) превалирование в обучающей выборке объектов некоторого класса;
г) отсутствие в векторах признаков компонент, соответствующих важным для проведения классификации признакам.

Выбросы, искажая картину явления, затрудняют работу с выборкой, в частности обучение и тестирование моделей машинного обучения. Прежде чем использовать выборку для обучения и тестирования, необходимо обнаружить выбросы в выборке и удалить их из неё. После исключения выбросов, в обучающей выборке могут быть выделены прототипы классов. В качестве прототипов для каждого класса выбираются такие элементы обучающей выборки, используя которые в качестве обучающей выборки, методом ближайшего соседа правильно классифицируются остальные элементы.

Рассмотренный нами метод ближайших соседей в том или ином виде применяется для идентификации выбросов во всех методах идентификации выбросов, и сам по себе является эффективным методом в сравнении с более сложными подходами [15].

Ещё одним широко используемым подходом является ODIN *(Outlier Detection using Indegree Number)* [16]. При таком подходе по выборке строится граф G *(kNN-граф)*, в котором вершины соотвествуют элементам выборки $\{x^{(i)}\}_{i=1}^{N}$. Вершины i и j, соответствующие элементам $x^{(i)}$ и $x^{(j)}$ соединяются ребром, если $\rho(i,j)$ принадлежит множеству k наименьших наименьших расстояний от i до k его ближайших соседей. Получаемый граф может быть рассмотрен как ориентированный, поскольку отношение принадлежности к множеству k ближайших соседей, вообще говоря, несимметрично, так и как неориентированный. Элемент выборки $x^{(i)}$ объявляется выбросом, если степень соответсвующей ему вершины i в графе G меньше некоторого заданного порогового значения. В случае ориентированного графа степень вершины определяется как количество входящих в вершину рёбер *(indegree number)*.

3.9 Нормализация

Значения различных компонент в векторе признаков могут иметь значительно отличающиеся один от другого интервалы возможных значений, что может приводить к тому, что на распознавание класса, к которому принадлежит объект, значения некоторых признаков будут оказывать необоснованно бóльшее влияние. Для того, чтобы избежать этого, может быть использована нормализация компонент вектора признаков. Одними из возможых способов нормализации являются минимаксная нормализация и Z-нормализация.

При применении *минимаксной нормализации* вектор признаков x с компонентами x_i заменяется на вектор признаков x' с компонентами x'_i по следующему правилу:

$$x'_i = \frac{x_i - \min\limits_i x_i}{\max\limits_i x_i - \min\limits_i x_i}, \tag{12}$$

где минимум берётся по всем компонентам x. В результате такого преобразования значения компонент вектора x' принадлежат интервалу $[0, 1]$.

В случае применения *Z-нормализации* вектор признаков x с компонентами x_i заменяется на вектор признаков x' с компонентами x'_i, вычисляемыми как

$$x'_i = \frac{x_i - \mathsf{M}_x}{\sigma_x}, \tag{13}$$

где M_x — среднее значение компонент вектора x, то есть

$$\mathsf{M}_x = \frac{1}{m}\sum_{i=1}^{m} x_i,$$

а σ_x — среднеквадратическое отклонение:

$$\sigma_x = \sqrt{\frac{1}{m}\sum_{i=1}^{m}(x_i - \mathsf{M}_x)^2}.$$

В этом случае большинство значений компонент полученного вектора x' будет содержаться в интервале $(-3\sigma, 3\sigma)$.

Замена x_i на $x_i - \mathsf{M}_x$ называется *центрированием*. Отметим, что часто вместо M_x при центрированиии и нормализации выгодней использовать медиану Me_x — значение компоненты вектора признаков, которое оказывается в середине упорядоченного по возрастанию множества всех компонент. В случае чётного количества компонент в качестве Me_x может быть выбрано любое из двух значений, оказывающихся при упорядочивании посередине, или их полусумма.

Применяется также центрирование и нормализация по отдельным признакам, то есть (12) и (13) вычисляются для множеств отдельно взятых компонент элементов выборки $\{x^{(i)}\}_{i=1}^{N}$.

В отличие от среднего арифметического, медиана является робастной статистической характеристикой, что означает, что она нечувствительна к выбросам. То есть если к множеству значений, для которых она рассчитывается, добавить слишком большое или слишком малое относительно содержащихся в ней значений, то медиана для полученного множества значений изменится мало, тогда как среднее арифметическое в этом случае будет меняться сильно.

Кроме того, использование среднего арифметическое оправданно, если значения множества, для которого оно вычисляется, распределены нормально или в соответствии с распределением близким к нормальному. Если же их распределение значительно отличается от нормального и не является симметричным, то использование среднего арифметического оправданным не является, и в качестве статистической оценки более подходит медиана.

3.10 Проклятие размерности

Размерность задачи распознавания образов — это размерность векторов признаков, представляющих классифицируемы объекты. Под *проклятием размерности* понимаются любые неудобные и необычные свойства многомерных пространств. Например, труднорешаемость задачи, то есть принадлежность её классу NP-трудных задач, и принципиальная невозможность её решить за время меньшее экспоненциального при условии $\mathrm{P} \neq \mathrm{NP}$ является проявлением проклятия размерности.

Проклятие размерности рассматривается нами в этом разделе на примере метода ближайшего соседа, однако оно свойственно всем без исклю-

чения рассматриваемым в нашей книге моделям.

Помимо указанных во введении причин, таких как трудноформализуемость и сложности при регистрации информации, трудность решения задач распознавания образов велика ещё и потому, что с ростом размерности задачи, что соответствует большей её реалистичности, для её решения может потребоваться экспоненциально растущая по своей мощности выборка. Либо при большой размерности вектора признаков эта выборка будет такова, что представленные в ней значения векторов признаков, полученные с помошью каким-либо образом проведённых измерений, заведомо не будут достаточно близки к истинным значениям векторов.

Пример 1. Рассмотрим задачу со следующей содержательной постановкой [7]. Имеется смесь нефти, воды и газа. Поток этой смеси при передаче под давлением по трубе может принимать три различные геометрические конфигурации в зависимости от процентного содержания в смеси её составляющих. В одном случае конфигурация представляет собой однородный поток — класс таких конфигураций обозначим $\mathcal{C}_1$, во втором и третьем — поток имеет либо кольцевую (класс $\mathcal{C}_2$), либо пластинчатую (класс $\mathcal{C}_3$) конфигурации, в которых смесь разбивается на слои определённой формы (рис. 3.4) в соответствии с плотностями составляющих.

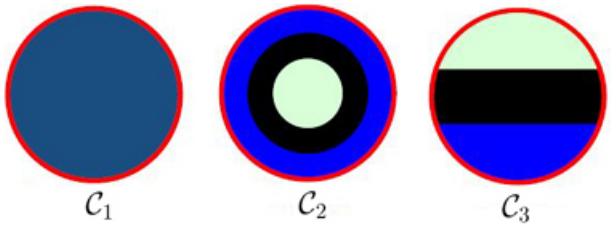


Рис. 3.4: Конфигурации потока смеси нефти, воды и газа.

Задача. Имеется вектор признаков $x \in \mathbb{R}^{12}$, состоящий из значений величин, полученных измерением угасания γ-лучей, направленных вдоль 12 направлений через поток, который нужно классифицировать относительно введённых классов конфигураций. Дана обучающая выборка $\{x^{(i)}, \mathcal{C}(x^{(i)})\}_{i=1}^{N}$, где значение $\mathcal{C}(x^{(i)})$ — это один из классов $\mathcal{C}_j$, $1 \leq j \leq 3$. Необходимо по вектору признаков x определить $\mathcal{C}(x)$, то есть класс конфигурации потока.

Аналитического метода решения этой задачи не разработано, тогда как на практике её требуется решать с целью организации безопасного режима передачи нефти по трубопроводам при их максимальной загрузке. Задача может быть решена с помощью метода ближайшего соседа, где, исходя из предположения о непрерывной зависимости типа потока (класса) от значений компонент вектора признаков для почти всех возможных значений вектора признаков. Тип потока выбирается по следущему правилу.

Алгоритм классификации конфигурации потока смеси

1. Разбить $\mathbb{R}^m$ на непересекающиеся ячейки одинакового размера.

2. Отнести x к тому классу $\mathcal{C}_j$, представителей которого больше в ячейке, которой принадлежит x.

Разбиение множества допустимых значений компонент вектора-признаков на одинаковые ячейки производится в результате разбиения интервалов их возможных значений на равные по длине непересекающиеся подинтервалы. Нетрудно показать, что по мере роста размерности задачи, количество элементов в выборке, достаточное для заполнения ячеек регулярной сетки с заданной плотностью и уверенного прогнозирования типа потока смеси, растёт экспоненциально. (Выполните задания 4 и 5 из раздела **Задания** этой главы.)

Этот пример показывает, что процедуры, которые могут быть вычислительно эффективны для задач малой размерности, не могут быть реализованы на практике уже для задач размерности, не превышающей нескольких десятков.

Пример 2. С ростом размерности задачи могут возникнуть сложности, интуитивно не всегда понятные, но влияющие на возможность применения методов распознавания образов, например, рассматриваемого нами в этой главе метода ближайшего соседа.

Предположим, мы имеем вектор признаков, компоненты которого являются результатами точных измерений. Можно также предположить, что если взять некоторую окрестность этого вектора, то элементы выборки, состоящей из результатов измерений, проведённых с ошибками, будут оказываться скорее ближе к точному значению вектора признаков, нежели к границам его окрестности, определяемой максимальной допустимой ошибкой измерений. Однако, если размерность вектора признаков достаточно велика, при фиксировании некоторой границы для ошибки измерений, элементы выборки неизбежно будут сосредоточены у границ задаваемой при этом окрестности истинного значения.

В самом деле, максимальная ошибка измерений по компонентам вектора признаков задаёт окрестность точного значения, в которую будут попадать результаты неточных измерений. Пусть ошибка по всем нормализованным компонентам вектора признаков одна и та же, и такая окрестность точного значения — это единичная сфера. Найдём долю объёма, содержащегося у границы сферы, между ней, и другой сферой с тем же центром и радиусом меньшим на ε. При равномерном распределении ошибки это означает, что элементы выборки измерений точного значения будут попадать в эту область с вероятностью, равной объёму этой области.

Пусть $V_n(r)$ — это объём n-мерной сферы радиуса r.

$$V_n(r) = K_n r^n,$$

где $K_n = const$ — константа, определяемая размерностью n. Рассчитываемая нами доля объёма составит

$$\frac{V_n(1) - V_n(1-\varepsilon)}{V_n(1)} = \frac{K_n - K_n(1-\varepsilon)^n}{K_n} = 1 - (1-\varepsilon)^n,$$

что уже для значений $n = 12$ и $\varepsilon = 0.2$ даёт более чем 0.93 от объёма сферы единичного радиуса.

То есть точки, соответствующие элементам даже больших экспериментальных выборок, как правило, находятся ближе к оболочке этих множеств, нежели к точному значению измеряемой многомерной величины. Поэтому с увеличением размерности вектора признаков получить точные совокупно по всем компонентам результаты измерений становится существенно сложнее, и даже довольно большая выборка может быть непригодной для решения задачи распознавания или классификации.

Для того, чтобы минимизировать проявления проклятия размерности, размерность вектора признаков должна быть как можно меньшей, при том что информации, представляемой им, должно быть достаточно для решения задач распознавания и классификации.

3.11 Метод главных компонент

Одним из основных способов снижения размерности задачи, то есть размерности векторов признаков, является *метод главных компонент* (в англоязычной литратуре *Principal Component Analysis, PCA*) . Будем рассматривать векторы признаков как векторы значений многомерной случайной величины $\xi = (\xi_1, \ldots, \xi_n)$. Будем считать, что для ξ задана ковариационная матрица $\Sigma = (\sigma_{ij})$. Идея метода главных компонент состоит в выделении из множества всех признаков такого их подмножества, которое включает наиболее некоррелированные признаки (главные компоненты вектора признаков), и отбросить те, которые являются от них зависимыми. В качестве меры зависимости признаков мы будем использовать их ковариацию. Напомним, однако, что случайные величины могут быть зависимы, имея при этом нулевую ковариацию.

Выделение главных компонент производится с помощью значений собственных значений и собственных векторов ковариационной матрицы. С помощью ортогонального преобразования, которое задаётся набором собственных векторов, мы производим переход к составленному из них базису. Это возможно, поскольку ковариационная матрица симметрична. После такого преобразования компоненты вектора признаков будут некоррелированы, то есть их ковариация будет равна нулю. После чего нами будут выбраны главные компоненты — такие компоненты пробразованного случайного вектора, дисперсия которых максимальна. Если дисперсия компоненты вектора признаков, рассматриваемого как значение многомерной случайной величины мала, то это означает, что в среднем изменение этого признака по выборке невелико, а значит он не содержит какой-либо важной информации для определения структуры вероятностного распределения, которому подчиняется выборка. После такого пробразования исходной выборки мы получим выборку векторов признаков меньшей размерности, компоненты которой некоррелированы.

Итак, нам дана выборка $\{x^{(i)}\}_{i=1}^{N}$, состоящая из N векторов $x^{(i)} \in \mathbb{R}^m$, где $x^{(i)}$ — результат i-го повторения эксперимента. $x_j^{(i)}$ — это значение j-го признака при i-м эксперименте. Если в исходной выборке компоненты вектора признаков коррелированы, то Σ — не диагональная матрица. Симметричная положительно-определённая матрица Σ может быть приведена к диагональной форме:

$$\Sigma' = V \Sigma V^\top,$$

где V — матрица, составленная из собственных векторов, Σ' — матрица с собственными значениями на диагонали. Производим следующие преобразования имеющихся эмпирических данных (данных выборки).

1. Центрировать значения компонент векторов $x^{(i)}$, $i = \overline{1, N}$.
2. Нормализовать значения компонент векторов.
3. Вычислить Σ для полученных данных.
4. Вычислить собственные значения Σ и собственные векторы — матрицу V.
5. Нормализовать собственные векторы Σ.

Преобразование $x' = V^\top x$ отображает векторы из исходного пространства признаков в пространство с базисом из собственных векторов с тем же количеством *некоррелированных* признаков.

Далее:

6. Производим уменьшение размерности задачи, вместо преобразования $x' = V^\top x$ производя преобразование $x' = V_M^\top x$, где M — количество главных компонент ($M < m$), то есть $x' \in \mathbb{R}^M$.

Значение M выбирается исходя из минимизаци *остаточной дисперсии (необъяснённой дисперсии)*, под которой понимается сумма дисперсий, то есть сумма собственных значений преобразованной ковариационной матрицы по отбрасываемым $M - m$ компонентам преобразованого вектора признаков, что эквивалентно максимизации *объяснённой дисперсии*, то есть суммы собственных значений, соответствующих выбранным главным направлениями.

Если считать, что собственные значения упорядочены по невозрастанию, то это означает, что мы выбираем такое M, например, что

$$\frac{\sum_{i=1}^{M} \sigma'_i}{\sum_{i=1}^{n} \sigma'_i} \geq 0.9,$$

имея при этом остаточную дисперсию не более 0.1.

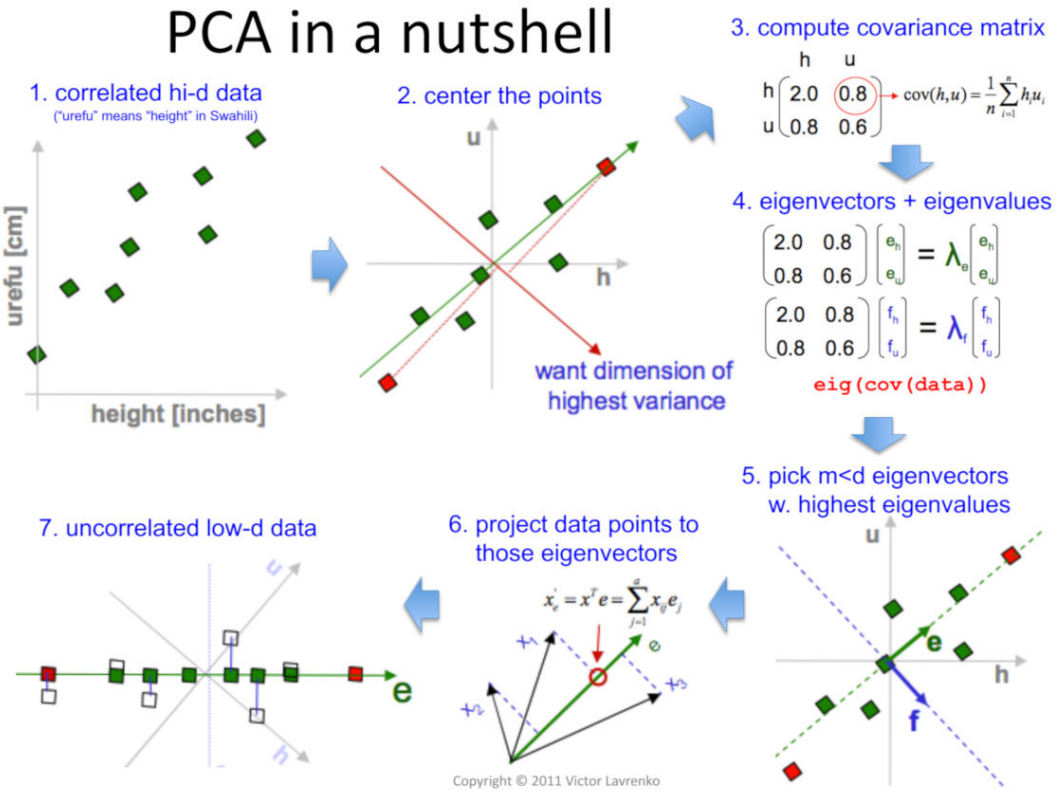
На рис. N проиллюстрировано применение метода главных компонент к двумерной выборке $\{(x_1^{(i)}, x_2^{(i)})\}_{i=1}^{7}$, где в векторе признаков x компонента x_1 соответствует длине, измеренной в единицах длины urefu народа суахили, а компонента x_2 соответствует длине, выраженной в дюймах. x_1 и x_2 выражают значение одного и того же физического параметра, измеренного с неизбежной ошибкой, поэтому зависимы. На рисунке показаны этапы применения к данным выборки метода главных компонент, в результате которого осуществляется переход от двумерных данных к одномерным.

3.12 Компромисс между смещением и дисперсией

3.12.1 Ошибки смещения и дисперсии

Предположим, мы в результате обучения мы получили некоторую модель. Возникает вопрос, какова обобщающая сила модели, то есть какова будет ошибка на данных, которых не было в выборке? Для ответа на этот вопрос используются следующие количественные характеристики — смещение, дисперсия и неустранимая ошибка модели.

Смещение модели (англ. bias) — ошибка, получаемая вследствие ошибочных предположений, используемых алгоритмом обучения. То есть смещение характеризует некоторую «предвзятость» при выборе модели. Это ошибка, которую классификатор будет иметь, независимо от того, сколько данных было использовано для обучения.



Дисперсия модели (разброс) (англ. variance) — ошибка, вызванная чувствительностью модели к малым изменениям данных обучающей выборки. При наличии большой дисперсии модели ей моделируются не взаимосвязи между признаками, извлекаемые из данных выборки, а скорее ошибки в данных. Дисперсия характеризует то, насколько отличаются результаты регрессии или классификации, получаемые с помощью обученной модели, от результатов, полученных при обучении по усреднённой, типичной выборке.

Как и проклятие размерности, правило, именуемое как *компромисс (дилемма) между смещением и дисперсией*, справедливость которого заметно ощутима эмпирически для всех без исключения моделей машинного обучения и которому мы дадим в этой главе теоретическое обоснование, может быть сформулировано следующим образом: уменьшая смещение модели, мы неизбежно увеличиваем её дисперсию, и наоборот, уменьшая дисперсию модели, мы неизбежно увеличиваем её смещение.

Неустранимая ошибка модели *(ошибка обобщения)* характеризует величину ошибки прогнозирования с помощью модели, то есть предска-

зания значения функции при регрессии или предсказания класса для входного вектора, при любых смещении и дисперсии модели. Неустранимая ошибка вызывается ошибкой измерений, которых нельзя избежать при получении выборки.

На рис. N приведёна графическая иллюстрация влияния смещения и дисперсии на точность прогнозирования с помощью модели в предположении, что точность прогнозирования с помощью модели характеризуется попаданием в центр мишени, задаваемой концентрическими окружностями.

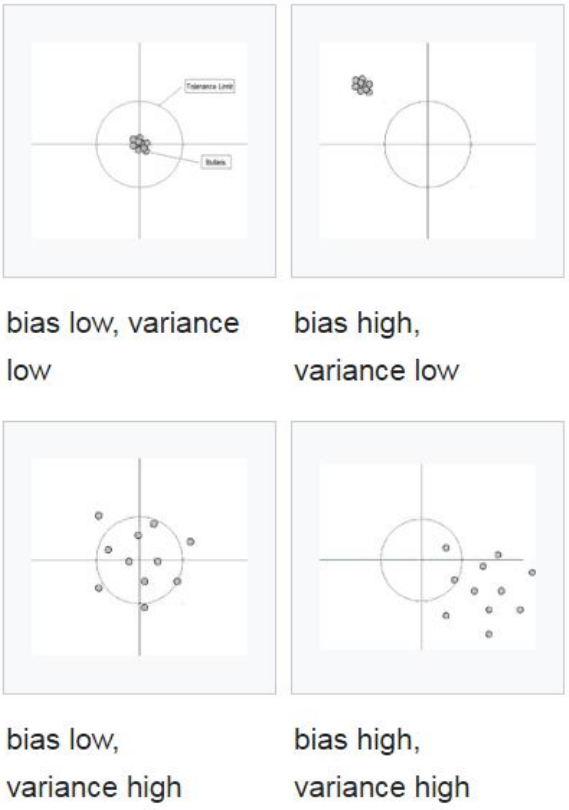


Рис. 3.5: Компромисс между смещением и дисперсией.

Рассмотрим следующий пример. Производится восстановление неизвестной функциональной зависимости по выборке (рис. N), где модель в первом случае выбирается как ломаная, соединяющая друг с другом ближайшие точки выборки, во втором приближение производится некоторым постоянным значением для всех значений аргумента, в третьем случае модель выбирается как некоторая гладкая функция, близкая к

восстанавливаемой функциональной зависимости.

В первом случае имеем переобучение, то есть построенная модель полностью соответствует данным выборки, однако, очевидно, что при варьировании данных и получении выборки, отличной от исходной, такая модель будет давать ошибку прогнозирования тем большую, чем больше будут отличаться значения элементов выборки от исходной. То есть модель будет иметь малое смещение и большую дисперсию.

Во втором случае, наблюдается недообучение, то есть модель плохо отражает зависимость между данными исходной выборки, но при рассмотрении разных выборок, мало отличающихся от исходной, ошибка прогнозирования, пусть и, возможно, большая, меняться не столь значительно.

В третьем случае наблюдается баланс между смещением и дисперсией: модель как хорошо описывает исходную выборку, так и ошибка прогнозирования для аргументов, находящихся достаточно близко к элементам исходной выборки, будет невелика. Можно сказать, что в этом случае достигнут компромисс между смещением и дисперсией.

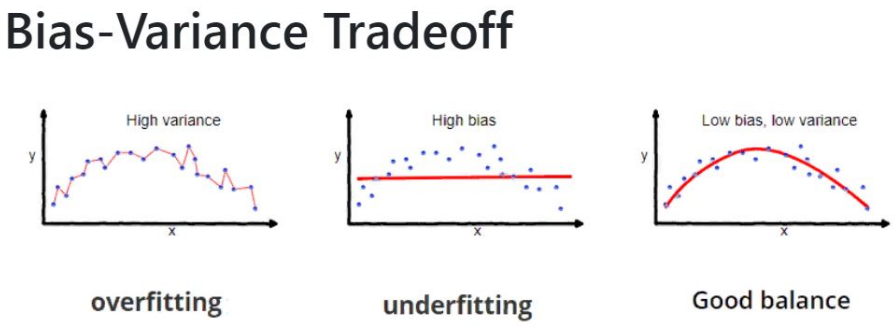


Рис. 3.6: Компромисс между смещением и дисперсией.

Резюмируя, можно сказать, что компромисс между смещением и дисперсией — это правило, которое описывает соотношение между

а) сложностью модели,

б) ошибкой на обучающей выборке,

в) ошибкой на неиспользуемых при обучении данных.

По мере увеличения количества настраиваемых в ходе обучения параметров модели (по мере увеличения сложности модели) модель становится более гибкой и лучше подстраивается под выборку, то есть имеет малое

смещение, но чем точнее модель подстраивается под конкретную выборку, тем больше будет её дисперсия. Обобщённо соотношение между смещением и дисперсией представлено на рис. N. Это соотношение отражает соотношение между недообучением и переобучением: более сложные модели с большим количеством параметров влечёт переобучение, тогда как выбор слишком простых моделей с малым количеством параметров приводит к недообучению.

Fig 1: Graphical illustration of bias and variance.
Source: http://scott.fortmann-roe.com/docs/BiasVariance.html

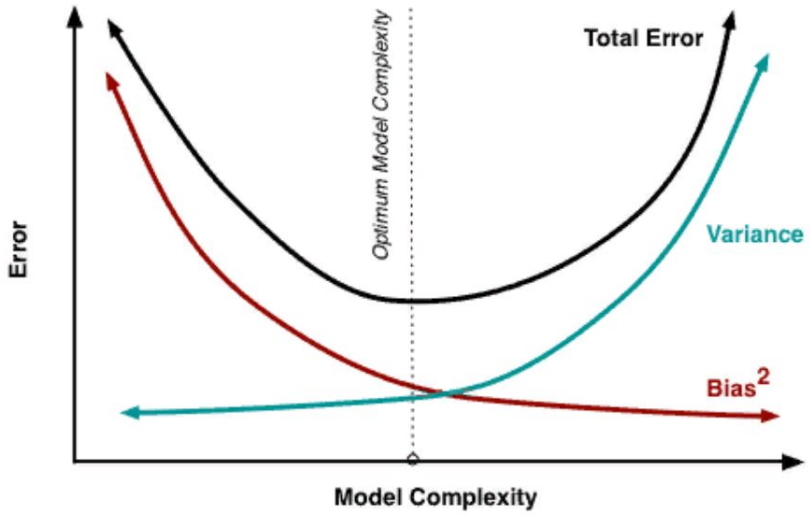


Fig 2: The variation of Bias and Variance with the model complexity. This is similar to the concept of overfitting and underfitting. More complex models overfit while the simplest models underfit.

Рис. 3.7: Компромисс между смещением и дисперсией.

Отметим, однако, что малое количество параметров модели не означает её малой дисперсии. Так для восстановления неизвестной функциональной зависимости выбрана модель вида $f(x, a, b) = a\sin(bx)$, имеющая всего два параметра a и b, то при достаточно большом значении b функция $f(x, a, b)$ может сколь угодно хорошо описывать сколь угодно большую выборку точек (x, y), где $x \in [-\pi/2, \pi/2]$, $y \in [0, 1]$. Однако модель имеет и большое смещение, и большую дисперсию.

3.12.2 Декомпозиция ошибки прогнозирования с помощью модели на ошибку смещения и дисперсии

Произведём декомпозицию ошибки прогнозирования с помощью модели может на долю ошибки, вызванную её смещением, десперсией, и неустранимую ошибку. Пусть значения функции для аргументов x получена как

$$y = f(x) + \varepsilon,$$

где ε — случайная величина, задающая ошибку при измерении значения y, соответствующего x, будем считать что системматическая составляющая ошибки равна нулю, то есть её математическое ожидание нулевое: $\mathsf{M}[\varepsilon] = 0$, а дисперсия составляет $\mathsf{D}[\varepsilon] = \sigma^2$. Пусть $\tilde{y} = \tilde{f}(x)$ — прогнозируемое с помощью модели $\tilde{f}$ восстанавливаемой функции f.

Средняя квадратичная ожидаемая ошибка прогнозирования раскладывается на сумму следующих слагаемых:

- ошибка, вызванная смещением модели:

$$\text{bias} = \mathsf{M}\big[\tilde{y} - y\big];$$

- ошибка, вызванная дисперсией модели:

$$\text{variance} = \mathsf{M}\big[(\mathsf{M}[\tilde{y}] - \tilde{y})^2\big];$$

- неустранимая ошибка прогнозирования: σ^2, то есть неустранимая ошибка, вызванная неточностью измерений.

Имеем:

$$MSE = \mathsf{M}\big[(\tilde{y} - y)^2\big] = \mathsf{M}\big[\tilde{y}^2 - 2\tilde{y}y + y^2\big] = \mathsf{M}\big[\tilde{y}^2\big] - 2\mathsf{M}\big[\tilde{y}y\big] + \mathsf{M}\big[y^2\big].$$

Поскольку

$$\mathsf{M}\big[\tilde{y}^2\big] = \mathsf{D}\big[\tilde{y}\big] + \big(\mathsf{M}\big[\tilde{y}\big]\big)^2,$$

а $y = f(x) + \varepsilon$, то

$$\mathsf{M}\big[y^2\big] = \mathsf{M}\big[(f(x) + \varepsilon)^2\big] = \mathsf{M}\big[f(x)^2\big] + 2\mathsf{M}\big[f(x)\varepsilon\big] + \mathsf{M}\big[\varepsilon^2\big] =$$

$$= \mathsf{M}\big[f(x)^2\big] + 2\mathsf{M}\big[f(x)\big]\mathsf{M}\big[\varepsilon\big] + \mathsf{M}\big[\varepsilon^2\big] = \mathsf{M}\big[f(x)^2\big] + \sigma^2.$$

Так как

$$\mathsf{M}\big[\tilde{y}y\big] = \mathsf{M}\big[\tilde{y}(f(x)+\varepsilon)\big] = f(x)\mathsf{M}\big[\tilde{y}\big],$$

то получаем:

$$\mathrm{MSE} = f(x)^2 + \sigma^2 - 2f(x)\mathsf{M}\big[\tilde{y}\big] + \mathsf{D}\big[\tilde{y}\big] + (\mathsf{M}\big[\tilde{y}\big])^2 =$$

$$= \big(\mathsf{M}\big[\tilde{y}-y\big]\big)^2 + \mathsf{D}\big[\tilde{y}\big] + \sigma^2 = \mathrm{bias}^2 + \mathrm{variance} + \sigma^2.$$

Таким образом,

$$MSE = \mathsf{M}[(y-\tilde{y})^2] = \mathrm{bias}^2 + \mathrm{variance} + \sigma^2$$

Для того, чтобы при неизвестной функциональной звисимости f оценить ошибку прогнозирования, оцениваем значения bias и variance по эмпирическим данным, то есть для разных выборок, полученных для прикладной задачи.

3.12.3 Достижение компромисса между смещением и дисперсией

На рис. 3.8 показаны графики MSE для обучающей и тестовой выборок при росте размера обучающей выборки и оптимальных значениях параметров модели. Можно выделить два режима функционирования модели. Первый режим — работа на выборке возрастающей мощности — характеризуется возрастанием ошибки на обучающей выборке и убыванием её на тестовой. То есть растёт смещение модели при убывании её дисперсии. При работе во втором режиме, то есть при работе с выборкой достаточной мощности — стабилизирующимися значениями этих ошибок. В дальнейшем увеличение выборки не приводит к существенному изменению разницы между ними при том, что ошибка оказыается достаточно близка к требуемому пороговому значению для неё, хотя и не становится меньше с ростом размера выборки, то есть достигается баланс между ошибками, вызванными смещением и дисперсией модели.

Рассмотрим способы, с помощью которых можно добиться уменьшения смещения и дисперсии.

Основные способы уменьшения смещения модели следующие:

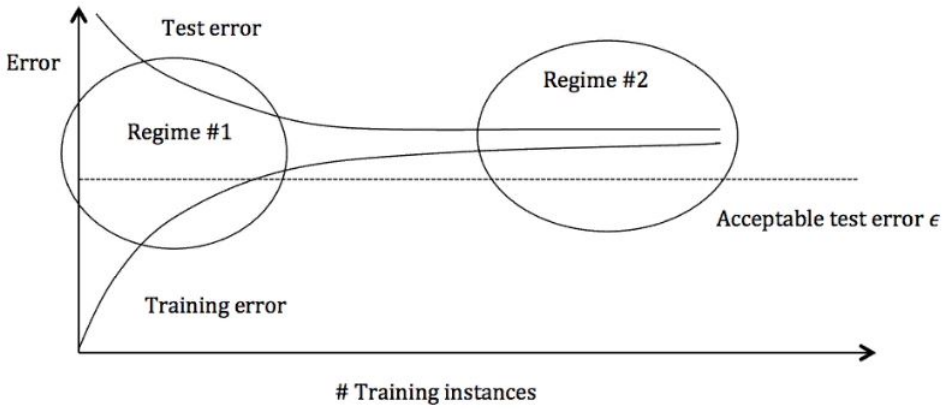


Рис. 3.8: Достижение компромисса между смещением и дисперсией.

1) добавление новых анализируемых признаков независимых от уже используемых позволяет поучать модель лучше соответствующую предметной области, для которой ставится задача;
2) усложнение модели может сделать её более гибкой, что позволяет восстанавливать более сложные функциональные зависимости, задаваемые на множестве векторов признаков;
3) использование *ансамблей*, то есть объединение моделей с большой ошибкой, вызванной смещением, то есть достаточно слабо отражающих соотношения между признаками векторов из выборки, в общую модель, то есть в совокупность моделей, которые вместе будут давать приемлемые результаты (см. далее бустинг).

Уменьшение дисперсии модели модели может быть получено за счёт

1) увеличение размера выборки,
2) уменьшение неоправданно завышенной сложности модели,
3) также за счёт использования ансамблей, в которые входят модели, обучающиеся на разных выборках (см. далее бэггинг, бустинг).

Рассмотрим соотношение смещения и дисперсии для изученного нами метода ближайших соседей (рис. 3.9). Влиять на них мы можем с помощью параметра k метода. При этом большие значения k ведут к большому смещению получаемой модели и её малой дисперсии, тогда как малые значения k — к малому смещению и большой дисперсии.

В качестве способа уменьшения дисперсии модели может использоваться её регуляризация. Регуляризация моделей машинного обучения

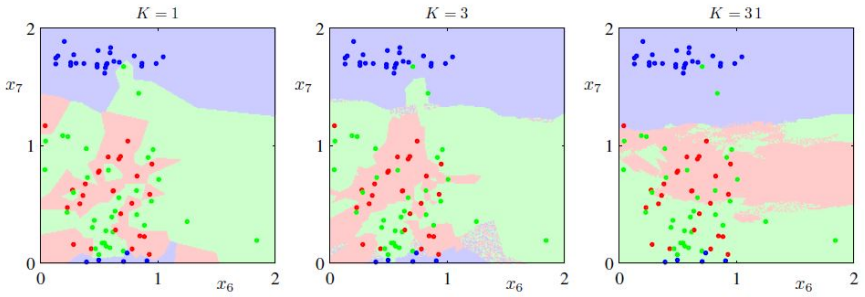


Figure 2.28 Plot of 200 data points from the oil data set showing values of x_6 plotted against x_7, where the red, green, and blue points correspond to the 'laminar', 'annular', and 'homogeneous' classes, respectively. Also shown are the classifications of the input space given by the K-nearest-neighbour algorithm for various values of K.

Рис. 3.9: Смещение и дисперсии для метода ближайшего соседа.

состоит в наложении ограничений на количества её парметров их значения. При этом дисперсия модели уменьшается, а смещение повышаеся. Конкретные примеры реализации регуляризации для различных моделей машинного обучения будут рассмотрены нами далее. На рис. 3.10 приведён пример регуляризации для полиномиальной регрессии. В этом случае мы накладываем ограничение на величину коэффициентов полинома, с помощью которого мы аппроксимируем неизвестную функцию. Такие виды используемой при этом регуляризации как гребневая регуляризация и лассо-регуляризация будут рассмотрены нами далее.

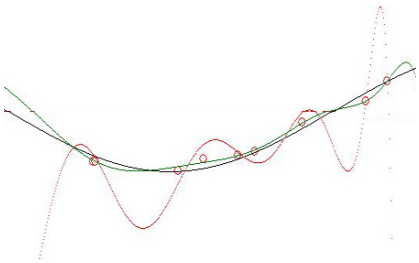


Рис. 3.10: Регуляризация для полиномиальной регресии.

3.13 Задания

1. По полученной с помощью метода ближайших соседей ломаной, изображённой на рис. 3.2, определите использованное значение па-

раметра k. Были ли при этом использованы веса? Приведите примеры функций, по которым при заданной величине ошибки измерений, может быть получена выборка, представленная на рисунке.

2. Пусть для прогнозирования типа потока в рассмотренной выше задаче требуется иметь M значений элементов выборки $x^{(i)} \in \mathbb{R}^{20}$ в каждой из ячеек, получаемых разбиением интервалов допустимых значений $[a_j, b_j]$ для каждой j-ой компоненты векторов признаков на n равных частей. Каков должен быть размер выборки N для решения задачи указанным способом? Каким будет N, если $x^{(i)} \in \mathbb{R}^{40}$?
3. Предположим, что нам необходимо оценить плотность равномерного распределения некоторой случайной величины в единичном гиперкубе в $\mathbb{R}^m$, основываясь на выборке из N элементов.
   а) Покажите, что почти все точки выборки находятся около границы m-мерного гиперкуба, используя для этого подход, применённый при рассмотрении m-мерной сферы.
   б) Найдите $l_m(p)$ — длину ребра гиперкуба в m-мерном пространстве, который содержит долю p точек от всех точек выборки $(0 \leq p \leq 1)$. Оцените $l_5(0.01)$, $l_5(0.1)$, $l_{20}(0.01)$, $l_{20}(0.1)$.
   в) Покажите, что почти все евклидовы расстояния между точками выборки являются достаточно большими и примерно одинаковыми в $\mathbb{R}^m$, и что их окрестности для того, чтобы содержать даже небольшое количество точек выборки, должны иметь большой радиус.
   г) Покажите, что расстояния Чебышёва между почти всеми точки выборки достаточно велики.
4. Напишите программу для распознавания растровых изображений, используя метод ближайшего соседа. Реализуйте программно равномерное и неравномерное зашумление изображений и сравните процент распознавания для используемых норм в случаях распознавания растровых бинарных изображений и изображений в градациях серого цвета для различных k. В качестве мер близости используйте предложенные выше и сравните результаты их применения.
5. Сгенерируйте обучающую выборку для решения задачи распознавания растровых изображений, содержащую выбросы *типа 0*. На-

зовём выбросы этого типа выбросами *типа 1*, если они не распознаются как выбросы с помощью метода ближайшего соседа, выбросами *типа 2* — выбросы типа 0, которые не распознаются с помощию метода ODIN. Реализуйте оба подхода к идентификации выбросов. Сравните результаты их работы.

4 Метод наименьших квадратов для решения задач регрессионного анализа

4.1 Задача регрессионного анализа и метод наименьших квадратов

Регрессионный анализ — это совокупность методов для решения задачи нахождения функциональной зависимости между зависимыми переменными и одной или несколькими независимыми переменными — *задачи регрессионного анализа* (или *задачи регрессии*).

Метод наименьших квадратов даёт один из подходов к решению задачи регрессионного анализа. Функция, которая является решением задачи восстановления функциональной зависимости, это функция, дающая минимум суммы квадратов отклонений её значений в точках, заданных выборкой, от значений, заднных выборкой для этих точек. Метод наименьших квадратов был независимо друг от друга предложен К. Ф. Гауссом (первое применение метода в 1795 г.) и А. М. Лежандром (публикация метода под современным названием 1805 г.). Он даёт асимптотически оптимальный способ оценивания параметров искомой функциональной зависимости заданного вида, когда ошибки измерений распределены нормально и имеют среднее значение, равное нулю [17].

Пусть дана выборка $\{x^{(i)}\}_{i=1}^{N}$. Будем предполагать, что значения $y^{(i)}$ получены с некоторой неизвестной для каждого измерения случайной ошибкой $\varepsilon^{(i)}$. Ошибка $\varepsilon^{(i)}$ может пониматься как ошибка точности измерительных приборов, с помощью которых получены значения $y^{(i)}$ для $x^{(i)}$. Задачу поставим следующим образом.

Задача 1. Дана выборка $\{x^{(i)}, y^{(i)}\}_{i=1}^{N}$, где $y^{(i)} = f(x^{(i)}) + \varepsilon^{(i)}$ для неизвестной функциональной зависимости f и некоторых малых значений $\varepsilon^{(i)}$. Необходимо найти функцию $\tilde{f}$, на которой достигается минимум значения функции $E(\tilde{f})$:

$$E(\tilde{f}) = \frac{1}{2}\sum_{i=1}^{N}\big(y^{(i)} - \tilde{f}(x^{(i)})\big)^2.$$

В качестве критерия, исходя из которого ищется решение $\tilde{f}$ задачи распознавания функциональной зависимости, в методе наименьших квадратов выступает достижение на $\tilde{f}$ минимума значения *функции ошибки* $E(\tilde{f})$, рассчитываемой по выборке.

Если известен вид зависимости, то есть $\tilde{f}(x) \equiv \tilde{f}(w, x)$, где набор параметров $w \in \mathbb{R}^M$ полностью определяет значение функции в каждой точке x, получаем

$$E(w) = \frac{1}{2}\sum_{i=1}^{N}\big(y^{(i)} - \tilde{f}(x^{(i)}, w)\big)^2. \tag{2}$$

То есть поставленная задача может быть сформулирована как задача нахождения такого набора параметров $\tilde{w}$, что

$$\tilde{w} = \arg\min_{w \in \mathbb{R}^M} E(w). \tag{3}$$

Решаемая нами задача принципиально отличается от задачи интерполяции функции наличием ошибки ε_i в данных выборки. Эта задача не состоит в получении функции, значения которой будут равны задаваемым выборкой. Задача состоит в нахождении зависимости наиболее адекватно моделирующей закономерности в данных, часть которых представлена выборкой.

4.2 Линейная регрессия

Рассмотрим пример применения такого подхода к решению задачи со следующей содержательной постановкой.



Рис. 4.1: Линейная регрессия методом наименьших квадратов

Задача 2. Необходимо измерить длину пути, представляемого ломаной на карте, несколько раз производя измерения линейкой на корабле во время качки. После N попыток измерения длины пути ввиду неизбежных ошибок измерения получены отличные друг от друга значения $x^{(1)}, \ldots, x^{(N)}$.

В данном случае задача нахождения постоянной величины — длины пути на карте — может быть поставлена как задача восстановления функциональной зависимости $\tilde{f}(x) \equiv w$, где $w \in \mathbb{R}$ — значение измеряемой длины пути, наилучшим образом удовлетворяющей выборке $\{x^{(i)}\}_{i=1}^{N}$ относительно критерия (3). В соответствии с ним нами будет получено значение w равное среднему арифметическому значений $x^{(i)}$.

В самом деле, минимум (2) достигается на таком w_0, что

$$\frac{dE(w_0)}{dw} = 0.$$

Имеем:

$$\frac{dE(w)}{dw} = \left(\frac{1}{2}\sum_{i=1}^{N}\left(w - x^{(i)}\right)^2\right)' = \sum_{i=1}^{N}\left(w - x^{(i)}\right) = 0.$$

И значит

$$w = \frac{1}{N}\sum_{i=1}^{N} x^{(i)}.$$

Рассмотренная нами задача является частным случаем применения подхода, называемого *линейной регрессией*, то есть решения задачи регрессии для случая линейности искомой функции.

Пусть известно, что значения $y^{(i)}$ зависят от $x^{(i)} \in \mathbb{R}$ линейно, поскольку подчиняются некоторому физическому закону, который связывает их таким образом. Нам дана выборка $\{x^{(i)}, y^{(i)}\}_{i=1}^{N}$. Исходя из существования значений параметров A и B искомой линейной зависимости, получим

$$y^{(i)} = Ax^{(i)} + B + \varepsilon^{(i)}.$$

Используя метод наименьших квадратов, будем искать A и B, минимизируя значение функции ошибки $E(A, B)$:

$$E(A, B) = \frac{1}{2}\sum_{i=1}^{N}\big(y^{(i)} - Ax^{(i)} - B\big)^2.$$

Необходимым условием достижения минимума $E(A, B)$ в точке (A, B) является равенство в ней нулю частных производных $\partial E/\partial A$ и $\partial E/\partial A$:

$$\frac{\partial E(A, B)}{\partial A} = \sum_{i=1}^{N}\Big(\big(y^{(i)} - Ax^{(i)} - B\big)\big(-x^{(i)}\big)\Big) = 0,$$

$$\frac{\partial E(A, B)}{\partial B} = \sum_{i=1}^{N}\Big(\big(y^{(i)} - Ax^{(i)} - B\big)\big(-1\big)\Big) = 0.$$

Откуда получаем следующую систему линейных алгебраических уравнений с неизвестными A и B:

$$\begin{cases} \left(\sum\limits_{i=1}^{N}(x^{(i)})^2\right)A + \left(\sum\limits_{i=1}^{N} x^{(i)}\right)B = \sum\limits_{i=1}^{N} y^{(i)}x^{(i)}, \\ \left(\sum\limits_{i=1}^{N} x^{(i)}\right)A + NB = \sum\limits_{i=1}^{N} y^{(i)}. \end{cases} \tag{4}$$

Решая систему уравнений (4), находим значения A и B, дающие минимум $E(A, B)$. (Выполните задание 2 из раздела **Задания** к этому разделу).

Обобщение подхода. Произведём обобщение предложенного подхода на случай $x \in \mathbb{R}^m$, $m > 1$. Линейная функция $\tilde{f}$ имеет вид

$$\tilde{f}(w, x) = w_0 + w_1 x_1 + w_2 x_2 + \ldots + w_m x_m,$$

то есть $\tilde{f}(w, x)$ представляет собой линейную комбинацию базисных функций $1, x_1, x_2, \ldots, x_m$ с коэффициентами $w = (w_1, \ldots, w_m)$.

Функция $\tilde{f}(w, x)$, вектор параметров w для которой мы ищем, линейна как по этим параметрам, так и по значениям переменной. Это существенно сужает область применения такой модели.

Обобщая предложенный подход, мы можем использовать нелинейные базисные функции $\Phi_1(x), \ldots, \Phi_M(x)$ и искать функциональную зависимость $\tilde{f}$ в виде

$$\tilde{f}(w, x) = w_0 + \sum_{i=1}^{M} w_i \Phi_i(x),$$

как мы будем это делать далее, реализуя полиномиальную регрессию и многослойный перцептрон, в случае которого функции $\Phi_i(x)$ зависят от параметров — весов нейронной сети.

Заметим, что используемые нами функции $\tilde{f}(w, x)$ при этом остаются линейными относительно параметров w, что облегчает нахождение их оптимальных относительно критерия (3) значений.

Сведение к задаче линейной регрессии. Линейная регрессия может быть использована не только в том случае, если известно, что зависимые и независимые переменные связаны линейно. Часто задачи, в которых эта зависимость нелинейна, после замены координат и соответствующего преобразования выборки, могут быть сведены к задачам, к которым можно применить линейную регрессию. Производя обратную замену координат, мы получаем функциональную зависимость для исходной задачи.

В качестве примеров функциональных зависимостей, для восстановления которых мы можем применить линейную регрессию, могут быть рассмотрены приведённые ниже. Для того, чтобы получить вид функциональной зависимости в новых координатах и преобразовать выборку $\{(x_i, y_i)\}_{i=1}^N$ в выборку $\{(\dot{x}_i, \dot{y}_i)\}_{i=1}^N$, для них должны быть использованы указанные ниже замены координат.

а) $y = A/x + B$. Замена координат: $\dot{x} = 1/x$, $\dot{y} = A\dot{x} + B$;
б) $y = Ae^x + B$. Замена координат: $\dot{x} = e^x$, $\dot{y} = A\dot{x} + B$;
в) $y = Ae^{Bx}$. Логарифмируя обе части равенства, получим $\ln y = Bx + A$. Полагая $\dot{x} = \ln y$, получаем линейную функциональную зависимость $\dot{x} = \dot{A}\dot{y} + \dot{B}$, где $\dot{A} = B$, $\dot{B} = A$.

4.3 Полиномиальная регрессия

Для *полиномиальной регрессии* в качестве базисных функций $\Phi_i(x)$ используются функции 1, x, x^2, …, x^M для некоторого $M \in \mathbb{Z}_+$ и функциональная зависимость ищется в виде

$$\tilde{f}(x) = \tilde{f}(w, x) = w_0 + w_1 x + w_2 x^2 + \ldots + w_M x^M. \tag{6}$$

Значение параметра M такой модели выбирается при реализации подхода для решения конкретной задачи: степень полинома (6) должна быть достаточной для того, чтобы значение $E(w)$ было достаточно мало. Вместе с тем, слишком большое значение M будет давать $\tilde{f}$ с малым значением функции ошибки, но плохо пригодную для прогнозирования значений искомой функции на x, которых не было в выборке.

Реализуя полиномиальную регресию, мы по заданной выборке ищем вектор параметров $w = (w_0, \ldots, w_M)$, дающий минимум (2). Нахождение вектора w производится решением системы линейных алгебраических уравнений

$$\frac{\partial E(w)}{\partial w_i} = 0, \tag{7}$$

$i = \overline{0, M}$. Эта система уравнений получается подстановкой в (2) полинома (6), дифференцированием и группировкой слагаемых. (Выполните задание 2 из раздела **Задания** этой главы.)

4.4 Переобучение и способы его устранения

Говорят, что при решении задачи регрессии имеет место *переобучение*, если полученная функциональная зависимость даёт малое значение функ-

ции ошибки для заданной выборки, как правило, небольшой, но при этом она вряд ли близка к искомой функции, поскольку её значение слишком сильно меняется при малых изменениях аргумента. Поэтому с её помощью нельзя прогнозировать значения распознаваемой функции в точках её области определения, отличных отличных от задаваемых выборкой.

Для устранения переобучения могут быть использованы следующие подходы:

1) увеличение мощности выборки,
2) регуляризация.

Кроме того, переобучение может быть устранено модификацией используемой модели. Так при реализации полиномиальной регрессии, степень полинома должна быть выбрана адекватно решаемой задаче.

Результаты полиномиальной регрессии при разных значениях параметра M приведёны на рис. 4.2 для $M = 9$. График полученной функциональной зависимости изображён более тёмным, чем график зависимости, по которой была получена выборка, также изображённая на рис. 4.2. Пример переобучения при использовании полиномиальной регрессии приведён на рис. 4.2 для $M = 9$. При этом значении M мы имеем соответствие полученного полинома обучающей выборке с достаточно малой ошибкой, но прогнозировать для какой-либо прикладной задачи значения распознаваемой функции с помощью этого полинома вряд ли возможно.

Для функциональных зависимостей, данных в задании 3 из раздела **Задания** этой главы, переобучение возникает при степенях полинома от 10 выше при использовании выборок с мощностью, не превышающей 10.

4.5 Регуляризация

Под *регуляризацией* при решении задачи регрессии понимается добавления дополнительных ограничений к условию задачи с целью предотвратить переобучение. Поскольку при переобучении для полученной функциональной зависимости при малых изменениях аргумента происходит слишком большое изменение функции, необходимо уменьшить абсолютные значения коэффициентов полинома $\tilde{f}(w, x)$ для того, чтобы он не имел слишком больших производных. Для этого функция ошибки $E(w)$

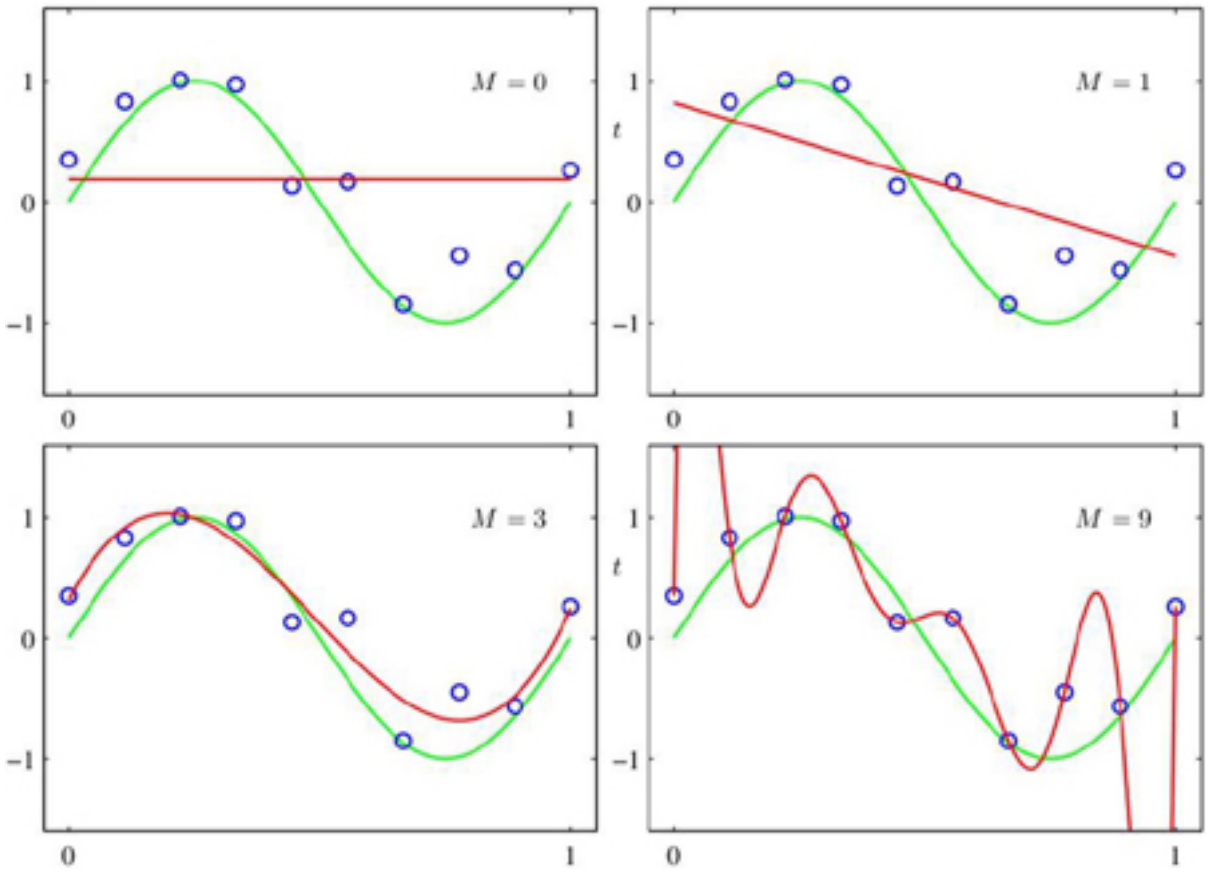


Рис. 4.2: Полиномиальная регрессия для разных M.

модифицируется добавлением *регуляризационного слагаемого* с целью минимизации абсолютных значений коэффициентов полинома:

$$E_\lambda(w) = \frac{1}{2}\sum_{i=1}^{N}\left(y^{(i)} - \tilde{f}(w, x^{(i)})\right)^2 + \frac{\lambda}{2}||w||^2, \tag{8}$$

где $||\cdot||$ — некоторая норма вектора. В качестве нормы $||\cdot||$ может быть выбрана евклидова норма $||w|| = \sum_{i=0}^{M} w_i^2$ или другая, более подходящая для решаемой задачи. Параметр λ задаёт вес регуляризационного слагаемого. Чем больше значение λ, тем меньше $||w||$, то есть меньше коэффициенты полинома $\tilde{f}(w, x)$. Такая регуляризация называется *тихоновской*.

Правильный выбор значения λ позволяет получить полином достаточной степени, чтобы значение функции ошибки $E(w)$ для обучающей выборки было мало, и при этом поведение функции не было слишком

хаотично. На рис. 4.3 чёрным цветом изображён график восстанавливаемой функциональной зависимости, красным цветом — полученной при минимизации (2). Изображённый зелёным цветом график — это график функциональной зависимости, полученной для того же значения M минимизацией (8).

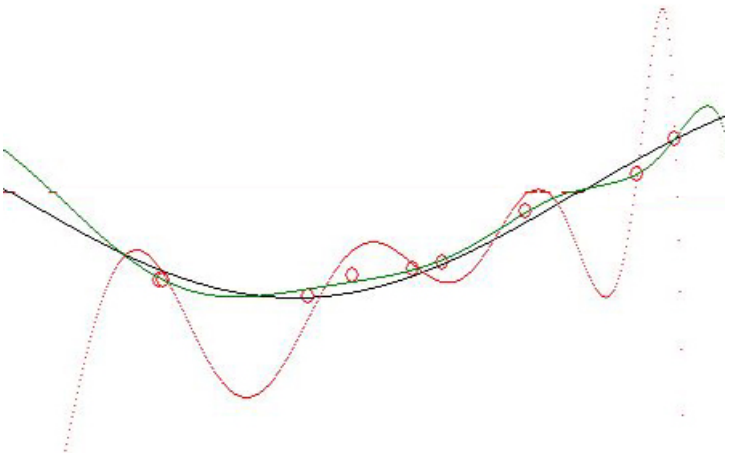


Рис. 4.3: Регуляризация для $M=15$ с $\lambda=0.01$.

Вычисление $||w||$ производится без учёта коэффициента w_0, то есть мы полагаем в (8) $||w|| = \sqrt{\sum_{i=1}^{M} w_i^2}$. Минимизация и w_0 приводит к тому, что любой полученный полином $\tilde{f}$ в окрестности нуля будет иметь близкие к нулю значения и производные. Это сужает диапазон функций, которые могут быть с достаточной точностью представлены полиномами $\tilde{f}$.

Обобщая (8) на случай произвольной нормы ℓ^q, получаем следующую функцию ошибки с регуляризационным слагаемым:

$$E_\lambda(w) = \frac{1}{2}\sum_{i=1}^{N}\left(y^{(i)} - \tilde{f}(w, x^{(i)})\right)^2 + \frac{\lambda}{2}\sum_{i=1}^{M}|w_i|^q \qquad (9)$$

Отдельно выделяют следующие случаи:

а) при $q=2$ — *гребневая-регуляризация*;

б) при $q=1$ — *ЛАССО-регуляризация* (от англ. *Least Absolute Shrinkage and Selection Operator*).

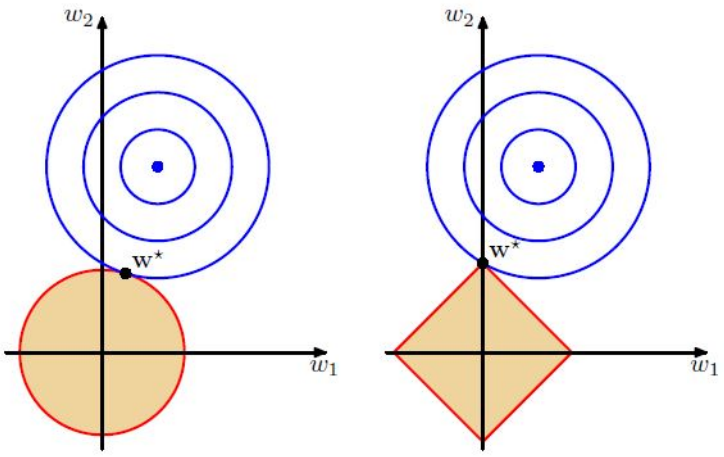


Figure 3.4 Plot of the contours of the unregularized error function (blue) along with the constraint region (3.30) for the quadratic regularizer $q = 2$ on the left and the lasso regularizer $q = 1$ on the right, in which the optimum value for the parameter vector $\mathbf{w}$ is denoted by $\mathbf{w}^\star$. The lasso gives a sparse solution in which $w_1^\star = 0$.

Рис. 4.4: Метод множителей Лагранжа

При ЛАССО-регуляризации, если λ достаточно велико, некоторые коэффициенты w_i обращаются в ноль. Это эквивалентно устранению соответствующих базисных функций, то есть происхожит уменьшение размерности модели. С ростом λ размерность убывает быстрее.

Минимизация (9) эквивалентна минимизации нерегуляризованного (1) при ограничении

$$\sum_{i=1}^{M} |x_i|^q \leq \eta$$

для некоторого η (метод множителей Лагранжа).

На рис. 4.3 w^* — это точка, в которой касательные к линии уровня (рис. N) $E(w)$ и к кривой $\sum_{i=1}^{M} |x_i|^q = \eta$ совпадают, то есть точки, в которых достигается максимум (9). На рис. 4.4 показана форма линий уровня регуляризационного слагаемого для различных q. В случае, если проводится ЛАССО-регуляризация или вообще регуляризация с $q \leq 1$, в ходе обучения будет происходить уменьшение размерности модели, поскольку некоторые компоненты w^* с большой вероятностью будут становиться нулевыми. Если производится гребневая регуляризация или вообще регуляризация с $q > 1$, размерность модели будет сохраняться в ходе обучения.

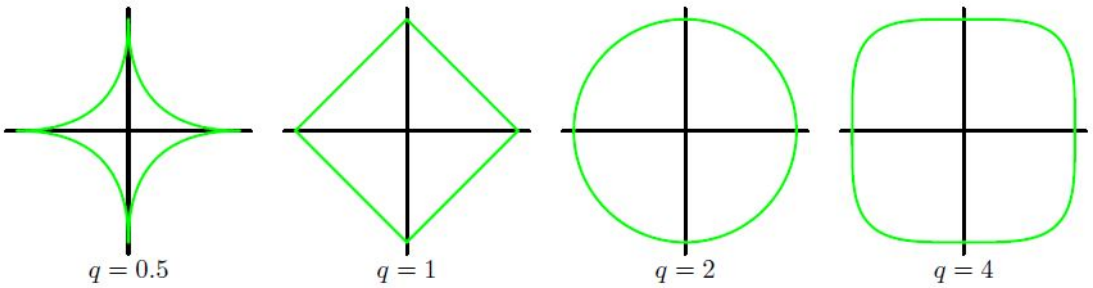


Figure 3.3 Contours of the regularization term in (3.29) for various values of the parameter q.

Рис. 4.5: Регуляризация при различных q

4.6 Кросс-валидация

Как отмечено выше, малое значение функции ошибки для $\tilde{f}$ на обучающей выборке не обязательно свидетельствует о том, что ошибка для $\tilde{f}$ на других выборках будет столь же мала. Если мощность выборки достаточно велика, то её данные могут быть разделены на те, которые используются на стадии обучения, и на те, на которых будет производиться проверка применимости полученной на стадии обучения функции для данных, не входящих в обучающую выборку.

Обучение может производиться с использованием различных параметров модели и давать несколько вариантов решения — несколько функциональных зависимостей, из которых после их тестирования на данных, не входящих в обучающую выборку, может быть выбрана наилучшая. Для этого может быть использована дополнительная *контрольная* выборка, на которой окончательно оценивается величина ошибки при таком выборе.

Вместе с тем, во многих практических приложениях запасы данных для обучения и тестирования полученных функциональных зависимостей ограничены. Поэтому для того, чтобы получить функциональные зависимости, дающие решение задачи регрессии с минимальной ошибкой, при обучении необходимо использовать максимальное количество имеющихся в распоряжении данных. Это, в свою очередь, может приводить к тому, что данных для проверки того насколько полученная зависимость будет соответствовать данным, не входящим в обучающую выборку, будет слишком мало.

Одним из возможных подходов к решению этой проблемы является

кросс-валидация (или «перекрёстная проверка», или «скользящий контроль»). Цель кросс-валидации состоит в том, чтобы оценить ожидаемый уровень соответствия модели данным, не зависящим от тех данных, которые были использованы для обучения. Применяя кросс-валидацию мы более тщательно используем выборку при обучении, получая из неё различные варианты подвыборок, на данных которых производим обучение и тестирование.

При реализации кросс-валидации имеющаяся выборка S случайным образом разбивается на K подмножеств $S_1, \ldots, S_K$, таких, что

$$S = \bigcup_{i=1}^{K} S_i,\ (i \neq j) \Rightarrow (S_j \bigcap S_i = \varnothing),$$

$1 \leq K \leq N$. Разбиение производится на равные по мощности подмножества S_i. После чего объединение $K-1$ подмножеств используется для обучения. Обучение производится для каждой из рассматриваемых моделей, задаваемых различными наборами параметров. Одно оставшееся подмножество используется для расчёта значений функции ошибки при сравнении получаемых моделей.

Такая процедура выполняется K раз, при этом каждое из K подмножеств один раз выступает в качестве выборки для тестирования, тогда как объединение оставшихся $K-1$ множеств используется для обучения. Результаты проведённых проверок усредняются и, исходя из них, происходит выбор модели с наименьшей по результатам всех проведённых проверок ошибкой.

Если мощность имеющейся выборки достаточно мала, то может быть положено $K = N$. Такая кросс-валидация называется «поэлементной кросс-валидацией» или «кросс-валидацией по отдельным объектам». Каких-либо определённых рекомендаций по выбору количества множеств S_i нет. В случае, если выборка небольшая рекомендуется поэлементная кросс-валидация.

Кросс-валидация может быть применена для выбора параметров моделей при реализации различных методов распознавания и классификации, в том числе и для всех рассматриваемых в этом учебном пособии методов.

Кросс-валидация для полиномиальной регрессии. На величину функции ошибки $E_\lambda(w)$ в виде (8) влияют два параметра — M и λ. В связи с чем, задача выбора наилучших их значений может быть сформулирована следующим образом.

Задача 3. Определить наилучшую пару (M, λ) для восстановления зависимости, исходя из имеющейся выборки $S = \{x^{(i)}, y^{(i)}\}_{i=1}^{N}$.

Сравнение полученных полиномов с коэффициентами w для различных вариантов (M, λ) производится сравнением значений функции ошибки $E(w)$ вида (2), тогда как на стадии обучения для каждой пары (M, λ) ищутся значения коэффициентов, минимизирующие $E_\lambda(w)$ вида (8). (Выполните задание 6 из раздела **Задания** к этому разделу).

Вычислительная сложность. Одна из главных проблем, с которой приходится иметь дело при реализации кросс-валидации, состоит в том, что вычислительная сложность решения задачи распознавания при применении такого подхода может значительно возрасти. Это происходит по той причине, что стадия обучения производится многократно с использованием различных выборок и для разных комбинаций параметров модели, что может иметь большую вычислительную сложность в случае если стадия обучения трудоёмка сама по себе. Если количество параметров достаточно велико, то вычислительная сложность проверки всех их комбинаций может оказаться слишком велика для численной реализации расчётов.

4.7 Метод наименьших квадратов и метод наибольшего правдоподобия

Метод наибольшего правдоподобия является асимптотически оптимальным способом определения параметров распределения по выборке [18]. В соответствии с этим методом мы выбираем такие значения неизвестных параметров, при которых максимальна вероятность получения нами данной выборки в случае дискретного вероятностного распределения.

В случае непрерывного распределения максимизируется плотность вероятностного распределения на множестве возможных значений параметров.

Предположим, на множестве неопределённых параметров w функции, в виде которой мы ищем решение задачи восстановления функциональной зависимости, задано вероятностное распределение указанием функции плотности $\mathsf{p}(w)$. Пусть $S = \{x^{(i)}, y^{(i)}\}_{i=1}^{N}$ — данная нам обучающая выборка, $\mathsf{p}(S|w)$ — условная плотность вероятности получения выборки S при значении параметров w.

По формуле Байеса имеем:

$$\mathsf{p}(w|S) = \frac{\mathsf{p}(S|w)\mathsf{p}(w)}{\mathsf{p}(S)}.$$

Применяя *метод наибольшего правдоподобия*, мы производим выбор параметров w так, чтобы максимизировать вероятность получения выборки S. То есть нами ставится следующая задача: найти вектор параметров $\tilde{w}$, такой что

$$\tilde{w} = \arg\max_{w} \mathsf{p}(S|w).$$

Выбором параметров w мы будем максимизировать условную плотность вероятности получения выборки S, то есть будем максимизировать значение функции правдоподобия.

Пусть $X = (x^{(1)}, \ldots, x^{(N)})$, $Y = (y^{(1)}, \ldots, y^{(N)})$. Предположим, что для данных значений X соответствующие значения Y имеют нормальное распределение со средним значением $\tilde{f}(w, x)$ для каждого $x \in X$, что схематично изображено на рис. 4.6, где $\mathsf{p}(y|\tilde{f}(w, x), \sigma)$ — плотность распределения $\mathcal{N}(\tilde{f}(w, x), \sigma^2)$ для некоторого σ.

Пусть $\tilde{f}(w, X)$ обозначает упорядоченное множество значений $\tilde{f}(w, x^{(i)})$ полинома. Функция правдоподобия имеет вид

$$\mathsf{p}(S|w) = \tilde{\mathsf{p}}(Y|\tilde{f}(w, X), \sigma), \tag{10}$$

где $\tilde{\mathsf{p}}(Y|\tilde{f}(w, X), \sigma)$ — плотность многомерного нормального распределения $\mathcal{N}(\tilde{f}(w, X), \sigma^2)$. (10) задаёт плотность вероятности получения выборки (Y, X) при заданных значениях w и σ при нормальном распределении ошибки. Значение параметра σ определяется точностью измерений при получении выборки.

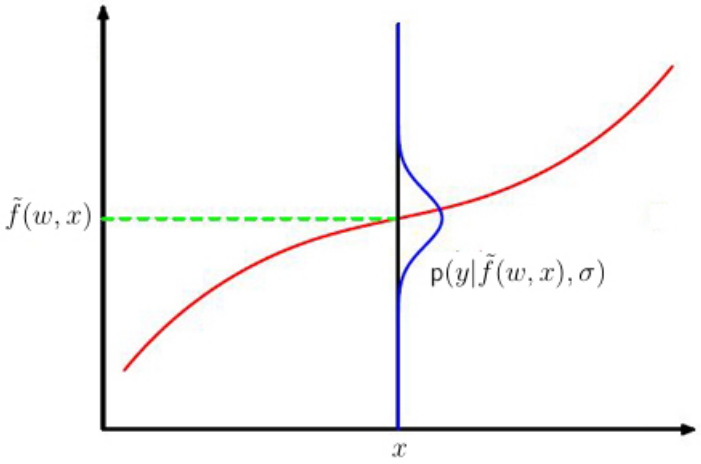


Рис. 4.6: Нормальное распределение ошибки.

Поскольку измерения предполагаются независимыми, то (10) эквивалентно

$$\mathsf{p}(S|w) = \prod_{i=1}^{N} \tilde{\mathsf{p}}_i\big(y^{(i)}|\tilde{f}(w,x^{(i)}),\sigma\big), \tag{11}$$

где

$$\tilde{\mathsf{p}}_i\big(y^{(i)}|\tilde{f}(w,x^{(i)}),\sigma\big) = \frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{\big(y^{(i)}-\tilde{f}(w,x^{(i)})\big)^2}{2\sigma^2}\right).$$

Логарифмируя (10), получаем

$$\ln \mathsf{p}(S|w) = \ln\prod_{i=1}^{N}\left(\frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{(y^{(i)}-\tilde{f}(w,x^{(i)}))^2}{2\sigma^2}\right)\right) =$$

$$= \sum_{i=1}^{N}\ln\left(\frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{\big(y^{(i)}-\tilde{f}(w,x^{(i)})\big)^2}{2\sigma^2}\right)\right) = \sum_{i=1}^{N}\ln\left(\frac{1}{\sqrt{2\pi}\sigma}\right) -$$

$$-\frac{1}{2\sigma^2}\sum_{i=1}^{N}\left(y^{(i)}-\tilde{f}(w,x^{(i)})\right)^2 = N\ln\left(\frac{1}{\sqrt{2\pi}\sigma}\right) - \frac{1}{2\sigma^2}\sum_{i=1}^{N}\left(y^{(i)}-\tilde{f}(w,x^{(i)})\right)^2.$$

Логарифм — монотонно возрастающая функция. Следовательно, чем больше значение функции правдоподобия $\mathsf{p}(S|w)$, тем более вероятно получение выборки S при данных значениях коэффициентов w. Это значит, что для выборки S максимальное значение функции правдоподобия

$\mathsf{p}(S|w)$ достигается тогда и только тогда, когда достигается минимум функции ошибки $E(w)$.

Проведённые рассуждения справедливы для любой, в том числе полиномиальной, функциональной зависимости $\tilde{f}$ с параметрами w.

Мы можем сделать следующий вывод. Если исходить из нормального распределения ошибки измерений, то решение задачи восстановления функциональной зависимости методом наибольшего правдоподобия эквивалентно минимизации функции ошибки в методе наименьших квадратов. Верно и обратное: решение задачи восстановления функциональной зависимости применением метода наименьших квадратов эквивалентно применению метода наибольшего правдоподобия при допущении о нормальном распределении ошибок измерений. Это означает, что применение метода наименьших квадратов к решению задачи распознавания функциональной зависимости является обоснованным только в том случае, если распределение ошибки измерений является нормальным.

4.8 Задания

1. Укажите, когда разрешима система уравнений (4), и объясните, почему решение единственно в этом случае. Какой выборке соответствует ситуация, когда определитель этой системы уравнений равен нулю?
2. Покажите, что коэффициенты w, минимизирующие функцию ошибки $E(w)$ в случае полиномиальной регрессии, являются решениями системы линейных уравнений вида

$$\sum_{j=0}^{M} a_{ij} w_j = b_i,$$

где

$$a_{ij} = \sum_{k=1}^{N} x_k^{i+j}, \;\; b_i = \sum_{k=1}^{N} x_k^i y_k,$$

где для простоты обозначений $x_k^i = (x^{(k)})^i$, $y_k = y^{(k)}$ для выборки $\{(x^{(k)}, y^{(k)})\}$. Всегда ли разрешима эта система уравнений?

3. Реализуйте программно восстановление функциональной зависимости методом наименьших квадратов с помощью полиномиальной регрессии. Для этого
   а) используйте значения параметра $M \in \{0, 1, \ldots, 15\}$;
   б) генерируйте выборку двумя способами: в первом случае моделируйте ошибку измерения как равномерно распределённую случайную величину, во втором — как нормально распределённую случайную величину;
   в) генерируйте значения x из заданного интервала случайно в соответствии с равномерным распределением;
   г) в качестве распознаваемых функциональных зависимостей используйте следующие:
   $y = \cos x$, $y = 5x^3 + x^2 + 5$, $y = x \sin x$, $x \in [0, 2\pi]$.
4. При условиях, сформулированных в задаче 3, реализуйте программно регуляризацию для полиномиальной регрессии и покажите, что переобучение может быть устранено при некоторых значениях M и λ. Найдите эти значения для выбранных функций и некоторых выборок, полученных для этих функций.
5. Реализуйте программно кросс-валидацию для полиномиальной регрессии с регуляризацией. Определите наилучшую пару (M, λ) для восстановления функциональных зависимостей из задания 4.

5 Нейронные сети

Одним из подходов к решению задач регрессии, и классификации является метод нейронных сетей прямого распространения. Этот метод основан на использовании базисных функций с параметрами, значения которых модифицируются в ходе стадии обучения.

Нейронная сеть представляет собой последовательность функциональных преобразований входных данных. Термин «нейронные сети» берёт своё начало из попыток найти математическое представление информационных процессов в биологических системах [22, 23, 24], многие из которых оказались необоснованными относительно их соответствия биологическим процессам.

Преобразование, которое задаётся нейронной сетью, может быть представлено в виде графа. Представляемые рёбрами и вершинами этого графа преобразования входных переменных и специфика задания отношения смежности на множестве вершин этого графа определяют *архитектуру* нейронной сети. *Архитектура* нейронной сети определяет:

а) представляемые рёбрами и вершинами этого графа преобразования входных переменных,
б) специфика задания отношения смежности на множестве вершин этого графа.

В этом разделе мы рассматриваем базовые архитектуры нейронной сети: элементарный перцептрон и многослойный перцептрон.

Для решения различных прикладных задач разработаны специфические архитектуры нейронных сетей, учитывающие специфику решаемых задач. Мы ограничимся рассмотрением нейронных сетей с двумя базовыми архитектурами — элементарного перцептрона и многослойного перцептрона.

5.1 Перцептрон

Перцептрон (*элементарный перцептрон, перцептрон Розенблатта*) — это алгоритм, задающий линейное преобразование значений входных переменных $x_1, x_2, \ldots, x_m$ с параметрами $w_0, w_1, \ldots, w_m$, результат которого преобразуется посредством ступенчатой функции θ в значение выходной переменной y:

$$y = \theta\big(\langle w, x\rangle\big),$$

где $\langle \cdot, \cdot \rangle$ — скалярное произведение:

$$\langle w, x\rangle = \sum_{i=0}^{m} w_i x_i,$$

где положим $x_0 = 1$, а *ступенчатая функция* θ — это функция

$$\theta(t) = \begin{cases} 1, & \text{если } t \geq 0; \\ -1, & \text{иначе.} \end{cases}$$

Параметр w_0 — *смещение* — это значение, неравенство которого нулю позволяет рассматривать линейные функции, задаваемые скалярным произведением, не обязательно равные нулю в начале координат.

На рис. 5.1 перцептрон представлен в виде графа, вершины в котором соответствуют входам и выходу y.

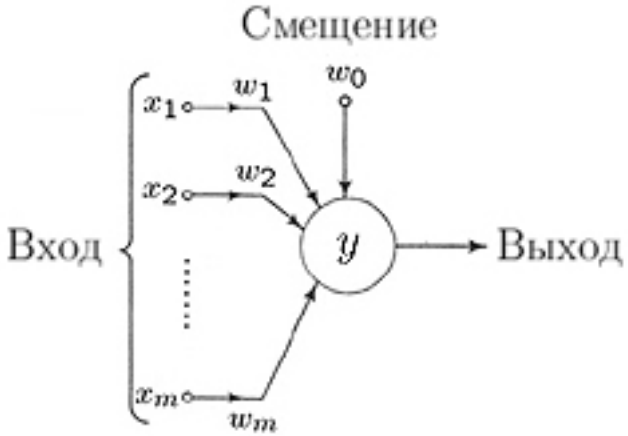


Рис. 5.1: Представление перцептрона в виде графа.

Пусть, решая задачу классификации, мы имеем два *линейно-отделимых* класса векторов признаков $\mathcal{C}_1, \mathcal{C}_2 \subset \mathbb{R}^m$, то есть при некотором значении вектора коэффициентов $w \in \mathbb{R}^{m+1}$ уравнение

$$w_0 + w_1 x_1 + \ldots + w_m x_m = 0 \tag{1}$$

задаёт гиперплоскость, разделяющую $\mathcal{C}_1$ и $\mathcal{C}_2$. Значения x, для которых $\langle w, x \rangle = 0$, задают *границу решений*: векторы признаков, оказывающиеся по одну сторону от этой границы принадлежат одному классу, по разные стороны — разным классам.

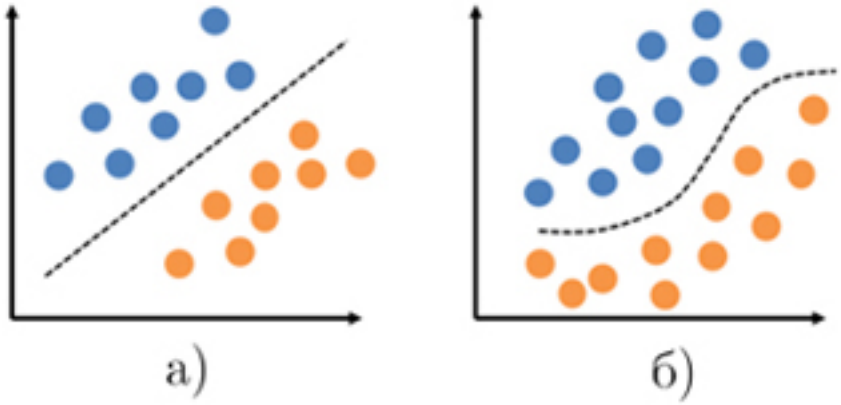


Рис. 5.2: Линейно-отделимые и не линейно-отделимые классы векторов признаков.

Решая задачу классификации, мы будем полагать, что любой допустимый вектор признаков x либо принадлежит $\mathcal{C}_1$, либо $\mathcal{C}_2$. Будем считать, что вектор признаков x классифицируется перцептроном правильно, если $y(x) = 1$ для $x \in \mathcal{C}_1$, и $y(x) = -1$ для $x \in \mathcal{C}_2$. Обучение перцептрона будем производить используя обучающую выборку $\mathcal{H}$: $\mathcal{H} = \mathcal{H}_1 \cup \mathcal{H}_2$, где $\mathcal{H}_1 \subset \mathcal{C}_1$, $\mathcal{H}_2 \subset \mathcal{C}_2$. В результате обучения нам необходимо найти такой вектор $\tilde{w}$, что

$$\begin{cases} \langle \tilde{w}, x \rangle > 0, & \forall x \in \mathcal{C}_1, \\ \langle \tilde{w}, x \rangle \leq 0, & \forall x \in \mathcal{C}_2. \end{cases}$$

Пусть $x(n)$, $w(n)$ — значения вектора признаков и вектора параметров w — *весов* — на n-ой итерации, $x(n) \in \mathcal{H}_1 \cup \mathcal{H}_2$, $|\mathcal{H}_1 \cup \mathcal{H}_2| = N$. Будем считать что все векторы из обучающей выборки $\mathcal{H}_1 \cup \mathcal{H}_2$ пронумерованы. Если $n > N$, то полагаем $x(n) = x\ (n \mod N)$.

Для обучения перцептрона будем использовать следующий алгоритм.

Алгоритм обучения перцептрона

1. Полагаем $n=0$; $w(0)=(0,\ldots,0)$.

2. Пока не выполняется $w(n)=w(n+t)$ для любого $t\geq N$:

$$\begin{cases} w(n+1) := w(n), & \text{если } x(n)\in\mathcal{H}_1 \text{ и } \langle w(n),x(n)\rangle > 0; \\ w(n+1) := w(n), & \text{если } x(n)\in\mathcal{H}_2 \text{ и } \langle w(n),x(n)\rangle \leq 0 \end{cases}$$

иначе

$$\begin{cases} w(n+1) := w(n)-\eta x(n), & \text{если } x(n)\in\mathcal{H}_2 \text{ и } \langle w(n),x(n)\rangle > 0; \\ w(n+1) := w(n)+\eta x(n), & \text{если } x(n)\in\mathcal{H}_1 \text{ и } \langle w(n),x(n)\rangle \leq 0. \end{cases}$$

3. $n:=n+1$. Перейти на шаг 2.

То есть, если классификация на n-ой итерации алгоритма производится правильно для вектора весов $w(n)$, то не изменяем его. В противном случае изменяем веса, используя для этого некоторое значение η, называемое *коэффициентом обучения*.

Будем говорить, что алгоритм обучения *сходится*, если в ходе его работы за конечное количество итераций мы находим такие значения весов, которые не меняются в ходе последующих его итераций и классификация с которыми производится верно для всех элементов обучающей выборки. Верна следующая

Теорема. *Пусть классы $\mathcal{C}_1$ и $\mathcal{C}_2$ линейно-отделимы. Тогда алгоритм обучения перцептрона сходится.*

Доказательство. Для упрощения изложения положим $\eta=1$. Если мы покажем, что сходимость алгоритма будет иметь место для такого значения коэффициента обучения, то сходимость будет иметь место и при меньших значениях η, но потребует большего количества итераций.

Предположим, $x(k) \in \mathcal{H}_1$, $k < n+1$, и классификация производится неверно на всех итерациях вплоть до $(n+1)$-ой. В этом случае, в соответствии со сформулированным выше алгоритмом обучения, мы полагаем

$$w(n+1) = w(n) + x(n).$$

Имея $w(0) = (0, \ldots, 0)$, получим:

$$w(1) = x(0),$$

$$w(2) = w(1) + x(1) = x(1) + x(0)$$

и так далее вплоть до $(n+1)$-ой итерации:

$$w(n+1) = x(0) + x(1) + x(2) + \ldots + x(n) = \sum_{i=0}^{n} x(i).$$

Поскольку $\mathcal{C}_1$ и $\mathcal{C}_2$ линейно-отделимы, то решение $\tilde{w}$ существует, а значит $\langle \tilde{w}, x(i) \rangle > 0$ для $i = 0, 1, \ldots, n$. Пусть

$$\alpha = \min_{x \in \mathcal{H}_1} \langle \tilde{w}, x \rangle.$$

Поскольку

$$\langle \tilde{w}, w(n+1) \rangle = \langle \tilde{w}, x(1) \rangle + \langle \tilde{w}, x(2) \rangle + \ldots + \langle \tilde{w}, x(n) \rangle,$$

то

$$\langle \tilde{w}, w(n+1) \rangle \geq n\alpha.$$

Применяя неравенство Коши-Буняковского, получаем:

$$\|\tilde{w}\|^2 \cdot \|w(n+1)\|^2 \geq \langle \tilde{w}, w(n+1) \rangle^2 \geq (n\alpha)^2,$$

то есть

$$\|w(n+1)\|^2 \geq \frac{(n\alpha)^2}{\|\tilde{w}\|^2}. \tag{2}$$

С другой стороны, поскольку

$$w(k+1) = w(k) + x(k)$$

для $k = 1, \ldots, n$ и $x(k) \in \mathcal{H}_1$, то если взять квадрат евклидовой нормы $w(k+1)$, мы будем иметь:

$$\|w(k+1)\|^2 = \|w(k)\|^2 + \|x(k)\|^2 + 2\langle w(k), x(k)\rangle.$$

Если классификация для $k = 1, \ldots, n$ проводилась неверно, имеем

$$\langle w(k), x(k)\rangle < 0.$$

Следовательно,

$$\|w(k+1)\|^2 \leq \|w(k)\|^2 + \|x(k)\|^2,$$

или

$$\|w(k+1)\|^2 - \|w(k)\|^2 \leq \|x(k)\|^2.$$

Суммируя такие неравенства для $k = 1, 2, \ldots, n$, получаем

$$\|w(n+1)\|^2 \leq \sum_{k=1}^{n} \|x(k)\|^2 \leq n\beta,$$

где

$$\beta = \max_{x(k) \in H_1} \|x(k)\|^2.$$

Значит,

$$\|w(n+1)\|^2 \leq n\beta. \tag{3}$$

Имея оценки (2) и (3), получаем

$$\frac{(n\alpha)^2}{\|\tilde{w}\|^2} \leq \|w(n+1)\|^2 \leq n\beta,$$

при том, что оценка снизу растёт быстрее оценки сверху, а значит существует такое значение $w(n_0)$ для некоторого n_0, что и (2), и (3) будут выполнены как равенства. Следовательно, существует такое n_0, что

$$\frac{n_0^2\alpha^2}{\|\tilde{w}\|^2} = n_0\beta.$$

Из чего следует, что

$$n_0 = \frac{\beta\|\tilde{w}\|^2}{\alpha^2}.$$

После итерации n_0 векторы из $\mathcal{H}_1$ будут классифицироваться верно и модификация весов больше производиться не будет.

При сделанных нами в начале доказательства предположениях о том, что $x(n) \in \mathcal{H}_1$ и классификация производится неверно на всех итерациях вплоть до $(n+1)$-ой, сходимость алгоритма обучения доказана. Для завершения доказательства выполните задания 1 и 2 из раздела **Задания** к этому разделу.

На рис. 5.3 приведена иллюстрация сходимости (алгоритма обучения) элементарного перцептрона. Гиперплоскость, определяемая w_t неверно классифицирует одну красную точку, которой классификатором должна быть назначена метка -1, и одну синюю, которой классификатором должна быть назначена метка $+1$. На среднем рисунке показано, как происходит обновление весов, то есть получение w_{t+1}, при выборе для проведения обновления неправильно классифицированной с помощью w_t красной точки x. Поскольку её метка -1, мы вычитаем её из w_t: $w_{t+1} = w_t - x$. Гиперплоскость, которая задаётся нормалью w_{t+1}, разделяет классы, то есть алгоритм обучения перцептрона сошёлся.

Для линейно неотделимых классов не существует разделяющей их гиперплоскости, поэтому с помощью перцептрона классификацию для них производить нельзя. Алгоритм обучения в этом случае не сходится. В этой связи важную роль в истории нейронных сетей сыграла следующая задача с линейно-неотделимыми классами — задача XOR. В этой задаче заданы двумерные векторы признаков (x, y), $x, y \in \{0, 1\}$; классы определяются в соответствии со значениями операции «исключающего или» для x и y:

$$\mathcal{C}_1 = \{(X, Y) \mid X \neq Y\}, \qquad \mathcal{C}_2 = \{(X, Y) \mid X = Y\}.$$

Необходимо найти такие веса $\tilde{w}$, что элементарный перцептрон реализует XOR, то есть распознаёт векторы из классы $\mathcal{C}_1$ и $\mathcal{C}_2$.

Несмотря на то, что в данной задаче мы имеем всю генеральную совокупность в качестве обучающей выборки, решить эту задачу с помощью элементарного перцептрона невозможно, как это возможно, например, для классов, определяемых операцией «или» (рис. 5.4 слева). То есть элементарный перцептрон не может смоделировать XOR ни при каком $\tilde{w}$.

Geometric Intuition

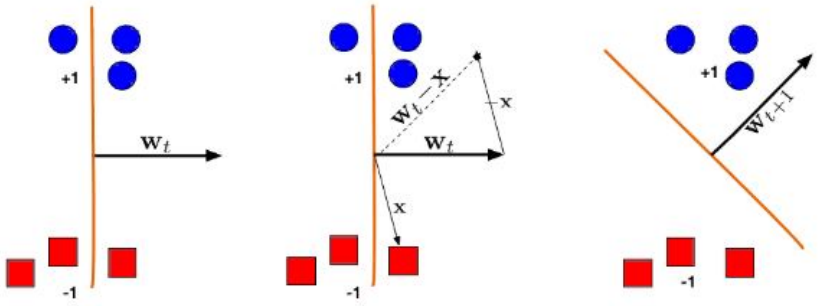


*Illustration of a Perceptron update. (Left:) The hyperplane defined by $\mathbf{w}_t$ misclassifies one red (-1) and one blue (+1) point. (Middle:) The red point $\mathbf{x}$ is chosen and used for an update. Because its label is -1 we need to **subtract** $\mathbf{x}$ from $\mathbf{w}_t$. (Right:) The udpated hyperplane $\mathbf{w}_{t+1} = \mathbf{w}_t - \mathbf{x}$ separates the two classes and the Perceptron algorithm has converged.*

Quiz: Assume a data set consists only of a single data point $\{(\mathbf{x}, +1)\}$. How often can a Perceptron misclassify this point $\mathbf{x}$ repeatedly? What if the initial weight vector $\mathbf{w}$ was initialized randomly and not as the all-zero vector?

Рис. 5.3: Сходимость элементарного пецептрона

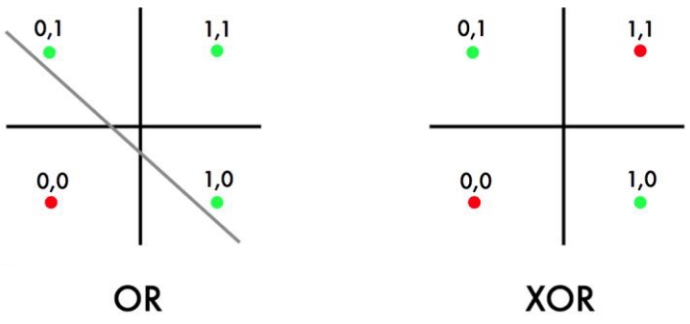


Рис. 5.4: Проблема XOR

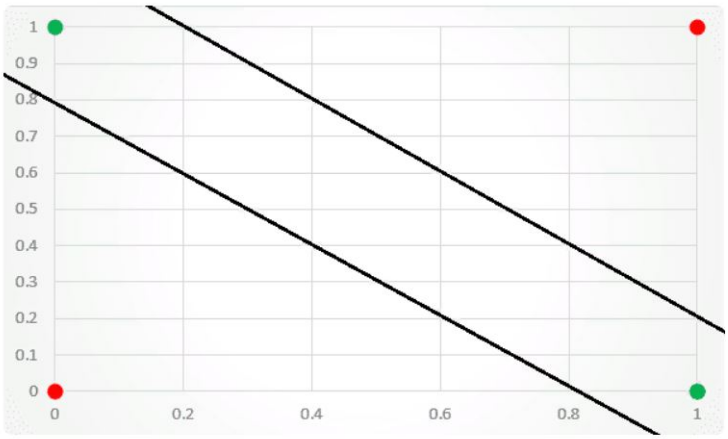


Рис. 5.5: Проблема XOR. Разделяющая поверхность

При обучении по представленному выше алгоритму для этой задачи сходимости не будет. Многослойный перцептрон, рассматриваемый далее, строит нелинейные разделяющие поверхности сколь угодно сложной формы, теоретически, как будет показано далее, позволяющие решить любую корректно поставленную задачу классификации. Для задачи XOR с помощью многослойного перцептрона может быть построена, например, такая разделяющая поверхность, какая изображённа на рис. 5.5.

5.2 Многослойный перцептрон

Многослойный перцептрон реализует многоэтапное преобразование входных данных, которое представляет собой композицию преобразований, задаваемых модифицированными простейшими перцептронами. Их функция активации отлична от ступенчатой. Это некоторая, как правило, сигмоидальная, дифференцируемая функция.

Линейные модели для решения задачи восстановления функциональной зависимости, рассмотренные нами ранее — линейная и полиномиальная модели для решения задач регрессии имеют вид

$$\tilde{f}(w,x) = \sum_{i=1}^{M} w_i \Phi_i(x).$$

Расширим эту модель, используя базисные функции $\Phi_i(x)$, зависящие

не только от вектора признаков x, но и от некоторых параметров, которые являются значениями функций того же вида.

Базисные функции, используемые в нейронных сетях, являются нелинейными функциями от линейных комбинаций их входов, подвергнутых многократным преобразованиям линейного комбинирования и заданного для нейронной сети нелинейного преобразования. Коэффициенты линейных комбинаций, используемых при этом, являются параметрами модели, определяемыми на стадии обучения.

Функциональное преобразование $\tilde{f} : X \to Y$, $X \subseteq \mathbb{R}^m$, $Y \subseteq \mathbb{R}^n$, задаваемое *двухслойным перцептроном*. Для этого построим M_1 (M_1 — параметр модели) линейных комбинаций входных переменных $x_1, \ldots, x_m$ вида

$$a_j^{(1)} = w_{j0}^{(1)} + \sum_{i=1}^{m} w_{ji}^{(1)} x_i, \tag{4}$$

где $j = \overline{1, M_1}$ и верхний индекс указывает, что соответствующие параметры являются параметрами первого *слоя* нейронной сети. Параметры $w_{ji}^{(k)}$ будем далее называть *весами*, а параметры $w_{j0}^{(k)}$ — *смещениями*.

Каждое значение функций $a_j^{(1)}(x)$ преобразуется с помощью дифференцируемой *функции активации* h и даёт значения

$$z_j^{(1)}(x) = h(a_j^{(1)}). \tag{5}$$

Нелинейная функция h может быть выбрана *сигмоидальной*, то есть функцией, которая обладает свойствами линейной и ступенчатой функций. По аналогии со ступенчатой функцией, она нелинейна, что даёт возможность выделять в пространстве векторов признаков области сложной формы, в том числе невыпуклые и несвязные. С другой стороны, подобно линейной функции и в отличие от ступенчатой, она непрерывна. Примерами сигмоидальных функций являются сигмоид

$$\sigma(x) = \frac{1}{1 + e^{-x}},$$

и гиперболический тангенс

$$\mathrm{th}(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} = \frac{e^{2x} - 1}{e^{2x} + 1}.$$

В качестве функции активации может быть выбрана и не сигмоидальная функция, например, ReLU. Далее мы рассмотрим этот вопрос подробнее.

На втором слое двухслойного перцептрона полученные значения $z_j^{(1)}$ снова многократно линейно комбинируются и дают значения *выходных активационных узлов* $a_k^{(2)}$:

$$a_k^{(2)} = w_{k0}^{(2)} + \sum_{j=1}^{M} w_{kj}^{(2)} z_j^{(1)}, \tag{6}$$

где $k = \overline{1, M_2}$, $M_2 = n$.

Выбор функции активации для *выходного слоя* нейронной сети производится исходя из специфики задачи. Так, для задач бинарной классификации значение активаций для выходного (в данном случае второго) слоя нейронной сети преобразуется с помощью сигмоидального преобразования, в качестве которого может быть выбран сигмоид:

$$\tilde{f}_k(w, x) = \sigma(a_k^{(2)}), \tag{7}$$

где $\tilde{f}_k(w, x)$ — компоненты вектора $\tilde{f}(x) \in \mathbb{R}^n$. В случае, если методом нейронной сети решается задача регрессии, то $\tilde{f}_k(w, x) = a_k^{(2)}$.

Таким образом, преобразование, задаваемое двухслойным перцептроном, имеет вид:

$$\tilde{f}_k(x, w) = \sigma\left(\sum_{j=1}^{n} w_{kj}^{(2)} h\left(\sum_{i=1}^{m} w_{ji}^{(1)} x_i + w_{j0}^{(1)}\right) + w_{k0}^{(2)}\right), \tag{8}$$

Множество всех весов и параметров смещения образуют вектор параметров w, значения компонент которого подбираются на стадии обучения нейронной сети.

Для задач классификации с количеством классов большим двух используется обобщение логистической функции для многомерного случая — *функция мягкого максимума* (англ. *softmax*) $\bar{\sigma}(t) : \mathbb{R}^k \to \mathbb{I}^k$, преобразующая вектор $t = (t_1, \ldots, t_k)$ в вектор $\bar{\sigma}(t) = (\bar{\sigma}_1(t), \ldots, \bar{\sigma}_k(t))$ той же размерности, где

$$\bar{\sigma}_i(t) = \frac{e^{t_i}}{e^{t_1} + \ldots + e^{t_K}}.$$

$\bar{\sigma}_i(t) \in [0,1]$ для $i = \overline{1,k}$, $\sum_{i=1}^{k} \bar{\sigma}_i(t) = 1$. Значение компоненты $\bar{\sigma}(t)_i$ интерпретируется как вероятность того, что объект принадлежит i-му классу.

Нейронная сеть прямого распространения задаёт нелинейную функцию от входных переменных x_i, зависящую от получаемого в ходе стадии обучения вектора параметров w. Это преобразование может быть представлено в виде ориентированного графа.

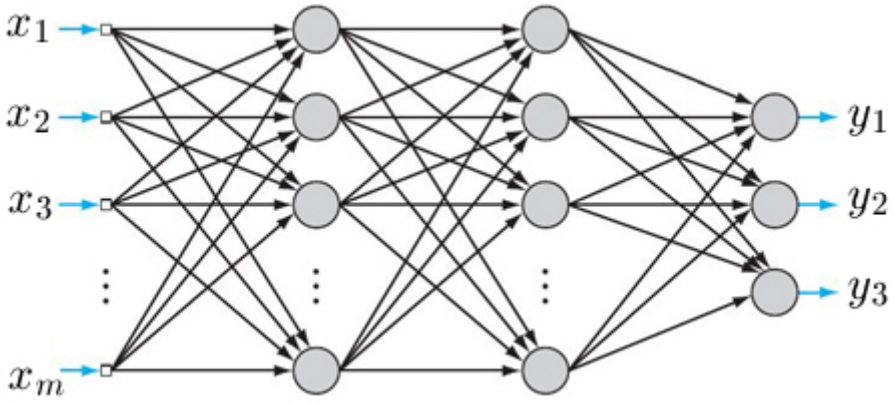


Рис. 5.6: Граф нейронной сети.

Для ориентированного графа нейронной сети вершины — нейроны — соответствуют входам сети, на которые подаются значения переменных x, *скрытым узлам* $z_j^{(k)}$, и выходам y. Параметры w задают веса дуг (ориентированных рёбер) графа нейронной сети. Дуги графа ориентированы в соответствии с направлением распространения данных по нейронной сети от её входов к выходам.

Слой нейронной сети — это множеств равноудалённых от входов нейронов, к которым ведут дуги с модифицируемыми в ходе обучения весами. Слои скрытых узлов называются *скрытыми слоями*. Для нейронной сети прямого распространения дуги могут быть ориентированы только от k-го слоя к $(k+1)$-му. Нейронная сеть прямого распространения называется *n-слойной*, если количество слоёв равно n. При подсчёте количества слоёв нейронной сети входной слой обычно не учитывается. На рис. 5.6 изображён 3-слойный перцептрон, задающий преобразование $x \in \mathbb{R}^m$ в $y \in \mathbb{R}^3$.

Параметры смещения в (4) могут быть включены в множество весовых параметров определением дополнительных фиктивных входных переменных x_0 с фиксированными значениями $x_0 = 1$. В результате, (4) при-

нимает вид

$$a_j^{(1)} = \sum_{i=0}^{m} w_{ji}^{(1)} x_i.$$

Включая также в вектор весов $w^{(2)}$ параметры смещения для второго слоя в (6), преобразование, задаваемое построенным нами двухслойным перцептроном, может быть представлено в виде

$$y_k(x, w) = \sigma\left(\sum_{j=0}^{M} w_{kj}^{(2)} h\left(\sum_{i=0}^{m} w_{ji}^{(1)} x_i\right)\right), \tag{9}$$

где w объединяет $w^{(1)}$ и $w^{(2)}$.

5.3 Выбор функции активации

В качестве функций активации как для скрытых слоёв, так и для выходного слоя могут быть выбраны сигмоидальные функции — дифференцируемые аналоги ступенчатой функции. *Сигмоидальная функция* — это ограниченная дифференцируемая вещественная функция, которая определена для всех вещественных входных значений и имеет неотрицательную производную в каждой точке и ровно одну точку перегиба. На рис. 5.7 приведены графики сигмоидальных функций — сигмоиды

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

и гиперболического тангенса

$$\tanh(x) = \frac{1}{e^x + e^{-x}}.$$

Ограниченность сигмоидальных функций препятствует взрывному росту значений нейронов сети и способствует устойчивости вычислений в нейронной сети. Кроме того, производные σ и tanh могут быть вычислены через сами эти функции, что повышает точность вычислений на ЭВМ.

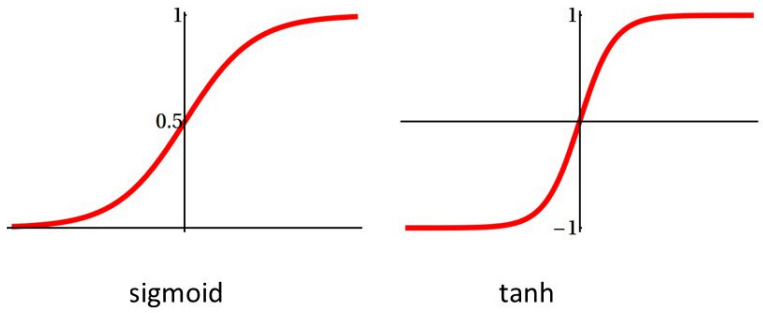


Рис. 5.7: Сигмоида и гиперболический тангенс

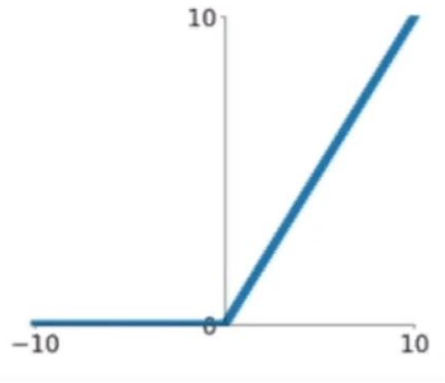


Рис. 5.8: Усеченное линейное преобразование (ReLU)

В настоящее время благодаря своему удобству для численной реализации нейронных сетей и алгоритмов их обучения в скрытых слоях нейронной сети чаще всего используется *усеченное линейное преобразование*, или ReLU (от англ. *Rectified Linear Unit)*:

$$\varphi(x) = \max\{0, x\}.$$

Функция $\varphi(x)$ — это нелинейная функция, дифференцируемая всюду, кроме нуля. При расчётах можно положить $\varphi'(0) \stackrel{def}{=} 0$. Возможно использование параметризованной линейной усечённой функции

$$\varphi(x) = \max\{0, \alpha x + \beta\}.$$

Заметим при этом, что функции активации — это гиперпарметр нейронной сети, и параметры α и β в этом случае не меняются в ходе обучения.

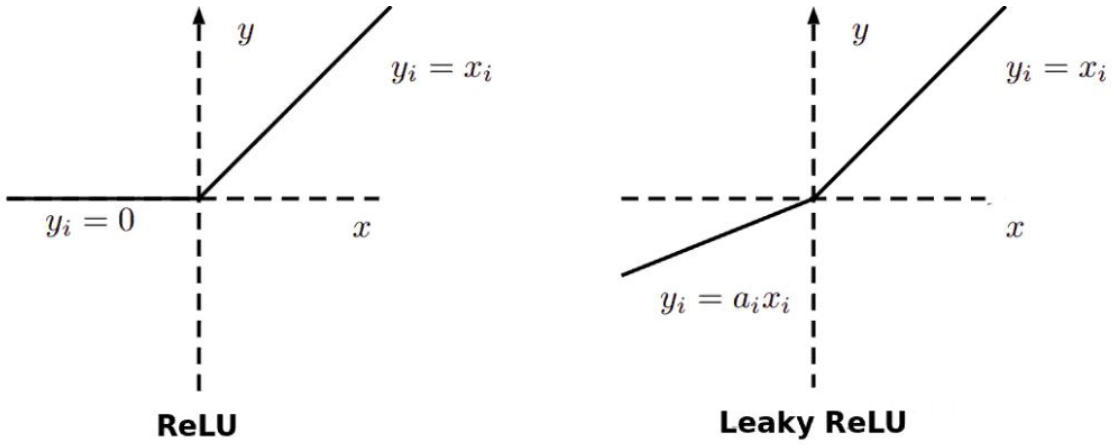


Рис. 5.9: Модифицированное усечённое линейное преобразование.

Для вычисления значения нейронной сети для данного входа x и обучения нейронной сети, необходимо многократно вычислять значения функции активации для нейронов сети и их производные. Как $\varphi(x)$, так и $\varphi'(x)$ вычисляются быстрее, чем значения функции и производной от неё для σ и $\tanh$ в x. Кроме того, использование φ позволяет избавиться от проблемы исчезновения градиента, рассматриваемой далее. Поскольку производные φ постоянны и их произведение не может быть близким к нулю, это не приводит к занулению компонент градиента функции ошибки в ходе обучения. Тогда как для сигмоидальных функций с ростом абсолютного значения x производные становятся близки к нулю, что может приводить к занулению компонент градиента функции.

При входе, зануляющем значение функции φ, получаем зануление и её производной. Это приводит к тому, что многие компоненты матриц и векторов *(тензоров)*, которые используются при вычислениях при обучении сети, становятся нулевыми. Что позволяет использовать при вычислениях процедуры для работы с разреженными данными, существенно снижая время, которое требуется для обучения нейронной сети.

В то же время в этой связи возможна проблема *мёртвого нейрона*: нейрон имеет нулевое значение, не изменяющееся в ходе обучения. Для уменьшения количества мёртвых нейронов может быть использовано модифицированное усечённое линейное преобразование *(Leaky ReLU)* (рис. 5.9). Для такой функции активации значение её параметра a_i малое, $a_i > 0$, но ненулевое.

5.4 Обучение нейронной сети

Стадия обучения нейронной сети состоит в нахождении таких весов дуг графа нейронной сети, при которых минимизируется значение функции ошибки $E(w)$ на обучающей выборке $\{x^{(i)}, y^{(i)}\}_{i=1}^{N}$:

$$E(w) = \sum_{i=1}^{N} E_i(w), \tag{10}$$

где

$$E_i(w) = \frac{1}{2}\left\| y\left(w, x^{(i)}\right) - y^{(i)} \right\|^2,$$

$\|\cdot\|$ — евклидова норма вектора.

$E(w)$ — дифференцируемая по всем компонентам w функция. Её минимальное значение достигается на *глобальном минимуме* $w_{\min}$. Под *локальным минимумом* понимается такое значение w, для которого значение $E(w)$ является минимальным в некоторой его окрестности.

Обучение нейронной сети представляет собой выполнение заданного количества этапов обучения. В ходе каждого из этапов обучения нами задаётся случайным образом выбранное начальное значение вектора весов w, модифицируя которое в ходе итераций этапа, мы получаем локальный минимум функции ошибки. Проведя T этапов обучения и найдя T локальных минимумов $w_{\min}^{(i)}$ $(i = \overline{1,T})$, мы выбираем из них такой $\tilde{w}$, что

$$E(\tilde{w}) = \min_{1 \le i \le T} E\left(w_{\min}^{(i)}\right),$$

при этом, вообще говоря, $E(\tilde{w}) \neq E(w_{\min})$, и представляем $\tilde{w}$ как результат обучения нейронной сети. Либо, найдя такой локальный минимум $w_{\min}^{(i)}$ функции ошибки, в котором $E\left(w_{\min}^{(i)}\right) \le \delta$ для заданного на старте стадии обучения малого значения $\delta > 0$, завершаем на этом обучение и представляем $w_{\min}^{(i)}$ как его результат.

На рис. 5.10 схематично показан поиск локального минимума на i-ом этапе обучения. $w_{\min}^{(i)}$ — локальный минимум на i-м этапе обучения, $w^{(i,0)}$ — начальное значение вектора параметров w на старте i-го этапа обучения, $w^{(i,j)}$ — значение вектора параметров на j-ой итерации i-го этапа стадии обучения.

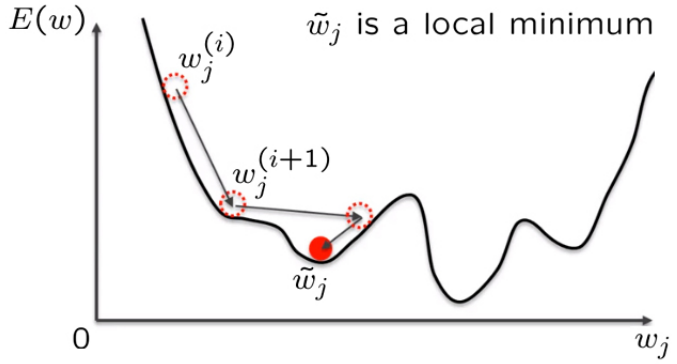


Рис. 5.10: Градиентный спуск к локальному минимуму на .

Отметим, что в связи с ошибками вычислений и в связи с возможно слишком большим для перебора количеством локальных минимумов $E(w)$, мы можем находить значения $w_{\min}^{(i)}$ только лишь близкие к локальным минимумам. Однако, во многих случаях это оказывается достаточным для эффективного применения многослойного перцептрона.

Рассмотрим i-й этап стадии обучения нейронной сети. Случайным образом выберем $w^{(i,0)} = \left(w_1^{(i,0)}, \ldots, w_M^{(i,0)}\right)$, где M — количество дуг нейронной сети. Будем минимизировать функцию ошибки, последовательно смещаясь в множестве возможных значений весов в $\mathbb{R}^M$ по направлению к ближайшему локальному минимуму функции ошибки. Смещение от произвольного заданного $w^{(i,0)}$ к локальному мимнимуму происходит в соответствии с антиградиентом функции ошибки, то есть вектором, направленным противоположно её градиенту.

По формуле Тэйлора для малых значений $||\delta w||$ значение функции ошибки в точке $w + \delta w$ может быть представлено как

$$\delta E(w) \approx \delta w^{\top} \nabla E(w),$$

где

$$\nabla E(w) = \left(\frac{\partial E}{\partial w_1}(w), \ldots, \frac{\partial E}{\partial w_m}(w)\right)$$

— градиент функции ошибки в точке $w \in \mathbb{R}^m$. Для дифференцируемой функции $E(w)$ локальный минимум, получаемый на i-м этапе обучения, достигается в точке $w_{\min}^{(i)} \in \mathbb{R}^m$ такой, что $\nabla E(w_{\min}^{(i)}) = 0$.

Пусть K — количество смещений по направлениям, задаваемым антиградиентами функции ошибки, в ходе одного этапа обучения, η $(\eta > 0)$

— *коэффициент обучения*, задающий величину этого смещения в $\mathbb{R}^m$ от точки $w^{(i,k)}$ к точке $w^{(i,k+1)}$:

$$w^{(i,k+1)} = w^{(i,k)} - \eta \nabla E(w^{(i,k)}). \tag{11}$$

η — параметр процедуры обучения нейронной сети, значение которого должно быть задано так, чтобы в ходе обучения смещение от $w^{(i,k-1)}$ к $w^{(i,k)}$ было достаточно большим для достижения значения вектора весов близкого к локальному минимуму функции ошибки за относительно небольшое число шагов. Вместе с тем, оно должно быть достаточно малым, чтобы, имея $w^{(i,k-1)}$ близкое к локальному минимуму $w_{\min}^{(i)}$, полученное в соответствии с (11) значение $w^{(i,k)}$ не оказалось снова удалённым от него.

Инициализировав значение $w_{\min}$ произвольным большим значением и положив значение δ близким к 0, будем выполнять T этапов обучения нейронной сети:

Этап стадии обучения нейронной сети

1. Случайным образом сгенерировать начальное значение вектора весов $w^{(i,0)}$.
2. Для k от 1 до K выполнять:
   2.1). Вычислить $\nabla E(w^{(i,k-1)})$.
   2.2). Положить $w^{(i,k)} = w^{(i,k-1)} - \eta \nabla E(w^{(i,k-1)})$.
   2.3). Если $E(w^{(i,k)}) \leq \delta$, положить $w_{\min} = w^{(i,k)}$. Завершить стадию обучения.
   2.4). Иначе перейти к следующему значению k.
3. Положить $w_{\min}^{(i)} = w^{(i,K)}$.
4. Если $E(w_{\min}^{(i)}) < E(w_{\min})$, положить $w_{\min} = w^{(i,K)}$.

Заметим, что если в ходе i-го этапа обучения для некоторого k нами получено значение $w^{(i,k)}$ такое, что $E(w^{(i,k)}) \leq \delta$, то количество проведённых этапов обучения будет меньшим T.

Используемый нами подход для поиска локальных минимумов функции ошибки является реализацией *метода градиентного спуска* [**?**].

5.5 Вычисление градиента функции ошибки

5.5.1 Приближённое вычисление

Градиент функции ошибки, который требуется находить на этапах стадии обучения, может быть рассчитан приблизительно, используя *разностную схему* для вычисления частных производных $E(w)$ [?, ?]. В соответствии с ним их значения могут быть приближённо вычислены как

$$\frac{\partial E}{\partial w_i}(w) \approx \frac{E(w_i + \delta_i) - E(w_i)}{\delta w_i}. \tag{12}$$

где δ_i обозначает приращение i-ой компоненты вектора w, а под $E(w_i)$ понимается значение $E(w_1, \ldots, w_i, \ldots, w_m)$, под $E(w_i + \delta_i)$ — значение $E(w_1, \ldots, w_i + \delta_i, \ldots, w_m)$. Правая часть в (12) тем ближе к значению частной производной в точке $w^{(k)}$, чем меньше значение δ_i. Погрешность такого нахождения частной производной для малых значений δ_i составляет $O(\delta_i)$.

Используя *центральную разностную схему*, значения частных производных $E(w)$ могут быть приближённо вычислены как

$$\frac{\partial E}{\partial w_i}(w) \approx \frac{E(w_i + \delta_i) - E(w_i - \delta_i)}{2\delta_i}.$$

Значение ошибки нахождения частной производной для малых значений δ_i при этом составит $O(\delta_i^2)$.

При приближённом вычислении частных производных $E(w)$ надо учитывать, что для слишком малых значений δ_i ошибки округления при вычислениях на компьютере могут быть сравнимы или больше самого δ_i.

Для нахождения градиента функции ошибки используется рассматриваемый нами далее метод обратного распространения ошибки, позволяющий для нейронных сетей находить градиент с необходимой точностью быстрее, чем приближённые вычисления по формулам частных производных. Однако непосредственное вычисление приближённых значений может быть использовано для тестирования численной реализации метода обратного распространения ошибки.

5.5.2 Метод обратного распространения ошибки

Метод обратного распространения ошибки — это метод вычисления градиента $E(w)$ с учётом специфики преобразования входных переменных, задаваемых нейронной сетью [27, 28, 29]. Под *обратным распространением ошибки* понимается последовательное нахождение частных производных $E(w)$ по весам w_i дуг графа k-слойной нейронной сети, входящих в j-й слой нейронной сети, используя значения частных производных $E(w)$, найденные для следующего $(j+1)$-го слоя, $j = \overline{1, k-1}$. Для этого в обратном порядке, начиная с k-го слоя — с выходов нейронной сети, производим вычисление частных производных $\partial E/\partial a_j$ по узлам нейронной сети. В случае регресии для последнего k-го слоя это значение по модулю равно суммарной абсолютной ошибке $|\tilde{f}(x^{(i)}) - y^{(i)}|$ по точкам выборки, используемым для получения градиента *(батча)*.

Рассмотрим далее нахождение методом обратного распространения ошибки градиента функции $E(w)$ для восстановления функциональной зависимости $f : X \to \mathbb{R}$ с помощью многослойного перцептрона. С целью упрощения обозначений, будем далее обозначать как a_j некоторую из функций $a_j^{(k)}$, а как z_i — функцию $z_i^{(k-1)}$, реализуемую на предыдущем слое.

Функциональное преобразование, задаваемое нейронной сетью, состоит из последовательного получения значений a_j и z_j, рассчитываемых по формулам вида (4) и (5) для всех слоёв нейронной сети. То есть сначала мы находим значения функции

$$a_j = \sum_{i=1}^{M} w_{ij} z_i. \tag{13}$$

a_j — взвешенная сумма M входов нейрона, w_{ij} — веса, соспоставляемые входным дугам нейрона, для которого вычисляется значение a_j. После чего получаем z_j:

$$z_j = h(a_j). \tag{14}$$

(z_j обозначает $z_j^{(k)}$.)

Последовательное выполнение таких вычислений для всех слоёв нейронной сети производится на этапе прямого распространения. В случае регрессии значение z_j, рассчитанное для внешнего слоя, является выходом задаваемого нейронной сетью преобразования.

Нахождение градиента функции ошибки $E(w)$ в точке w с помощью метода обратного распространения состоит из двух этапов:

1). Этап прямого распространения для вычисления $E(w)$: используя (13) и (14), вычисляем $E_n(w)$ для всех $x^{(n)}$ из выборки, после чего вычисляем $E(w)$.

2). Этап обратного распространения ошибки: находим $\partial E_n/\partial w_{ij}$. Поскольку, как следует из вида функционального преобразования, задаваемого нейронной сетью,

$$\frac{\partial E_n}{\partial w_{ij}} = \frac{\partial E_n}{\partial a_j}\frac{\partial a_j}{\partial w_{ij}}. \tag{15}$$

Будем определять частные производные функции ошибки, начиная с весов рёбер, инцидентных крайнему правому (выходному) слою в графе нейронной сети.

Из (13) имеем:

$$\frac{\partial a_j}{\partial w_{ij}} = z_i.$$

Полагая

$$\delta_j = \frac{\partial E_n}{\partial a_j},$$

получаем:

$$\frac{\partial E_n}{\partial w_{ij}} = \delta_j \cdot z_i.$$

Метод обратного распространения ошибки состоит в вычислении значений δ_j, исходя из обратного распространения по нейронной сети ошибки δ_1 на выходном слое. Получая значения δ_j и используя значения z_i, рассчитанные на этапе прямого распространения, мы можем найти частные производные по весам дуг, входящих в скрытые узлы текущего слоя. После чего можем перейти к расчёту производных по весам дуг предыдущего слоя.

В случае, если с помощью нейронной сети производится регрессия с функцией ошибки (10), то есть $f : X \to \mathbb{R}$, для выходов сети будем иметь:

$$E_n(w) = \frac{(y^{(n)} - \tilde{f}(w, x^{(n)}))^2}{2} = \frac{(y^{(n)} - a_1(w, x^{(n)}))^2}{2}.$$

В этом случае δ_1 находится следующим образом:

$$\delta_1 = \frac{\partial E_n}{\partial a_1} = \frac{1}{2}\frac{\partial (y^{(n)} - \tilde{f}(w, x^{(n)}))^2}{\partial a_1} =$$

$$= \big(y^{(n)} - \tilde{f}(w, x^{(n)})\big)\frac{\partial \tilde{f}(w, x_n)}{\partial a_1} = (y^{(n)} - \tilde{f}(w, x^{(n)}))\frac{\partial a_1(w, x^{(n)})}{\partial a_1(w, x^{(n)})} =$$

$$= (y^{(n)} - \tilde{f}(w, x^{(n)})),$$

где значение $\tilde{f}(w, x^{(n)})$ рассчитывается в ходе процедуры прямого распространения. То есть δ_1 равно ошибке предсказания в точке выборки, которая будет распространяться нами по сети последовательно через все скрытые слои от выходного слоя к входному.

Для скрытых элементов какого-либо слоя, при рассчитанных частных производных по весам дуг для последующего слоя, находим значения δ_j для нейронов текущего слоя:

$$\delta_j = \frac{\partial E_n}{\partial a_j} = \sum_{k=1}^{M'} \frac{\partial E_n}{\partial a_k}\frac{\partial a_k}{\partial a_j}, \tag{16}$$

где суммирование производится по всем M' исходящим из a_j дугам. Из (13) для значений a_j с текущего слоя

$$\frac{\partial a_k}{\partial a_j} = h'(a_j)w_{jk},$$

и (16) эквивалентно:

$$\delta_j = h'(a_j)\sum_{k=1}^{M'} \delta_k w_{jk}. \tag{17}$$

Используя найденные значения δ_k, находим значения δ_j для дуг, инцидентных скрытым элементам предшествующих слоёв.

Метод обратного распространения ошибки может применяться как для регрессии, так и для классификации. Метод не имеет настраиваемых параметров и может применяться для различных архитектур нейронных сетей. Нахождение градиента в соответствии с графом, задающим архитектуру нейронной сети, позволяет добиваться необходимой для обучения скорости и точности вычислений.

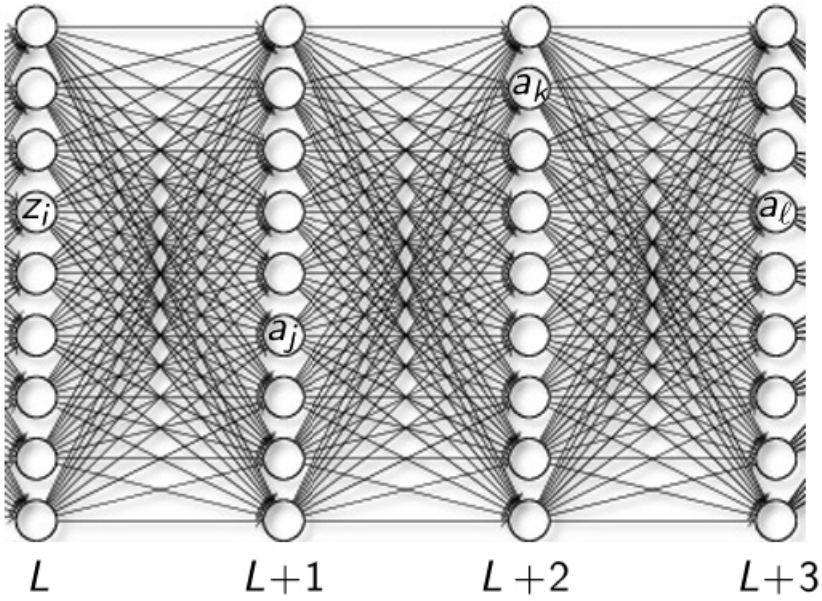


Рис. 5.11: Нейроны из чётырёх последовательных слоёв нейронной сети

5.6 Взрыв и исчезновение градиента

Как показано выше,

1) ошибка δ_1 в выходном слое зависит от производной используемой на нём функции активации, если проризводится классификация;
2) из (17) следует, что значения δ_j в нейронах слоя нейронной сети пропорциональны весам, значениям δ_i в следующем за ним слое и производной функции активации h;
2) частные производные $\partial E_n/\partial w_{ij}$ для дуг любого слоя зависят от произведений производных для последующих скрытых слоев.

Таким образом для нейронных сетей с большим количеством слоёв для функций активации σ и $\tanh$ для вычисления частных производных $\partial E_n/\partial w_{ij}$ будет производиться умножение большого количества множителей близких к нулю, что влечёт близость к нулю частных производных.

Пусть для некотрого L-го слоя z_i — нейрон из L-го слоя, a_j — значение, из которого применением функции активации получаем значение неёрона из L+1-го слоя, a_k — из L+2-го слоя, a_l — из L+3-го слоя. Имеем:

$$\frac{\partial E}{\partial w_{ij}} = \frac{\partial E}{\partial a_j}\frac{\partial a_j}{\partial w_{ij}} = \frac{\partial E}{\partial a_j} \cdot z_i.$$

Как показано выше,

$$\frac{\partial E}{\partial a_j} = \sum_{k=1}^{Q} \frac{\partial E}{\partial a_k} \frac{\partial a_k}{\partial a_j},$$

где Q — количество нейронов в одном слое.

$$\frac{\partial E}{\partial a_k} = \sum_{\ell=1}^{Q} \frac{\partial E}{\partial a_\ell} \frac{\partial a_\ell}{\partial a_k}.$$

$$\frac{\partial a_k}{\partial a_j} = \left(\sum_{t=1}^{Q} w_{jk} h(a_t) \right)' = w_{jk} h'(a_j),$$

где a_t — значения из $L+1$-го слоя.

$$\frac{\partial a_\ell}{\partial a_k} = \left(\sum_{t=1}^{Q} w_{k\ell} h(a_t) \right)' = w_{k\ell} h'(a_j),$$

где a_t — значения из $L+2$-го слоя. Следовательно,

$$\frac{\partial E}{\partial w_{ij}} = \frac{\partial E}{\partial a_j} \cdot z_i = \left(\sum_{k=1}^{Q} \frac{\partial E}{\partial a_k} \frac{\partial a_k}{\partial a_j} \right) z_i = \left(\sum_{k=1}^{Q} \left(\sum_{l=1}^{Q} \frac{\partial E}{\partial a_\ell} \frac{\partial a_\ell}{\partial a_k} \right) \frac{\partial a_k}{\partial a_j} \right) z_i =$$

$$= \left(\sum_{k=1}^{Q} \left(\sum_{l=1}^{Q} \frac{\partial E}{\partial a_\ell} w_{k\ell} h'(a_k) \right) w_{jk} h'(a_j) \right) z_i =$$

$$= \left(\sum_{k=1}^{Q} \left(\sum_{l=1}^{Q} \frac{\partial E}{\partial a_\ell} w_{k\ell} h'(a_k) \right) w_{jk} h'(a_j) \right) z_i =$$

$$= \left(\sum_{k=1}^{Q} \left(\sum_{l=1}^{Q} \frac{\partial E}{\partial a_\ell} (w_{k\ell} w_{jk}) (h'(a_k) h'(a_j) \right) \right) z_i,$$

и так далее.

По мере продвижения к последнему M-му слою многослойного перцептрона, получим:

$$\frac{\partial E}{\partial w_{ij}} = \left[\sum_{k_L=1}^{Q} \sum_{k_{L+1}=1}^{Q} \cdots \sum_{k_M=1}^{Q} \left[\frac{\partial E}{\partial a_1} \left(\prod w_{kl} \right) \left(\prod h'(a_k) \right) \right] \right] z_i, \qquad (18)$$

где произведение производится по рёбрам всех ориентирванных цепей в графе нейронной сети, соединяющих нейрон z_i и a_1, суммирование производится по всем слоям нейронной сети, через нейроны которого проходит эта цепь.

Под *исчезновением градиента* понимается такая ситуация, когда компоненты градиента функции ошибки *«исчезают»* в ходе обучения, то есть значения частных производных, связанных с нейроном, становятся близки к нулю. Следствием такой ситуации является то, что первые слои нейронной сети меняются медленнее, чем остальные. В результате чего на обучение первых слоёв (подбор весов для них) тратится существенно больше времени.

Под *взрывом градиента* понимается ситуация, когда компоненты градиента функции ошибки становятся слишком большими, что приводит к нестабильному поведению нейронной сети после обновления. Это выражается в том, что изменение весов нейронной сети производится хаотически, а не в соответствии с поверхностью функции ошибки в окрестности точки w текущих значений весов нейронной сети.

Взрыв и исчезновение градиента — проблемы, возникающие при обучении глубоких нейронных сетей, имеющих большое количество слоёв. Без преодоления этих проблем обучение таких сетей невозможно. Далее мы познакомимся с подходами по устранению этих проблем в глубоких нейронных сетях.

5.7 Аппроксимационные возможности нейронных сетей

Возможности использования нейронных сетей прямого распространения для аппроксимации функций широко изучались. Так, например, в [25] показано, что при использовании гладкой нелинейной функции в качестве функции активации, любая непрерывная функция от произвольного числа переменных может быть аппроксимирована нейронной сетью с произвольной точностью. Так называемая «универсальная теорема аппроксимации» [26] утверждает, что с помощью нейронной сети прямого распространения с сигмоидальными функциями активации и одним скрытым слоем, содержащим конечное число нейронов, может быть сколь угодно

точно аппроксимирована любая непрерывная функция на компактном подмножестве $\mathbb{R}^m$. Доказано множество вариантов таких теорем с различными условиями на архитектуру нейронной сети.

Хотя такие результаты выглядят весьма обнадёживающе, выполнение стадии обучения нейронных сетей во многих прикладных задачах регрессии и классификации требует значительных затрат вычислительных ресурсов и времени, требуемого для обучения, и потому не всегда может быть реализовано на практике.

5.8 Задания

1. Важен ли порядок, в котором пронумерованы векторы признаков из обучающей выборки для алгоритма обучения, предложенного в доказательстве теоремы о сходимости перцептрона?
2. Покажите, что если сходимость алгоритма будет иметь место для значения коэффициента обучения равного 1, то сходимость будет иметь место и при меньших значениях η, но потребует большего количества итераций.
3. Доказательство сходимости алгоритма обучения перцептрона было проведено нами в предположении, что $x(n) \in \mathcal{H}_1$ и классификация производится неверно на всех итерациях вплоть до $(n+1)$-ой. Покажите, что при других возможных промежуточных результатах работы алгоритма обучения перцептрона к $(n+1)$-ой итерации (имеются итерации, на которых классификация производится верно, выбираемые из выборки в соответствии с введённой нумерацией векторы признаков принадлежат классу $\mathcal{H}_2$), проведённые нами рассуждения достаточны для того, чтобы утверждать о сходимости алгоритма обучения.
4. Пусть обучающая выборка состоит из одного элемента $\{x, +1\}$. Предположим, что начальные значения весов для элементарного перцептрона выбираются случайно в соответствии с равномерным распределением на интервале $[0, 1]$. Сколько в среднем неверных классификаций подряд может быть произведено при выполнении алгоритма обучения? Под средним понимается математическое ожидание. Как оно зависит от $\|x\|$? Покажите, что чем меньше коэф-

фициент обучения, тем оно больше.

5. Покажите, что если в качестве функции активации используется линейная функция, то преобразование, задаваемое такой нейронной сетью будет линейным.
6. Покажите, что в случае использования линейных функций активации, если количество скрытых узлов нейронной сети меньше количества входов или выходов сети, то, линейное преобразование, задаваемое такой нейронной сетью, имеет меньшую размерность, чем размерность входа или выхода.
7. Рассмотрим нейронную сеть с линейными функциями активации, в которой допустимы дуги, соединяющие узлы из разных слоёв. Покажите, что для ограниченных входных значений такая сеть эквивалентна многослойному перцептрону с линейными скрытыми узлами, то есть со скрытыми узлами, в которых значения z_j получаются с помощью линейных функций.
8. Найдите производные логистического сигмоида и гиперболического тангенса. Почему использование таких функций активации удобно использовать при реализации метода обратного распространения?
9. Реализуйте программно алгоритм обучения элементарного перцептрона для распознавания растровых изображений. Можете использовать следующие варианты реализации:
   а) 10 элементарных перцептронов, классифицирующих цифры как цифры двух классов: *эта цифра/другая цифра*;
   б) один перцептрон, вместо ступенчатой функции использующий в качестве функции активации функцию мягкого максимума, обучаемый с помощью стохастического градиентного спуска.

   Может быть использована обучающая выборка для заданий 3 и 4 главы 3.6 «Задания» раздела «Метод ближайшего соседа».
10. Сформируйте ансамбль из обученных элементарных перцептронов из предыдущего задания. Сравните для одной и той же выборки результаты классификации растровых изображений с результатами, полученными методом ближайшего соседа и с помощью отдельного классификатора из предыдущего задания.
11. Реализуйте программно восстановление функциональной зависимости с помощью многослойного перцептрона с одним и двумя сло-

ями и количеством скрытых узлов в каждом из слоёв от одного до трёх. Для этого

а) в качестве распознаваемых функциональных зависимостей используйте следующие:
$y = \cos(2\pi x)$, $y = 5x^3 + x^2 + 5$, $y = x\sin(2\pi x)$, $x \in [0, 1]$;

б) сгенерируйте выборку, моделируя ошибку измерения как нормально распределённую случайную величину, и проведите процедуру кросс-валидации для определения наилучшего для распознавания количества слоёв и скрытых узлов в них.

6 Деревья решений

6.1 Категориальные и некатегориальные признаки

До этой главы компоненты рассматриваемых векторов признаков предполагались вещщественными числами. Однако, не всегда признак может быть охарактеризован числом. Вообще говоря, признаки объектов, которые могут быть использованы для решения задач машинного обучения, могут быть двух типов:

а) *порядковые* признаки, для векторов которых может быть задана мера близости;

б) *категориальные* (качественные) признаки, которые представляют собой значения неупорядоченных именованных переменных (атрибутов), задающих категории внутри группы; векторы таких признаков, в общем случае, упорядочить нельзя.

Примерами порядковых признаков являются длина, ширина некоего объекта, острота зрения. Примерами категориальных признаков могут служить пол, род существительного, время глагола. В этом случае вектор признаков может рассматриваться скорее не геометрически, как вектор, а как список атрибутов объекта.

Для объяснения подхода, представляемого деревьями решений к задачам машинного обучения, будем рассматривать деревья решений как подход к решению задачи классификации.

Деревья решений в обоих случаях выступают как естественный подход к классификации, производимой через получение ответов на последовательность вопросов о признаках (атрибутах) вектора-элемента выборки, в которой каждый последующий вопрос зависит от ответа на текущий. Такой подход не является *метрическим* методом классификации, при котором может быть задано расстояние (метрика) на множестве объектов, или мера близости, что тоже относит использующий её подход к метриче-

ским. Элементы выборки классифицируются исходя из их близости друг к другу. Последовательность вопросов о признаках классифицируемого вектора признаков и возможных ответов представляется в виде графа — *дерева решений*, а решение задачи калассификации представляет собой переход по вершинам дерева *(узлам)* от корневой вершины этого дерева до некоторого его листа. Главные принципы этого подхода могут быть сформулированы следующим образом:

1) последовательно разбиваем выборку на подмножества исходя из значений признаков, последовательно проверяемых по-отдельности или группами, или один за другим;
2) итоговые подмножества, полученные в результате таких разбиений, представляют собой подвыборку исходной, преимущественно состоящую из элементов некоторого класса, которому принадлежит классифицируемый объект.

Таким образом, *дерево решений* — это дерево, каждый узел которого соответствует некоторому вопросу о значении признака, задаваемого компонентой (или компонентами) входного вектора признаков классифицируемого объекта. То есть это дерево классификаторов, соответствующих каждому узлу дерева, таких что если задана обучающая выборка S, то i-му узлу дерева решений соответствует некоторая её подвыборка $S_i \subset S$. При этом корневой вершине — первому уровню дерева решений — сответствует вся выборка S, её потомкам на втором уровне двоичного дерева решений — две подвыборки S: выборки S_1 и S_2 такие, что $S_1 \cap S_2 = \varnothing$, $S_1 \cup S_2 = S$, вершинам третьего уровня — 4 подвыборки S и т.д. Подвыборки, получаемые в результате многократных разбиений исходной и соответствующие листьям, в основном, должны содержать элементы одного класса.

Процедура обучения дерева решений, то есть процедура получения представляемого им классификатора, определяется ответами на следующие вопросы:

1. Сколько значений может принимать каждый признак?
2. Какой признак должен проверяться в текущем узле графа?
3. В каком случае узел должен быть объявлен листом?
4. Если дерево становится слишком разветвлённым, как его упростить? С какого уровня можно отсечь некоторую его ветвь (*англ. pruning*)?

5. Если лист всё-таки содержит элементы выборки, принадлежащие разным классам, как назначать класс при прогнозировании?
6. Что делать в случае, если значения некоторых признаков в векторе признаков не определены?

Будем далее рассматривать задачу классификации с порядковыми признаками векторов признаков. Категориальные признаки могут быть численно закодированы и классифкаторы узлов дерева решений могут быть представлены как проверка равенства признака некоторому числовому значению. Однако, при этом мы не подразумеваем наличие какой-либо меры близости или как-либо определённого расстояния, исходя из которых мы разбиваем выборку на подвыборки.

Классификаторы, соответствующие узлам дерева решений, могут быть следующих типов.

I. *Покоординатные*, то есть задающие гиперплоскости параллельные координатным осям, разделяющие множество возможных признаков. Главное их преимущество состоит в том, что параметры этих классификаторов легко вычислимы ввиду возникающих при их определении одномерных оптмизационных задач. В этом случае дерево называется *монотетичным* (англ. *monothetic tree*).

II. *Не покоординатные*, то есть производимое при такой классификации линейное или нелинейное разделение основывается на значениях некоторых совокупностей признаков — *политетичное дерево* (англ. *polythetic tree*).

Во втором случае, например, может быть использован классификатор вида

$$h(x, \theta_i) = \sigma(w^\top x),$$

то есть логистическая регрессия, с помощью которой прогнозируется вероятность принадлежности вектора признаков x заданному классу. Функциия, в соответствии с которой производится классификация — сигмоида, в данном случае нелинейна.

При построении дерева решений все используемые в его узлах классификаторы должны быть одного типа. То есть тип используемых классификаторов является гиперпараметром дерева решений.

Если в каждом узле проводится проверка выполнения неравенства вида $x_i \leq x_{is}$, то такое монотетичное дерево решений задаёт границы областей, принадлежность к которым вектора признаков определяет принад-

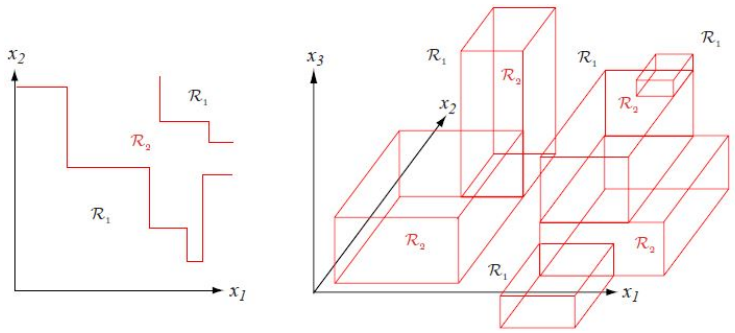


Рис. 6.1: Разделение на области $\mathcal{R}_i$ для двух классов в $\mathbb{R}^2$ и в $\mathbb{R}^3$.

лежность его тому или иному классу. Эти области выделяются в $\mathbb{R}^n$ гиперплоскостями, перпендикулярными координатным осям (рис. 6.1, 6.2).

Выбор классификаторов, используемых в дереве решений, должен соответствовать выборке в том смысле, что последовательность вопросов должна быть достаточной для эффективной классификации, не будучи слишком длинной. Если это условие не выполняется, то могут быть получены деревья, имеющие слишком большое количество вершин. Такая ситуация будет соответствовать переобучению дерева решений как классификатора (рис. 6.2) при линейном разделении с помощью набора гиперплоскостей, задаваемых деревом решений (рис. 6.3). При использовании в этом же случае обоих признаков для классификации мы получим более компактное дерево решений (рис. 6.4), то есть проведение классификации по нескольким компонентам вектора признаков позволяет разбивать обучающую выборку на подвыборки лучше.

Выбор порядка признаков, в соответствии с которым производится построение дерева решений, производится так, чтобы на каждом шаге делить выборку на максимально *однородные* подвыборки, то есть содержащие как можно больше элементов из одного класса. То есть перед построением дерева требуется некоторая предобработка данных выборки, чтобы определить такой порядок.

В случае, если листья дерева содержат элементы выборки, принадлежащие разным категориям, категория назначается по большинству элементов подвыборки, соответствующей листу.

Деревья решений представляют собой реализацию жадного подхода, то есть ему свойственнен недостаток, присущий всем методам, реализующий такой подход, а именно эффект горизонта. Под *эффектом гори-*

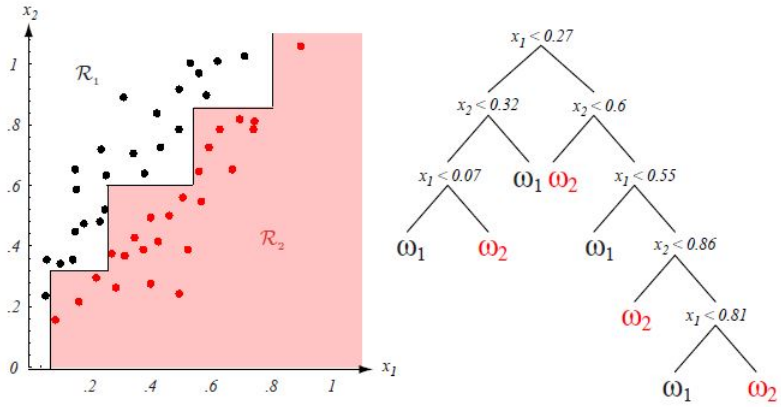


Рис. 6.2: Построение дерева решений с помощью покоординатных классификаторов.

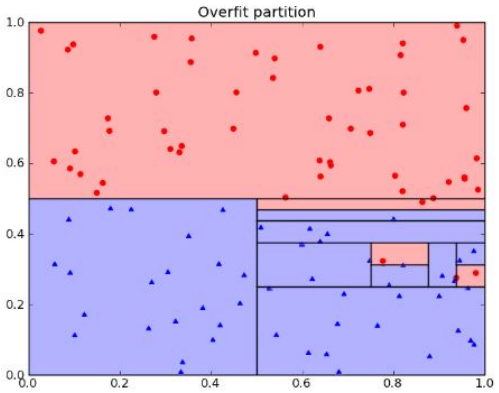


Рис. 6.3: Разбиение $\mathbb{R}^2$ для переобученного дерева решений.

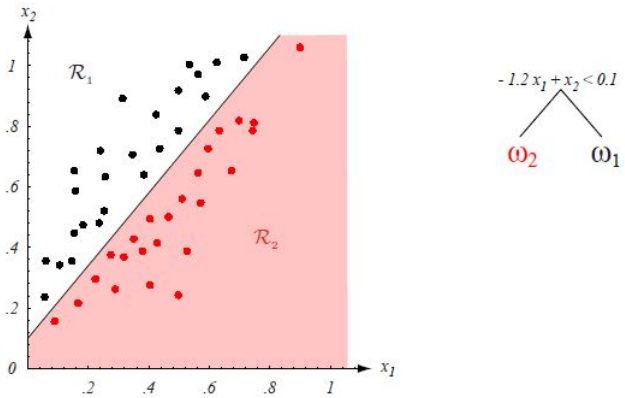


Рис. 6.4: Построение дерева решений с помощью линейных не покоординатных классификаторов.

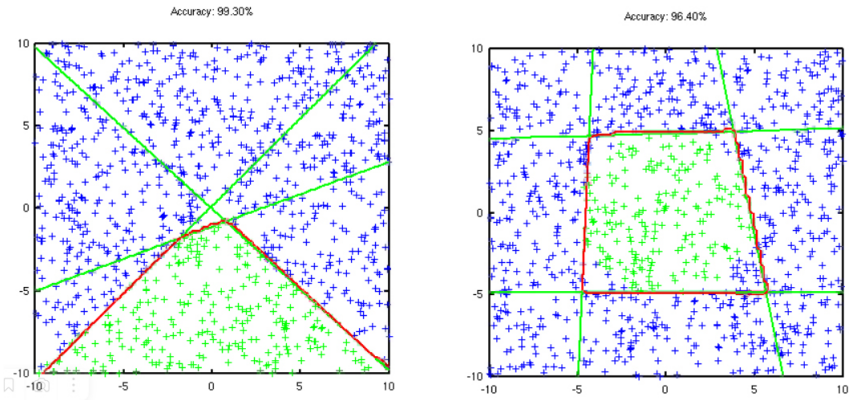


Рис. 6.5: Классификация с помощью дерева решений с не покоординатных классификаторами. Какие деревья решений соответствуют полученным разделениям $\mathbb{R}^2$ на области, соответствующие классам?

зонта понимается локальность оптимизации при производимом на каждом этапе выборе, то есть на разных стадиях оптимизация производится без учёта всей информации. При этом оптимальное разделение в одном узле может привести к неоптимальному разделению рот классификациях в последующих узлах дерева решений.

Классификация и регрессия с помощью деревьев решений предпочтительны для относительно небольших по размерности задач.

6.2 Выбор параметров классификаторов в узлах дерева решений

Пусть векторы признаков принадлежат классам $C_1, \ldots, C_K$. i-му узлу дерева решений соответствует выборка

$$S_i = S_i^{(1)} \cup \ldots \cup S_i^{(K)},$$

где $S_i^{(k)} \subset C_k$. Пусть S_{ij} — подвыборка потомка j узла i, $S_{ij} \subset S_i$, $N_i = |S_i|$, $N_{ij} = |S_{ij}|$, $N_{ij}^{(k)} = |S_{ij}^{(k)}|$ — размеры соответствующих подвыборок.

Предположим, нам дана функция $\mathcal{I}$, характеризующая неоднородность выборки по составу из элементов разных классов. Определим максимизируемое для узла дерева *увеличение однородности* как разницу между

неоднородностью подвыборки узла дерева и средней неоднородностью его потомков:

$$\Delta\mathcal{I}(S_i) = \mathcal{I}(S_i) - \sum_j \frac{N_{ij}}{N_i}\mathcal{I}(S_{ij}) \to \max_{\theta_i}. \tag{1}$$

Параметры классификаторов в узлах дерева должны быть выбраны так, чтобы ветвление в i-м узле дерева решений производилось в соответствии с максимальным уменьшением неоднородности подвыборок. Значение $\Delta\mathcal{I}(S_i)$ также называется *увеличение информации (information gain)*. Таким образом, минимизируя неоднородность S_i, мы максимизируем $\Delta\mathcal{I}(S_i)$.

Классификатор $h(x, \theta_i)$ задаёт подвыборки, соответствующие потомкам узла i. Значения θ_i для классификатора $h(x, \theta_i)$ могут быть определены одним из следующих способов:

а) если признак категориальный, то можно призводить перебор возможных значений θ_i;

б) если признак порядковый (вещественный), то может также производиться как перебор возможных значений θ_i, так и минимизация (1), например, с использованием градиентного спуска.

Если полученное оптимальное значение не единственно, то есть имеется некоторый интервал $[\theta_l, \theta_u]$, которому принадлежат оптимальные значения параметра $\theta_i \in [\theta_l, \theta_u]$, то может быть выбрано среднее значение:

$$\theta_i := (\theta_l + \theta_u)/2,$$

или взвешенное среднее значение:

$$\theta_i := \frac{N_{i1}}{N_i}\theta_l + \frac{N_{i2}}{N_i}\theta_u.$$

При этом оптимизация дерева решения как классификатора производится и как оптимизация точности классификации или регрессии, производимых с его помощью, и как оптимизация по времени вычислений, требуемых для его обучения и прогнозирования с его помощью.

6.3 Меры неоднородности выборки

По мере проведения классификаций дерева решений подвыборки S_i, соответствующие вершинам дерева, становятся *однородней* («чище», англ.

pure), то есть содержат преимущественно элементы одного класса. В том случае, когда подвыборка узла дерева поиска становится достаточно однородной, она больше не разбивается на подвыборки и объявляется листом.

Для количественного оценивания неоднородности $\mathcal{I}(S)$ (от англ. *impurity*) выборки S, как правило, используются следующие меры:

а) энтропия,
б) дисперсионная неоднородность,
в) неоднородность Джини (дисперсионная неоднородность для случая многих классов),
г) неоднородность ошибки классификации.

Пусть $\mathsf{P}_k = N_i^{(k)}/N_i$ — частота элементов k-го класса в выборке S_i. *Энтропия* выборки определяется как

$$H(S_i) = -\sum_{k=1}^{K} \mathsf{P}_k \log \mathsf{P}_k.$$

При этом логарифм может быть взят по любому основанию больше 1, и если $\mathsf{P}_k = 0$ то, полагаем $\mathsf{P}_k \log \mathsf{P}_k = 0$. В случае, если основание логарифма равно 2, то единицей измерения энтропии является бит. При классификации по одному признаку изменение энтропии для подвыборок при разбиении не может быть больше одного бита (задача 7 из раздела **Задания** к этой главе).

Используя в качестве меры неопределённости энтропию, имеем:

$$\Delta\mathcal{I} = H(S_i) - \sum_j \frac{N_{ij}}{N_i} H(S_{ij}) \to \max_\theta, \tag{2}$$

где

$$H(S_i) = -\sum_k \frac{N_i^{(k)}}{N_i} \log \frac{N_i^{(k)}}{N_i}. \tag{3}$$

То есть максимизируется разность энтропий исходной подвыборки S_i и получаемых из неё подвыборок S_{ij}.

В качестве меры неоднородности выборки также могут быть использованы *неоднородность Джини (Gini impurity)*:

$$\mathcal{I}_2(S_i) = \sum_{i \neq j} \mathsf{P}_i \mathsf{P}_j = 1 - \sum_i \mathsf{P}_i^2, \tag{3}$$

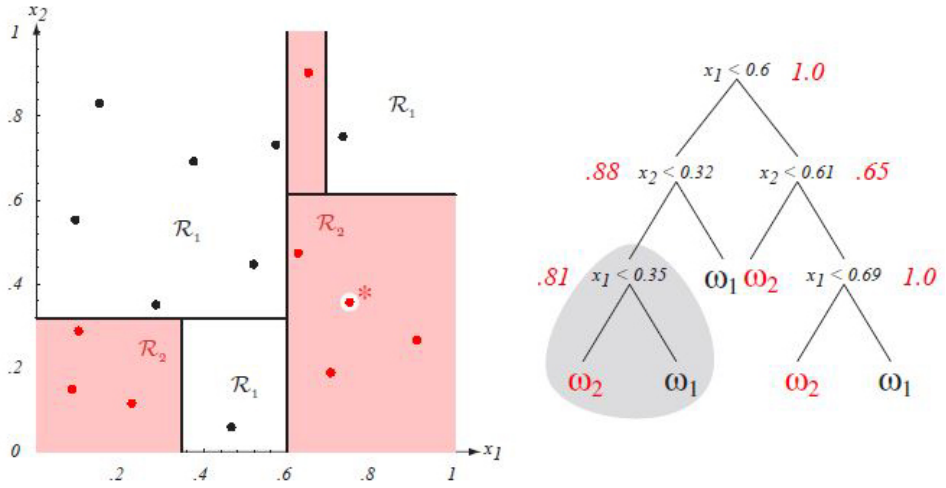


Рис. 6.6: Дерево решений с энтропией листьев равной нулю.

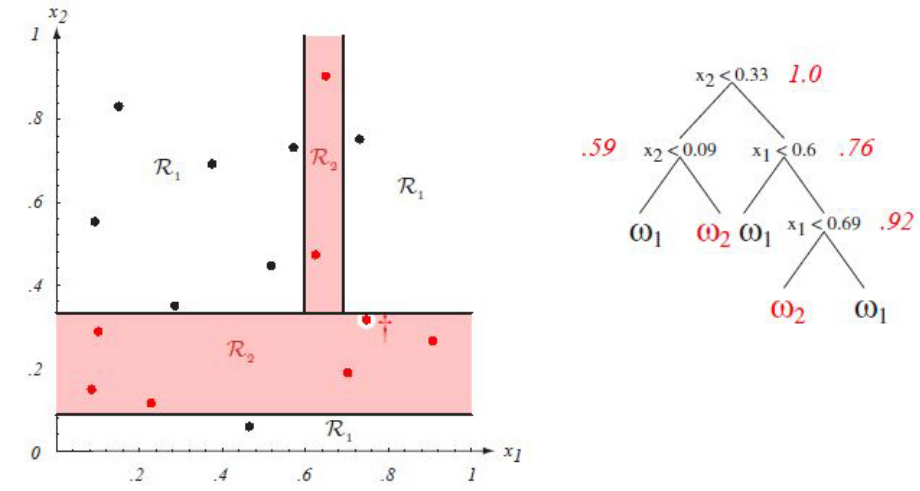


Рис. 6.7: Дерево решений с энтропией листьев равной нулю. Выборки для деревьев решений на рис. 6.6. и 6.7 отличаются только одним элементом — выделенной на рисунках точкой с незначительно изменяемой компонентой x_2.

и *неоднородность ошибочной классификации (misclassification impurity)*:

$$\mathcal{I}_3(S_i) = 1 - \max_i \mathsf{P}_i. \tag{4}$$

Меры неоднородности $\mathcal{I}_1$, $\mathcal{I}_2$, $\mathcal{I}_3$ не эквивалентны друг другу. Например (задача 6 из раздела **Задания** к этой главе), рассмотрим следующее разбиение выборки в i-м узле дерева решений: $|S_i| = 100,\ N_i^{(1)} = 90,\ N_i^{(2)} = 10;\ |S_{i1}| = 70,\ N_{i1}^{(1)} = 70,\ N_{i1}^{(2)} = 0;\ |S_{i2}| = 30,\ N_{i2}^{(1)} = 20,\ N_{i2}^{(2)} = 10.$ Такое разбиение оказывается достаточно неплохим в ситуации, когда нет разбиений, которые давали бы большинство элементов, принадлежащих классу C_2, в любом из двух потомков, поскольку после этого разбиения следующим разбиением мы можем добиться верной классификации. Между тем, вероятность ошибки классификации составляет 0.1 для всех возможных разбиений S_i, что не позволяет с его помощью выбрать наилучшее разбиение. В то время как индекс Джини показывает, что при получении подвыборок в соответствии с таким разбиением неоднородность подвыборок уменьшается и указанное разбиение является эффективным при построении (обучении) дерева решений.

Однако, выбор функции неоднородности редко оказывается решающим для качества дерева решений как классификатора. Часто используется энтропия ввиду естественности её применения, основанной на множестве приложений из теории информации, и простоте её вычисления. Однако большее значение на точность классификации и регрессии с помощью обученного дерева решений оказывают критерий остановки ветвления и процедура усечения дерева.

6.4 Критерии остановки ветвления

Если ветвить дерево решений до тех пор, пока не будет достигнута минимальная неоднородность, мы можем получить переобучение. В наихудшем случае это может привести к тому, что каждый лист полученного дерева будет содержать подвыборку, состоящую из одного элемента исходной выборки. В результате нами будет получен не классфикатор с достаточной для классификации обобщающей силой, а дерево поиска, полученное для конкретной данной выборки. И наоборот, если ветвление остановить слишком рано, то ошибка классификации будет слишком велика, что будет соответствовать недообучению.

Могут быть использованы следующие критерии остановки ветвления:

1) минимизация ошибки на тестовой выборке;
2) достижение порогового значения неоднородности подвыборок узлов;
3) достижение порогового значения на мощность подвыборок узлов;
4) минимизация неоднородности с регуляризацией.

Рассмотрим эти варианты.

1. В первом случае мы ветвим дерево до тех пор, пока не будет минимизирована ошибка на тестовой выборке, не использумой при произведённом выборе классификаторов в узлах полученного на текущий момент дерева.

2. Во втором случае мы останавливаем ветвление, как только

$$\max_{\theta_i} \Delta\mathcal{I}(i) \leq \beta$$

для некоторого заданного порогового значения β. При этом для обучения используем все данные. Полученное дерево решений может быть *несбалансированным*, то есть его листья могут находиться на разных уровнях.

3. При фиксировании достижения порогового значения на мощность подвыборки мы останавливаем ветвление в i-м узле, когда $|S_i| \leq M$ для заданного порогового значения M. Преимущество этого подхода состоит в том, что мы получаем «более мелкое» разбиение там, где данных много (их плотность большая), и «крупное», там где их мало (то есть их плотность велика).

4. При минимизации неоднородности с регуляризацией, останавливаем ветвление, когда будет достигнут минимум функции

$$\lambda \cdot \text{size} + \sum_{LN} \mathcal{I}(i) \leq \beta,$$

где $\lambda > 0$ — регуляризационный коэффициент, а size — это количество рёбер или вершин полученного на текущий момент дерева.

6.5 Усечение дерева решений

Как отмечено выше, слишком разветвлённое дерево решений, как правило, представляет собой переобученный классификатор, который может рассматриваться, скорее, как дерево поиска для заданной выборки.

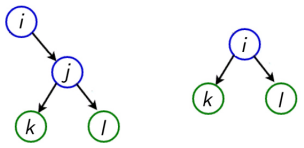


Рис. 6.8: Нерелевантный узел дерева решений.

По этой причине для такого дерева решений необходима процедура его *усечения* (или *подрезания*), минимизирующая эффект горизонта. Процедура усечения дерева решений включает в себя следующие этапы:

1). Строим дерево решений полностью до тех пор, пока неоднородность листьев не становится минимальной.
2). Рассматриваем все пары соседних листьев и объединяем их, если уменьшение неоднородности $\Delta\mathcal{I}(i)$ для узла i, потомками которого они являются, при их получении оказалось меньше установленного порогового значения. И, в целом, удаляем поддеревья, корни которых — это произвольные узлы i дерева решений такие, что $\Delta\mathcal{I}(i)$ оказывается меньше установленного порогового значения.
3). Удаляем нерелевантные узлы. Узел j, смежный с узлом i и следующий после него *нерелевантен*, если $S_i = S_j = S_k \bigcup S_l$, то есть классификатор узла j не приводит к разделению выборки S_i на подвыборки (рис. 6.8).

Усечение, как и построение дерева решений, должно производиться с учётом контекста, задаваемого решаемой прикладной задачей. Так, если какие-то признаки оказываются менее значимыми для повышения точности классификации, то они должны использоваться в узлах, более далеко отстоящих от корневого узла, которые и будут предпочтительны для усечения.

6.6 Случай неопределённых атрибутов

6.7 Случайные леса. Ансамбли классификаторов. Бэггинг. Бустинг

6.8 Задания

1. Докажите, что для любого дерева решений существует функционально эквивалентное ему дерево решений, в котором последовательность классификаторов («вопросов») на пути от корня дерева к его листу содержит только неповторяющиеся классификаторы.
2. Докажите, что для любого дерева решений существует эквивалентное ему двоичное дерево решений.
3. Рассмотрим дерево с двумя уровнями, в котором корневая вершина смежна с B листьями. Каковы нижняя и верхняя границы количества уровней в функционально эквивалентном такому дереву двоичном дереве решений, выраженные как функции от B? Каким будет количество узлов в таком дереве?
4. Сравните вычислительные сложности классификации с помощью монотетичного и политетичного дерева, обучаемых на одних и тех же данных следующим образом. Предположим, в выборке из N элементов имеется по $N/2$ элементов каждого класса. Элемент выборки имеет d атрибутов, каждый из которых принимает одно из k значений. Предполагается, что наилучшее разбиение разбивает выборку на две равные части.
   а) Сколько уровней будет в монотетичном и политетичном деревьях?
   б) Какова сложность нахождения оптимального разбиения в корнях таких деревьев?
   в) Сравните общую вычислительную сложность обучения таких деревьев.
5. Оцените вычислительную сложность обучения монотетичного дерева решений с использованием какой-либо меры неоднородности. Предположим имеется c классов $w_1, \ldots, w_c$. Выборка *сбалансирована*, то есть содержит по n/c d-мерных элементов каждого класса.
   а) Сколько может быть разбиений в корневой вершине?

б) Какова вычислительная сложность нахождения разбиения, минимизирующего энтропию?

в) Оцените вычислительную сложность разбиения, минимизирующего энтропию в корневой вершине.

г) Для упрощения рассмотрения предположим, что в каждой вершине мы разбиваем подвыборку на две подвыборки одинакового размера, и подвыборка каждого листа дерева решений состоит из одного элемента. Сколько будет уровней в таком дереве?

д) Количество классов, представители которого которого есть в подвыборке узла, зависит от уровня дерева решений. Так, на 1-м уровне подвыборка корневой вершины содержит элементы всех c классов, в узлах смежных листьям — двух классов (что это за классы будет определяться конкретной вершиной). Оцените количество классов для каждого уровня.

е) Оцените вычислительную сложность построения такого дерева решений вплоть до L-го уровня.

ж) Предположим, что мы имеем выборку $\{x^{(i)}\}_{i=1}^{N}$ размера $N = 2^{10}$, $x^{(i)}$ — 6-мерный вектор признаков (атрибутов), количество классов $c = 16$, выборка сбалансирована. Предположим, одна элементарная операция требует для выполнения 10^{-10} сек. Сколько времени потребуется для обучения дерева решений и прогнозирования с его помощью?

6. Рассмотрим следующее разбиение выборки S в i-м узле дерева решений: $|S_i| = 100$, $N_i^{(1)} = 90$, $N_i^{(2)} = 10$; $|S_{i1}| = 70$, $N_{i1}^{(1)} = 70$, $N_{i1}^{(2)} = 0$; $|S_{i2}| = 30$, $N_{i2}^{(1)} = 20$, $N_{i2}^{(2)} = 10$. Покажите, что если нет разбиений, которые давали бы большинство элементов из C_2 в любом из двух потомков, то вероятность ошибки классификации составляет 0.1 для всех возможных разбиений S_i. Это не позволяет с его помощью этой меры неоднородностии выбрать наилучшее разбиение. Позволят ли это сделать энтропия и коэффициент Джини?

7. Рассмотрим двоичное дерево решений.

а) Покажите, что уменьшение энтропии, которое даёт один да/нет-классификатор, не может быть больше одного бита. Обобщите результат для случая произвольного количества потомков узла.

б) Объясните, почему возможны ситуации, когда неоднородность в узле может быть меньше, чем в его потомке. Приведите пример.

8. Покажите, что метод вспомогательных (суррогатных) расщеплений использует предположение, что признак, значение которого не задано для элемента выборки, наиболее информативен.
9. Предположим, что в задаче классификации с двумя классами дана следующая выборка элементов с двоичными атрибутами:

w_1	w_2
0110	1011
1010	0000
0011	0100
1111	1110

а) Постройте дерево решений, используя энтропию в качестве функции неоднородности.

б) С помощью формул булевой алгебры выразите каждый класс простейшим логическим выражением, то есть логическим выражением с наименьшим количеством операций OR и AND.

7 Байесовская теория решений

7.1 Байесовское решающее правило

Байесовская теория решений — это подход к решению задач классификации, основанный на выборе класса для заданного вектора признаков, исходя из оценивания вероятности ошибки при таком выборе и вероятных потерь, которые мы понесём при выборе того или иного класса. Для применения этого подхода решаемая нами задача должна быть сформулирована в терминах теории вероятностей и все необходимые для её решения вероятности, плотности и условные плотности вероятностных распределений должны быть известны.

Предположим, что по конвейеру к нам поступают детали, среди которых случайным образом могут попадаться бракованные. Используя терминологию теории решений, мы можем сказать, что в данном случае возможны два *состояния природы*: либо прибывшая по конвейеру деталь является бракованной, либо нет. Пусть ω обозначает состояние природы: $\omega = \omega_1$ для качественной детали, $\omega = \omega_2$ для бракованой детали. Поскольку состояние природы — наличие брака в детали, получаемой с конвейера для нас непредсказуемо, то будем считать ω дискретной случайной величиной. Предположим также, что нам известны вероятности $\mathsf{P}(\omega_1)$ и $\mathsf{P}(\omega_2)$ $(\mathsf{P}(\omega_1) + \mathsf{P}(\omega_2) = 1)$ наличия этих состояний природы. Эти вероятности отражают наше априорное знание о том, насколько вероятно получить с конвейера бракованую или качественную деталь до того, как мы сможем выяснить это в действительности. Значение $\mathsf{P}(\omega_2)$ зависит от износа станков, используемых при производстве детали, материала, из которого она изготавливается и пр.

Нам необходимо принять решение о качестве детали, которая поступила по конвейеру. Мы предполагаем, что наше решение о состоянии при-

роды повлечёт некоторые последствия, которые могут быть выражены в виде *потерь*, которые мы понесём в случае принятия неверного решения о качестве детали. Это могут быть дополнительные денежные расходы, время, затраченное на исправление последствий принятия неверного решения и пр.

Рассмотрим два возможных подхода к решению поставленной задачи.

Подход 1. Рассмотрим ситуацию, когда единственной доступной нам информацией, которую мы можем использовать при принятия решения о качестве получаемой по конвейеру детали, являются априорные вероятности $\mathsf{P}(\omega_1)$ и $\mathsf{P}(\omega_2)$. В этом случае мы можем действовать, используя следующее правило. Для поступаемой по конвейеру детали принимать решение о состоянии природы ω_1, если $\mathsf{P}(\omega_1) > \mathsf{P}(\omega_2)$, иначе принимать решение о состоянии природы ω_2.

Основываясь только на априорной вероятности и не используя никакой информации о конкретной детали, поступившей с конвейера, мы всегда будем принимать только одно решение о состоянии природы. Если одна из вероятностей $\mathsf{P}(\omega_1)$ и $\mathsf{P}(\omega_2)$ существенно больше другой, то такое решение для большинства получаемых деталей может оказаться верным. Однако, если эти вероятности равны или близки к $1/2$, то такое решение повлечёт значительные потери. Под потерями в данном случае можно понимать убыток, который понесёт изготовитель деталей, принимая качественные детали за бракованные и наоборот. В среднем для каждой второй детали решение о её качестве будет приниматься неправильно.

Подход 2. Предположим теперь, что кроме априорных вероятностей получения качественной или бракованой детали, мы имеем в своём распоряжении также числовое значение некоторого признака x детали. Известно, что его значения в большинстве случаев различаются для качественных и бракованых деталей. Это может быть масса детали, её прочность или какой-либо другой признак, характеризующий её качество. Будем считать, что x — это случайная непрерывная величина, для которой заданы условные плотности $\mathsf{p}(x|\omega_1)$ и $\mathsf{p}(x|\omega_2)$, показывающие насколько значение x вероятно для каждого из состояний природы. Как может повлиять результат измерения x на наше решение о состоянии природы?

В соответствии с формулой Байеса вероятность $\mathsf{P}(\omega_i|x)$ иметь состояние природы ω_i при наличии измерения x равна:

$$\mathsf{P}(\omega_i|x) = \frac{\mathsf{p}(x|\omega_i)\mathsf{P}(\omega_i)}{\mathsf{p}(x)}, \tag{1}$$

где

$$\mathsf{p}(x) = \mathsf{p}(x|\omega_1)\mathsf{P}(\omega_1) + \mathsf{p}(x|\omega_2)\mathsf{P}(\omega_2).$$

Формула Байеса даёт возможность получить апостериорные вероятности состояний природы $\mathsf{P}(\omega_1|x)$ и $\mathsf{P}(\omega_2|x)$ при получении значения признака x. Правило, в соответствии с которым мы будем выбирать состояние природы, может быть сформулировано следующим образом: при значении x признака выбрать такое состояние природы ω_i, для которого достигается максимальное значение $\mathsf{P}(\omega_i|x)$, $i=\overline{1,2}$.

Два предложенных выше похода задают два правила выбора состояний природы, называемых «решающими правилами». *Решающее правило* — это правило выбора состояния природы.

В первом случае, формулируя решающее правило, мы обошлись только лишь априорными вероятностями состояний природы $\mathsf{P}(\omega_1)$ и $\mathsf{P}(\omega_2)$, не используя никаких признаков деталей, и сформулировали

Решающее правило 1. Принять решение, что текущее состояние природы — это ω_1, если $\mathsf{P}(\omega_1) > \mathsf{P}(\omega_2)$, и принять решение, что текущее состояние природы ω_2, если $\mathsf{P}(\omega_1) \leq \mathsf{P}(\omega_2)$.

Во втором случае нам известно значение некоторого признака x детали, исходя из которого можно делать предположения о её качестве. В этом случае мы принимаем решение, используя, представляемую им дополнительную информацию о вероятности состоянии природы.

Решающее правило 2. Принимаем решение о том, что текущее состоянии природы — ω_1, если при наблюдении (измерении) получено x такое, что $\mathsf{P}(\omega_1|x) > \mathsf{P}(\omega_2|x)$, и принимаем решение о том, что состоянии природы — ω_2, если при наблюдении получено x такое, что $\mathsf{P}(\omega_1|x) \leq \mathsf{P}(\omega_2|x)$.

Сформулированное решающее правило 2 называется *байесовским* решающим правилом.

7.2 Минимизация ошибки и условный риск

Минимизация ошибки при использовании байесовского решающего правила. При применении сформулированного выше подхода к классификации состояний природы наша задача состоит в получении такого решающего правила, при котором минимизируется ошибка при классификации. Найдём вероятность ошибки $\mathsf{P}(\text{ошибка}|x)$ при применении байесовского решающего правила для значения признака x:

$$\mathsf{P}(\text{ошибка}|x) = \begin{cases} \mathsf{P}(\omega_2|x), & \text{если принимаем решение о } \omega_1, \\ \mathsf{P}(\omega_1|x), & \text{если принимаем решение о } \omega_2. \end{cases} \qquad (2)$$

Поскольку в ходе классификации состояний природы мы можем получать все значения x из возмножной области его значений, мы заинтересованы в том, чтобы минимизировать *средняюю вероятность ошибки* $\mathsf{P}(\text{ошибка})$, которая рассчитывается по следуюшей формуле:

$$\mathsf{P}(\text{ошибка}) = \int_{-\infty}^{+\infty} \mathsf{P}(\text{ошибка}|x)\mathsf{p}(x)dx,$$

где $\mathsf{P}(\text{ошибка}|x)$ — вероятность ошибки при значении признака, равном x. Если для любого $x \in \mathbb{R}$ ошибка оказывается минимальной из возможных, как это происходит при применении байесовского решающего правила, то в результате его применения мы получим минимальное значение вероятности $\mathsf{P}(\text{ошибка})$. Из чего следует, что байесовское решающее правило минимизирует среднюю ошибку.

Рассмотрим возможные «крайние» случаи при использовании байесовского решающего правила.

а) Для некоторого x имеем равенство значений функции правдоподобия для состояний природы ω_2 и ω_2:

$$\mathsf{p}(x|\omega_1) = \mathsf{p}(x|\omega_2).$$

В этом случае наблюдение x не даёт информации о состоянии природы, и решение целиком определяется априорными вероятностями состояний природы.

б) Имеем равенство априорных вероятностей состояний природы:

$$\mathsf{P}(\omega_1) = \mathsf{P}(\omega_2).$$

В этом случае принятие решения производится исходя только из значений функций правдоподобия $\mathsf{p}(x|\omega_i)$ в x.

На рисунках 7.1 и 7.2 показаны возможные графики для функций правдоподобия и апостериорных плотностей для состояний природы ω_1 и ω_2. Разница между значениями $\mathsf{p}(x|\omega_1)$ и $\mathsf{p}(x|\omega_2)$ характеризует разницу в вероятности иметь значение признака x для состояний природы ω_1 и ω_2 (рис. 7.1).

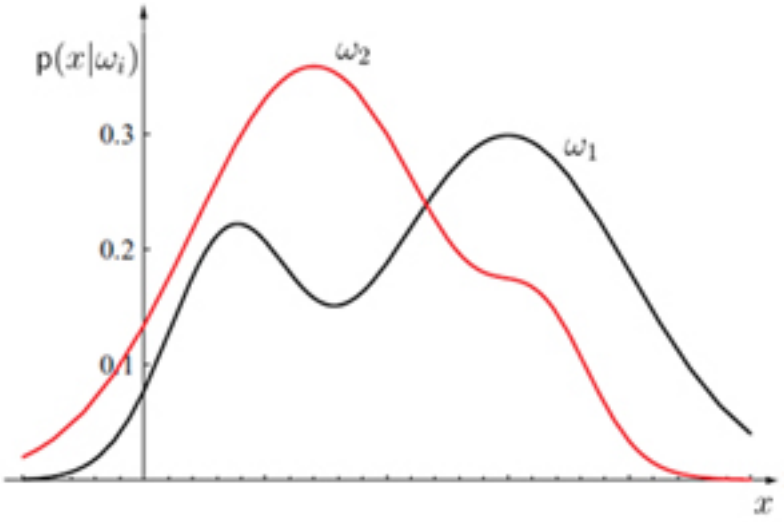


Рис. 7.1: Функции правдоподобия для состояний природы ω_1 и ω_2.

Разница между значениями $\mathsf{P}(\omega_1|x)$ и $\mathsf{P}(\omega_2|x)$ характеризует разницу в апостериорных вероятностях состояний природы ω_1 и ω_2 при значении признака x (рис. 7.2).

Обобщение подхода. Произведём далее обобщение рассмотренного нами подхода.

1) Будем использовать более одного признака, то есть $x \in \mathbb{R}^m$, $m > 1$.
2) Будем допускать произвольное количество c состояний природы ω_i, $i = \overline{1, c}$.

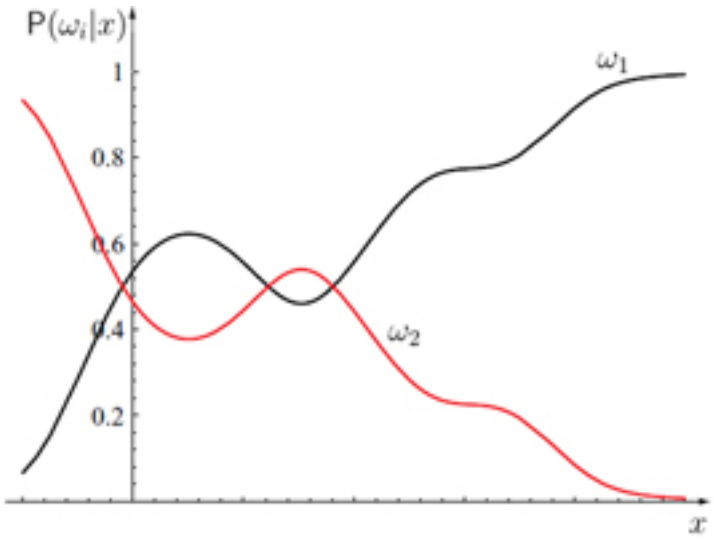


Рис. 7.2: Апостериорные вероятности для состояний природы ω_1 и ω_2.

3) Будем допускать действия отличные от принятия решения о состоянии природы, прежде всего, допуская решение, состоящее в отказе принимать решение о состоянии природы, если это приводит к меньшим потерям, чем принятие такого решения.
4) Введём *функцию потерь* как обобщение введённого нами выше понятия вероятности ошибки.

Функция потерь устанаваливает зависимость между нашим выбором решения о состоянии природы и потерями. Пусть далее $\Omega = \{\omega_1, \ldots, \omega_c\}$ — конечное множество возможных состояний природы. $\mathrm{A} = \{\alpha_1, \ldots, \alpha_a\}$ — конечное множество из a возможных действий при выборе состояния природы. Действия могут состоять как в выборе одного из возможных состояний природы, так и в отказе от такого выбора, если это допустимо и мы при этом несём меньшие потери. Потери, выражаемые *функцией потерь* λ: $\lambda(\alpha_i|\omega_j)$, — это потери, связанные с принятием действия α_i при действительном состоянии природы ω_j.

Для значения вектора признаков $x = (x_1, \ldots, x_m)$ как $\mathsf{p}(x|\omega_i)$ будем обозначать плотность распределения вектора признаков x при состоянии природы ω_i. Для $x \in \mathbb{R}^m$ также будем иметь (1), где

$$\mathsf{p}(x) = \sum_{i=1}^{c} \mathsf{p}(x|\omega_i)\mathsf{P}(\omega_i).$$

Введём функцию *условного риска* для выражения ожидаемых потерь при совершении действия α_i:

$$R(\alpha_i|x) = \sum_{j=1}^{c} \lambda(\alpha_i|\omega_j)\mathsf{P}(\omega_j|x). \tag{3}$$

Будем далее решать задачи классификации состояний природы, минимизируя ожидаемые потери. Для этого будем выбирать действие, минимизирующее условный риск для каждого значения $x \in \mathbb{R}^m$. Под *решающим правилом* будем понимать функцию $\alpha(x) : \mathbb{R}^m \to \mathrm{A}$. То есть $\alpha(x) = \alpha_i$, где $\alpha_i \in \mathrm{A}$.

Общий риск R при использовании решающего правила $\alpha(x)$ определим как

$$R = \int_{-\infty}^{+\infty} R(\alpha(x)|x)\mathsf{p}(x)dx,$$

где кратный интеграл берётся по всем допустимым значениями признаков x_i, $i = \overline{1,m}$, а под dx понимается бесконечно малое приращение объёма $dx_1 \times \ldots \times dx_m$. Выбирая такое решающее правило $\alpha(x)$, что $R(\alpha(x)|x)$ является минимальным для каждого x, получаем минимум общего риска R.

После проведённых обобщений байесовское решающее правило может быть сформулировано следующим образом: для каждого $x \in \mathbb{R}^m$ минимизируем условный риск $R(\alpha(x)|x)$, задавая правило выбора действия $\alpha_i \in \mathrm{A}$ как функцию $\alpha(x) = \alpha_i$. Минимальный общий риск R, задаваемый (3), будем далее называть *байесовским риском*.

Минимальная ошибка и минимум условного риска. Покажем, что классификация с минимизацией ошибки эквивалентна классификации с минимумом условного риска для функции потерь, заданной следующим образом:

$$\lambda(\alpha_i|\omega_j) = \begin{cases} 0, & \text{если } i = j, \\ 1, & \text{если } i \neq j, \end{cases}$$

то есть все возможные ошибки при классификации приводят к одинаковым потерям. Потерь нет в том случае, если классификация состояния природы произведена верно.

Условный риск $R(\alpha_i|x)$ в этом случае рассчитывается как

$$R(\alpha_i|x) = \sum_{j=1}^{s} \lambda(\alpha_i|\omega_j)\mathsf{P}(\omega_j|x) = \sum_{j\neq i} \mathsf{P}(\omega_j|x) = 1 - \mathsf{P}(\omega_i|x).$$

То есть в соответствии с байесовским решающим правилом для минимизации условного риска мы выбираем такое состояние природы ω_i, что

$$\mathsf{P}(\omega_i|x) = \max_{\omega_j\in\Omega} \mathsf{P}(\omega_j|x),$$

что эквивалентно выбору состояния природы, минимизирующего вероятность ошибки.

7.3 Классификация в случае двух классов

Применим байесовское решающее правило для классификации двух состояний природы. В этом случае в принятых нами обозначениях $\Omega = \{\omega_1, \omega_2\}$. $\mathrm{A} = \{\alpha_1, \alpha_2\}$ — возможные действия, состоящие в выборе состояний природы: α_1 — выбор состояния природы ω_1, α_2 — выбор ω_2.

Пусть $\lambda_{ij} = \lambda(\alpha_i|\omega_j)$ — значение функции потерь при выборе действия α_i— классификации состояния природы как ω_i — при действительном состоянии природы ω_j. Можно считать, что задана *матрица потерь* $\Lambda = (\lambda_{ij})$:

$$\Lambda = \begin{pmatrix} \lambda_{11} & \lambda_{12} \\ \lambda_{21} & \lambda_{22} \end{pmatrix}.$$

Матрица потерь аналогичным образом задаётся для произвольного количества состояний природы.

При выборе действий α_1 и α_2 имеем:

$$\begin{cases} R(\alpha_1|x) = \lambda_{11}\mathsf{P}(\omega_1|x) + \lambda_{12}\mathsf{P}(\omega_2|x), \\ R(\alpha_2|x) = \lambda_{21}\mathsf{P}(\omega_1|x) + \lambda_{22}\mathsf{P}(\omega_2|x), \end{cases} \tag{4}$$

Байесовское решающее правило формулируется следующим образом: считаем, что при значении признака x имеется состояние природы ω_1, если $R(\alpha_1|x) < R(\alpha_2|x)$. В этом случае, в соответствии с (4) получаем

$$\lambda_{11}\mathsf{P}(\omega_1|x) + \lambda_{12}\mathsf{P}(\omega_2|x) < \lambda_{21}\mathsf{P}(\omega_1|x) + \lambda_{22}\mathsf{P}(\omega_2|x),$$

что эквивалентно

$$(\lambda_{21} - \lambda_{11})\mathsf{P}(\omega_1|x) > (\lambda_{12} - \lambda_{22})\mathsf{P}(\omega_2|x). \tag{5}$$

Заметим, что $\lambda_{21} - \lambda_{11} > 0$, $\lambda_{12} - \lambda_{22} > 0$, так как в случае ошибочного выбора состояния природы потери, как правило, больше. Заменяя в (5) апостериорные вероятности произведениями функций правдоподобия и априорных вероятностей, получим

$$(\lambda_{21} - \lambda_{11})\mathsf{p}(x|\omega_1)\mathsf{P}(\omega_1) > (\lambda_{12} - \lambda_{22})\mathsf{p}(x|\omega_2)\mathsf{P}(\omega_2).$$

Предполагая, что $\lambda_{21} > \lambda_{11}$, получаем, что выбор состояния ω_1 в соответствии с байесовским решающим правилом производится, если

$$\frac{\mathsf{p}(x|\omega_1)}{\mathsf{p}(x|\omega_2)} > \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} \cdot \frac{\mathsf{P}(\omega_2)}{\mathsf{P}(\omega_1)}. \tag{6}$$

Отношение $\mathsf{p}(x|\omega_1)/\mathsf{p}(x|\omega_2)$ называется *отношением правдоподобия.*

Таким образом, в случае классификации для двух классов, байесовское решающее правило может быть сформулировано следующим образом:

Байесовское решающее правило для случая двух классов. Выбирать ω_1 в том случае, если отношение правдоподобия превышает пороговое значение, не зависящее от измеренного значения признака x и задаваемое правой частью (6).

7.4 Задача классификации с возможным отказом от принятия решения

Существуют такие задачи классификации, при решении которых помимо выбора класса (состояния природы), к которому требуется отнести вектор признаков, допустим отказ от такого выбора. Такое действие — отказ от принятия решения — при определённым образом заданной функции потерь может давать мнимальный риск. Например, для рассмотренного нами случая классификации детали, поступающей по конвейеру, в определённых ситуациях мы можем отказаться от определения того, является она бракованой или нет, поскольку принятие нами ошибочного

решения может привести к большим потерям. Вместо этого мы можем передать полномочия по принятию такого решения сотрудникам отдела, обладающим специальным оборудованием.

Пусть имеется c классов и задана функция потерь

$$\lambda(\alpha_i|\omega_j) = \begin{cases} 0, & i = j;\ i,j = \overline{1,c}, \\ \lambda_r, & i = c+1, \\ \lambda_s, & \text{иначе}, \end{cases} \tag{8}$$

где λ_r — потери при отказе от принятия решения, λ_s — потери, соответствующие ошибке определения класса.

В этом случае минимимальный риск достигается при принятии решения ω_i в том случае, если $\mathsf{P}(\omega_i|x) \geq \mathsf{P}(\omega_j|x)$ для всех j и $\mathsf{P}(\omega_i|x) \geq 1 - \lambda_r/\lambda_s$. В противном случае мы отказываемся принимать решение.

$$R(\alpha_i|x) = \sum_{j=1}^{c} \lambda(\alpha_i|\omega_j)\mathsf{P}(\omega_j|x) = \sum_{j\neq i} \lambda_s \mathsf{P}(\omega_j|x) = \lambda_s(1 - \mathsf{P}(\omega_i|x)).$$

Если $\mathsf{P}(\omega_j|x) \leq \mathsf{P}(\omega_i|x)$, то $R(\alpha_i|x) \leq R(\alpha_j|x)$.

Отношение λ_r/λ_s определяет пороговое значение, при превышении которого апостериорной вероятностью состояния природы, мы принимаем решение. В противном случае — отказываемся. То есть при принятии решения ω_i имеем

$$\mathsf{P}(\omega_i|x) \geq 1 - \frac{\lambda_r}{\lambda_s}.$$

При $\lambda_r = 0$ всегда выгодней отказаться от принятия решения о состоянии природы, поскольку при этом будем иметь недостижимый иначе нулевой риск. Если же $\lambda_r > \lambda_s$, то для любого i:

$$\mathsf{P}(\omega_i|x) \geq 1 - \frac{\lambda_r}{\lambda_s} \geq -\delta,$$

где $\delta > 0$, а значит всегда будет меньший условный риск при принятии решения.

7.5 Разделяющие функции

Одним из способов представления классификатора, реализующего байесовское решающее правило, является использование *разделяющих функций*.

Классификатор, реализуемый с помощью разделяющих функций $g_i(x)$, $i = \overline{1,c}$, ставит в соответствие вектору признаков x состояние природы ω_i, если для $i \neq j$ верно неравенство

$$g_i(x) > g_j(x).$$

Для решения задачи классификации с минимизацией условного риска положим:

$$g_i(x) = -R(\alpha_i|x).$$

Для более частного случая минимизации вероятности ошибки при классификации, принимаем $g_i(x) = \mathsf{P}(\omega_i|x)$.

Выбор разделяющих функций может быть произведён не единственным образом. Если h — монотонно возрастающая функция, то при замене функций $g_i(x)$ на функции $h(g_i(x))$ классификация состояний приоды будет производиться для любого x точно так же, как она производилась бы с использованием функций $g_i(x)$. Однако, использование эквивалентных разделяющих функций, производимое, например, с учётом известного распределения на пространстве векторов признаков, может быть более удобным с вычислительной точки зрения. Кроме того, другой набор разделяющих функций может быть использован для удобства записи или упрощения графического представления областей векторов признаков, соответствующих различным состояниям природы.

В качестве разделяющих функций могут быть использованы следующие:

а) $g_i(x) = \mathsf{P}(\omega_i|x)$,
б) $g_i(x) = \mathsf{p}(x|\omega_i)\mathsf{P}(\omega_i)$,
в) $g_i(x) = \log \mathsf{p}(x|\omega_i) + \log \mathsf{P}(\omega_i)$.

Использование логарифмической функции удобно для случая нормального распределения значений компонент вектора признаков.

Разделяющие функции разбивают пространство векторов признаков x на *с областей решений* $D_1, \ldots, D_c$. Если для любого j имеем $g_i(x) > g_j(x)$, то считаем, что $x \in D_i$, и сопоставляем x состояние природы ω_i, поскольку

оно является более вероятным. Области решений D_i отделяются друг от друга своими границами, называемыми *границами областей решений*. Уравнение границы областей D_i и D_j задаётся как

$$g_i(x) = g_j(x). \tag{9}$$

Границы решений не зависят от выбора разделяющих функций. Для x, лежащих на границе между областями решений и удовлетворяющих (9), задача классификации не может быть разрешена однозначно.

Разделяющие функции для случая двух классов. Пусть задан набор из двух разделяющих функций $g_1(x)$ и $g_2(x)$ вида

$$g_i(x) = \mathsf{P}(\omega_i|x).$$

В случае, если пространство значений вектора признаков x — это прямая $\mathbb{R}$, она разделяется на области решений так, как показано на рис. 7.3.

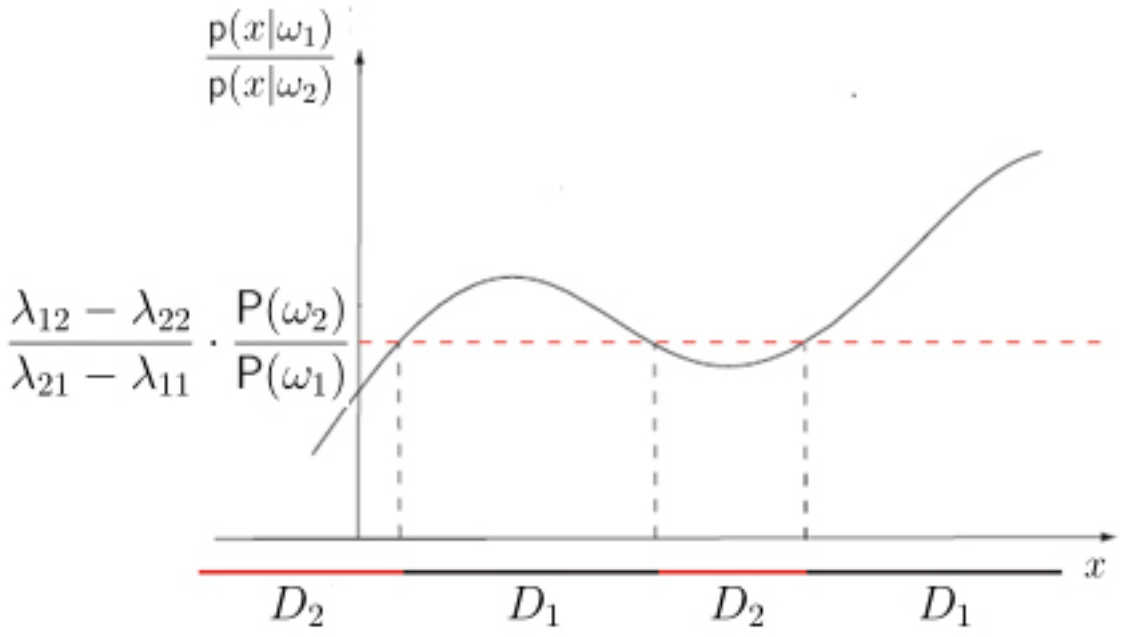


Рис. 7.3: Разбиение $\mathbb{R}$ на области ω_1 и ω_2.

Границами областей решений являются точки x_1, x_2, x_3.

Вместо двух разделяющих функций $g_1(x)$ и $g_2(x)$ можно рассматривать одну функцию

$$g(x) = g_1(x) - g_2(x).$$

При этом будем принимать решение о состоянии природы ω_1, если $g(x) > 0$, и будем принимать решение о состоянии природы ω_2, если $g(x) \leq 0$. Варианты выбора функции $g(x)$ в этом случае могут быть следующими:

$$g(x) = \mathsf{P}(\omega_1|x) - \mathsf{P}(\omega_2|x),$$

и

$$g(x) = \log \frac{\mathsf{p}(x|\omega_1)}{\mathsf{p}(x|\omega_2)} + \log \frac{\mathsf{P}(\omega_1)}{\mathsf{P}(\omega_2)}.$$

Разделяющие функции для задачи классификации с возможным отказом от принятия решения. Рассмотрим снова задачу классификации с функцией потерь (8), для которой допустим отказ от принятия решения, и получим для неё оптимальный с точки зрения минимизации общего риска разделяющие функции.

Производя классификацию с минимизацией риска, положим

$$g_i(x) = -R(\alpha_i|x).$$

Для любого x, если не происходит отказа от выбора, будет выбрано такое состояние природы ω_i, что

$$g_i(x) = \max_{i=\overline{1,c}} \{\mathsf{p}(x|\omega_i)\mathsf{P}(i)\}.$$

То есть

$$\mathsf{P}(\omega_i|x) \geq \mathsf{P}(\omega_j|x).$$

Следовательно, выбранные нами функции $g_i(x)$ будут оптимальны как разделяющие функции для классификации с минимумом ошибки.

Если происходит отказ от выбора, то, поскольку максимум достигается на $i = c + 1$, для любого j имеем:

$$\mathsf{p}(x|\omega_j)\mathsf{P}(\omega_j) \leq \frac{\lambda_s - \lambda_r}{\lambda_s} \sum_{k=1}^{c} \mathsf{p}(x|\omega_k)\mathsf{P}(\omega_k). \tag{10}$$

Разделив обе части (10) на $\mathsf{p}(x)$, получаем:

$$\frac{\mathsf{p}(x|\omega_i)\mathsf{P}(\omega_i)}{\mathsf{p}(x)} \leq \frac{\lambda_s - \lambda_r}{\lambda_s} \sum_{j=1}^{c} \frac{\mathsf{p}(x|\omega_j)\mathsf{P}(\omega_j)}{\mathsf{p}(x)}, \tag{11}$$

то есть

$$\mathsf{P}(\omega_i|x) \leq \frac{\lambda_s - \lambda_r}{\lambda_s} \sum_{j=1}^{c} \mathsf{P}(\omega_j|x) = \frac{\lambda_s - \lambda_r}{\lambda_s} \cdot 1 = \frac{\lambda_s - \lambda_r}{\lambda_s},$$

или

$$\mathsf{P}(\omega_i|x) \leq \frac{\lambda_s - \lambda_r}{\lambda_s} = 1 - \frac{\lambda_r}{\lambda_s},$$

что соответствует выбору решающего правила с минимальным риском.

Границы областей решений для случая многомерного нормального распределения. Если значения всех признаков распределены нормально, может быть проведена следующая классификация границ областей решений, задаваемых (9). Предполагается, что средние значения признаков для каждого из состояний природы заданы как $\mu^{(i)}$, и задана ковариационная $c \times c$ матрица Σ. В случае взаимно независимых признаков, составляющих вектор признаков, эта матрица диагональна, в противном случае — не диагональна.

В [9, 11] показывается, что использование разделяющих функций вида

$$g_i = \log \mathsf{p}(x|\omega_i) + \log \mathsf{P}(\omega_i)$$

экивалентно использованию следующей меры близости вектора признаков x к векторам средних значений признаков:

$$\rho(x, \mu^{(i)}) = (x - \mu^{(i)})^\top \Sigma^{-1} (x - \mu^{(i)}).$$

ρ — неотрицательно определённая квадратичная форма.

Производя классификацию в соответствии с байесовсем решающим правилом для случая, при котором все признаки взаимно независимы, мы задаём гиперплоскость, смещённую ближе к векторам средних значений $\mu^{(i)}$ для состояний природы с меньшими априорными вероятностями. В случае зависимых признаков границы областей решений задаются квадратичными формами, дающими уравнения гиперквадрик — гиперплоскостей, гиперсферы, гиперэллипсоида, гиперболоида.

7.6 Дискретный случай

До сих пор, применяя байесовскую теорию решений, мы предполагали, что компоненты вектора признаков вещественны. Во многих практических приложениях компоненты вектора признаков принимают дискретные значения. В таких случаях формула Байеса принимает вид:

$$\mathsf{P}(\omega_i|x) = \frac{\mathsf{P}(x|\omega_i)\mathsf{P}(\omega_i)}{\mathsf{P}(x)},$$

где

$$\mathsf{P}(x) = \sum_{i=1}^{c} \mathsf{P}(x|\omega_i)\mathsf{P}(\omega_i).$$

Определение условного риска $R(\alpha|x)$ для случая дискретного вектора признаков не отличается от того, что было дано нами выше для вектора признаков с вещественными компонентами. Не меняется и байесовское решающее правило: чтобы минимизировать общий риск, мы выбираем такое действие $\alpha^* \in \{\alpha_1, \ldots, \alpha_c\}$, для которого риск $R(\alpha_i|x)$ минимален:

$$\alpha^* = \arg\min_{1 \le i \le c} R(\alpha_i|x).$$

Независимые бинарные признаки. Применим байесовскую теорию решений для классификации состояний природы, исходя из бинарности вектора признаков x, то есть $x \in \mathbb{I}^m$. Рассмотрим эту задачу для случая двух состояний природы и взаимно независимых признаки. Пусть $p_i = \mathsf{P}(x_i = 1|\omega_1)$, $q_i = \mathsf{P}(x_i = 1|\omega_2)$.

В такой задаче классификации значение каждого признака представляет собой ответ вида «да/нет» о распознаваемом состоянии природы. Если $p_i > q_i$, то мы ожидаем, что i-ый признак для данного вектора даёт ответ «да» более часто, когда действительное состояние природы ω_1, чем когда действительное состояние природы ω_2.

Предполагая независимость признаков, имеем

$$\mathsf{P}(x|\omega_1) = \prod_{i=1}^{d} p_i^{x_i}(1 - p_i)^{1 - x_i}$$

и

$$\mathsf{P}(x|\omega_2) = \prod_{i=1}^{d} q_i^{x_i}(1-q_i)^{1-x_i}.$$

Отношение правдоподобия в этом случае имеет вид:

$$\frac{\mathsf{P}(x|\omega_1)}{\mathsf{P}(x|\omega_2)} = \prod_{i=1}^{d}\left(\frac{p_i}{q_i}\right)^{x_i}\left(\frac{1-p_i}{1-q_i}\right)^{1-x_i}.$$

Таким образом, для случая двух состояний природы получаем разделяющую функцию

$$g(x) = \sum_{i=1}^{d}\left(x_i \ln\frac{p_i}{q_i} + (1-x_i)\ln\frac{1-p_i}{1-q_i}\right) + \ln\frac{\mathsf{P}(w_1)}{\mathsf{P}(w_2)}.$$

Заметим, что эта функция линейна по x_i, и, следовательно, мы можем записать

$$g(x) = \sum_{i=1}^{d} w_i x_i + w_0,$$

где

$$w_i = \ln\frac{p_i(1-q_i)}{q_i(1-p_i)}$$

для $i = \overline{1,d}$ и

$$w_0 = \sum_{i=1}^{d}\ln\frac{1-p_i}{1-q_i} + \ln\frac{P(\omega_1)}{P(\omega_2)}.$$

Решающее правило может быть сформулировано следующим образом. Мы принимаем решение о текущем состоянииии природы ω_1, если $g(x) > 0$, и принимаем решение о состоянии природы ω_2, если $g(x) \leq 0$.

Значение $g(x)$ — это взвешенная сумма компонент вектора признаков x. Величина веса w_i означает значимость ответа «да» для признака x_i при проведении классификации. Если $p_i = q_i$, то значение x_i i-го признака не даёт нам никакой информации о состоянии природы, получаем $w_i = 0$. Если $p_i > q_i$, то $1-p_i < 1-q_i$ и $w_i > 0$. В этом случае ответ «да» для x_i даст ненулевой вклад w_i в пользу выбора состояния природы ω_1. При любом q_i значение w_i тем больше, чем больше p_i. С другой стороны,

если $p_i < q_i$, значение w_i отрицательно и ответ «да» даёт вклад равный $|w_i|$ для выбора состояния природы ω_2. Значения априорных вероятностей $\mathsf{P}(\omega_1)$ и $\mathsf{P}(\omega_2)$ влияют на значение w_0. При неизменности прочих параметров нашей модели, при увеличении $P(\omega_1)$ вероятным становится состояние природы ω_1, при уменьшении $P(\omega_1)$ более вероятным становится состояние природы ω_2.

Таким образом, используя условие независимости признаков, мы построили построить линейный классификатор состояний природы. В данном случае $x \in \mathbb{I}^m$, то есть возможные значения x являются вершинами гиперкуба $\mathbb{I}^m$, для разделения которых может быть использовано множество гиперплоскостей, отделяющих вершины, соответствующие состоянию природы ω_1, от вершин, соответствующих состоянию природы ω_2.

Обобщение подхода. Обобщим используемый нами подход к классификации вектора признаков с дискретными компонентами на случай, когда компоненты могут принимать произвольное количество l своих значений.

Пусть $\mathsf{p}_{k,ij}$ — вероятность того, что x_i принимает значение $k \in \{1, \ldots, l\}$ при состоянии природы ω_j, $\sum_{k=1}^{l} \mathsf{p}_{k,ij} = 1$. Вероятность $\mathsf{P}(x|\omega_j)$ получения признаком значения x при состоянии природы ω_j ищем как произведение множителей вида

$$\mathsf{p}_{1,ij}^{\varphi_1(x_i)} \mathsf{p}_{2,ij}^{\varphi_2(x_i)} \cdot \ldots \cdot \mathsf{p}_{l,ij}^{\varphi_l(x_i)},$$

где $\{\varphi_k(x)\}_{k=1}^{c}$ — такая система полиномов, что $\varphi_k(x) = 1$, если $x = k$, и $\varphi_k(x) = 0$, иначе. Задача построения разделяющей функции, таким образом, сводится к построению системы функций $\{\varphi_k\}_{k=1}^{l}$, представляющих собой функции компонент x_i.

Например, рассмотрим задачу с тернарными компонентами вектора признаков, то есть принимающими значения из множества $\{-1, 0, 1\}$ со следующими вероятностями:

$$p_{ij} = \mathsf{P}(x_i = 1|\omega_j),$$

$$q_{ij} = \mathsf{P}(x_i = 0|\omega_j),$$

$$r_{ij} = \mathsf{P}(x_i = -1|\omega_j).$$

Найдём разделяющие функции $g_j(x)$ и покажем, что они позволяют получить решающее правило с минимальной вероятностью ошибки.

Определим $\mathsf{P}(x|\omega_j)$. В случае $x \in \mathbb{R}$: $\mathsf{P}(x = 1) = p$, $\mathsf{P}(x = 0) = q$, $\mathsf{P}(x = -1) = r$. Вероятность принятия того или иного значения значения x при состоянии природы ω_j может быть выражена как

$$\mathsf{P}(x \,|\, \omega_j) = p^{\frac{x^2+x}{2}} q^{1-x^2} r^{\frac{x^2-x}{2}}.$$

Для c состояний природы и m-мерного x:

$$\mathsf{P}(x \,|\, \omega_j) = \prod_{i=1}^{m} p_{ij}^{\frac{x_i^2+x_i}{2}} q_{ij}^{1-x_i^2} r_{ij}^{\frac{x_i^2-x_i}{2}},$$

следовательно,

$$g_j(x) = \left[\prod_{i=1}^{m} p_{ij}^{\frac{x_i^2+x_i}{2}} q_{ij}^{1-x_i^2} r_{ij}^{\frac{x_i^2-x_i}{2}} \right] \mathsf{P}(\omega_j). \tag{12}$$

Логарифмируя (12), получаем квадратичную разделяющую функцию для решения задачи классификации состояния природы по тернарным векторам признаков.

7.7 Задания

Дайте содержательные постановки для предложенных ниже задач.

1. Пусть условные плотности для одномерной задачи и двух классов заданы распределением Коши:

$$\mathsf{p}(x|\omega_i) = \frac{1}{\pi b} \cdot \frac{1}{1 + \left(\dfrac{x - a_i}{b} \right)^2},$$

$i = 1, 2$. Считая, что $\mathsf{P}(\omega_1) = \mathsf{P}(\omega_2)$, покажите, что $\mathsf{P}(\omega_1|x) = \mathsf{P}(\omega_2|x)$ при $x = (1/2)(a_1 + a_2)$. Изобразите схематично график $\mathsf{P}(\omega_1|x)$ для случая $a_1 = 3$, $a_2 = 5$, $b = 1$. Как ведёт себя $\mathsf{P}(\omega_1|x)$ при $x \to \pm\infty$?

2. Используя условные плотности из задачи 1 и полагая априорные вероятности равными, покажите, что минимальная вероятность ошибки определяется выражением

$$\mathsf{P}(\text{ошибка}) = \frac{1}{2} - \frac{1}{\pi}\operatorname{arctg}\left|\frac{a_2 - a_1}{2b}\right|.$$

Рассмотрите это выражение как функцию величины $(a_2 - a_1)/b$.

3. Рассмотрите следующее решающее правило для одномерной задачи и двух классов: принимать решение ω_1 в случае, если $x > \theta$; в противном случае принимать решение ω_2. Покажите, что при использовании этого правила вероятность ошибки определяется выражением

$$\mathsf{P}(\text{ошибка}) = \mathsf{P}(\omega_1)\int_{-\infty}^{\theta}\mathsf{P}(x|\omega_1)dx + \mathsf{P}(\omega_2)\int_{\theta}^{+\infty}\mathsf{P}(x|\omega_2)dx.$$

Покажите посредством дифференцирования, что для получения наименьшего значения $P(\text{ошибка})$ необходимо, чтобы величина θ удовлетворяла выражению

$$\mathsf{p}(\theta|\omega_1)\mathsf{P}(\omega_1) = \mathsf{p}(\theta|\omega_2)\mathsf{P}(\omega_2).$$

Проверьте, однозначно ли определяется этим выражением величина θ. Приведите пример, когда величина θ, удовлетворяющая данному уравнению, на самом деле соответствует максимальной ошибке.

4. Пусть $\omega_{\max}(x)$ — состояние природы, для которого $\mathsf{P}(\omega_{\max}|x) \geq \mathsf{P}(\omega_i|x)$ для любого $i = \overline{1,c}$. Покажите, что $\mathsf{P}(\omega_{\max}(x)|x) \geq 1/c$. Покажите также, что в случая принятия решения, исходя из минимизации ошибки, средняя вероятность ошибки определяется выражением

$$\mathsf{P}(\text{ошибка}) = 1 - \int \mathsf{P}(\omega_{\max}|x)\mathsf{p}(x)dx.$$

На основании полученных результатов, покажите что $\mathsf{P}(\text{ошибка}) \leq (c-1)/c$. Опишите случай, при котором $\mathsf{P}(\text{ошибка}) \leq (c-1)/c$.

5. Изобразите эти разделяющие функции и области решений для одномерного случая и двух классов для рассмотренной выше задачи классификации с возможным отказом от выбора состояния природы при $\mathsf{p}(x\,|\,\omega_1) \sim \mathcal{N}(1,1)$, $\mathsf{p}(x\,|\,\omega_2) \sim \mathcal{N}(-1,1)$, $\mathsf{P}(\omega_1) = \mathsf{P}(\omega_2) = 1/2$ и $\lambda_r/\lambda_s = 1/4$.
6. Рассмотрим рандомизированное решающее правило, состоящее в том, что с вероятностью $\mathsf{P}(\alpha_i|x)$ мы принимаем решение α_i при наблюдаемом значении x. Покажите, что риск в этом случае определяется выражением

$$R = \int \left[\sum_{i=1}^{a} R(\alpha_i|x)\mathsf{P}(\alpha_i|x)\right]\mathsf{p}(x)dx.$$

   Покажите кроме того, что риск можно минимизировать, выбирая $\mathsf{P}(\alpha_i|x) = 1$ для действия α_i, связанного с наименьшим условным риском $R(\alpha_i|x)$, т.е. что рандомизация в этом случае никакой выгоды не даёт.
7. Обоснуйте возможность перехода от (10) к (11).
8. Пусть $x \in \mathbb{I}^m$. Пусть $\mathsf{P}(\omega_j)$ — априорная вероятность состояния природы ω_j $(j = \overline{1,c})$, и пусть

$$p_{ij} = \mathsf{P}(x_i = 1|\omega_j),\ i = \overline{1,d}, j = \overline{1,c}.$$

   Пусть компоненты x_i статистически независимы.
   а) Покажите, что минимальная вероятность ошибки достигается при использовании следующего решающего правила: принять решение ω_k, если $g_k(x) \geq g_j(x)$ для всех j, где

$$g_j(x) = \sum_{i=1}^{m} x_i \log \frac{p_{ij}}{1-p_{ij}} + \sum_{i=1}^{m} \log(1-p_{ij}) + \log \mathsf{P}(\omega_j).$$

   б) Покажите, что решающее правило по уровню ошибки при этом имеет вид

$$\text{принять решение } \omega_1, \text{ если } \sum_{i=1}^{m} x_i > m/2.$$

в) Покажите, что минимальная вероятность ошибки определяется выражением

$$\mathsf{P}_e(m,p) = \sum_{k=0}^{(m-1)/2} C_m^k p^k (1-p)^{m-k}.$$

г) Чему равен предел $\mathsf{P}_e(m,p)$ при $p \to 1/2$?

д) Покажите, что $\mathsf{P}_e(m,p)$ стремится к нулю при $m \to \infty$.

Литература

[1] П.В. Новицкий, И.А. Зограф. Оценка погрешностей результатов измерений. Л.: Энергоатомиздат. Ленингр. отделение, 1985.

[2] А.И. Орлов. Часто ли распределение результатов наблюдений является нормальным? // Заводская лаборатория. 1991 Т. 57.

[3] Е.С. Вентцель. Теория вероятностей: Учеб. для вузов. М.: Высш. шк., 1999.

[4] А.А. Боровков. Теория вероятностей: учеб. пособие для вузов. М.: URSS, 2009.

[5] J. Hadamard. *Sur les problemes aux problèmes aux dérivée et leur signification physique* // Princeton University Bulletin. 1902. pp. 49–52.

[6] А. Н. Тихонов. Корректные и некорректные задачи. Большая советская энциклопедия. 3-е изд. М. : Советская энциклопедия, 1969–1978.

[7] C.M. Bishop. Pattern Recognition and Machine Learning. Springer, 2006.

[8] A.V. Prolubnikov. *An Interval Approach to Pattern Recognition of Numerical Matrices* // Reliable Computing. 2013. Vol. 19. PP. 107 – 119.

[9] Р. Дуда, П. Харт. Распознавание образов и анализ сцен. М.: Мир. 1976.

[10] T. Cover, P. Hart. *Nearest neighbor pattern classification* // IEEE Transactions on Information Theory IT-11, 1967. PP. 21–27.

[11] R. Duda, P. Hart, D. Stork. Pattern Classification. Wiley-Interscience. 2000.

[12] E.A. Nadaraya. *On Estimating Regression* // Theory of Probability and Its Applications, 1964. Vol. 9, N. 1. PP. 141–142.

[13] G.S. Watson. *Smooth regression analysis* // Sankhy?: The Indian Journal of Statistics, Series A. 1964. V. 26, N. 4. PP. 359–372.

[14] H.J. Bierens *The Nadaraya–Watson kernel regression function estimator* // Topics in Advanced Econometrics. New York: Cambridge University Press, 1994. PP. 212–247.

[15] G.O. Campos et al. *On the evaluation of unsupervised outlier detection: measures, datasets, and an empirical study* // Data Mining and Knowledge Discovery, 2016. Vol. 30, N. 4. PP. 891–927.

[16] V. Hautamaki, I. Karkkainen, P. Franti. *Outlier detection using k-nearest neighbour graph* // Proceedings of the 17th International Conference on Pattern Recognition, 2004. ICPR 2004., Cambridge, UK, 2004. Vol. 3. PP. 430–433.

[17] P.C. Hansen, V. Pereyra, G. Scherer. Least Square Data Fitting with Applications. The John Hopkins University Press, Baltimore, Maryland, 2013.

[18] E.L. Lehman, G. Casella. Theory of Point Estimation. Springer, New York, 2003.

[19] V. Kreinovich, S.P. Shary *Interval Methods for Data Fitting under Uncertainty: A Probabilistic Treatment* // Reliable Computing. 2016. Vol. 23. PP. 105-140.

[20] E.T. Jaynes. *Information Theory and Statistical Mechanics* // Physical Review. Series II. 1957. Vol. 106 (4). PP.: 620 – 630.

[21] E.T. Jaynes. *Information Theory and Statistical Mechanics II* // Physical Review. Series II. 1957. Vol. 108 (2). PP. 171 – 190.

[22] W.S. McCalloch, W. Pitts. *A logical calculus of the ideas immanent in nervous activity* // Bull. Math. Biophys. 1943. Vol. 5. PP. 115 – 133.

[23] B. Widrow and M.E. Hoff. *Adaptive switching circuits* // In IRE WESCON Convention Record. 1960. Vol. 4. PP. 96-104.

[24] F. Rosenblatt. Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms. Spartan Books, Washington DC. 1962.

[25] V.Y. Kreinovich. *Arbitrary nonlinearity is sufficient to represent all functions by neural networks: a theorem* // Neural Networks. 1991. Vol. 4 (3). PP. 381 – 383.

[26] G. Cybenko. *Approximations by superpositions of sigmoidal functions* // Mathematics of Control, Signals, and Systems. 1989. Vol. 2 (4). PP. 303 – 314.

[27] А.И. Галушкин. Синтез многослойных систем распознавания образов. М.: Энергия, 1974.

[28] P.J. Werbos. Beyond regression: new tools for prediction and analysis in the behavioral sciences. Ph.D. thesis, Harvard University, Cambridge, MA, 1974.

[29] D.E. Rumelhart, G.E. Hinton, R.J. Williams. *Learning Internal Representations by Error Propagation* // Parallel Distributed Processing, Cambridge, MA, MIT Press, 1986. Vol. 1. PP. 318-362

[30] Горбань А.Н. Обобщение аппроксимационной теоремы и вычислительные возможности нейронных сетей // Сибирский журнал вычислительной математики, 1998. 1 (1).

[31] Lu Zh., Hu P., Wang F., Hu Z., Wang L. The expressive power of neyral networks: view from the width // Advances in Neural Information Processing Systems, Curran Associates, 2017. 30.

[32] Olson M., Wyner A.J., Berk R. Modern neural networks generalize on small data sets // 32nd Conference on Neural Information Processing Systems. NeurIPS, 2018.